目录

《生物医学智能信息处理》实验一实验报告 1
数据降维与特征筛选 1
一、实验目的 1
二、实验环境 1
三、实验数据与预处理 2
四、实验内容 2：数据降维 3
五、实验内容 3：非监督学习特征筛选 7
六、实验内容 4：监督学习特征筛选 8
七、实验结论 14
附录 A：实验代码 14
附录 B：各方法 top20 特征得分图 16
附录 C：结果文件清单 20

《生物医学智能信息处理》实验一实验报告

数据降维与特征筛选

项目	内容
课程名称	生物医学智能信息处理（课程代码 317300007083）
实验名称	数据降维与特征筛选
实验学时	4
姓名 / 学号	_____

一、实验目的

1. 掌握常见的数据降维方法（主成分分析、t-SNE、自编码器）和特征筛选方法（方差、熵、t 检验、Mann-Whitney U 检验、互信息、mRMR、Lasso 回归）。
2. 通过实验了解不同方法在生物医学数据中的适用性差异，理解”无监督筛选”与“监督筛选”在原理和目标上的本质区别。
3. 掌握生物医学高维数据的可视化方法，学会用散点图结合量化指标判断样本在降维空间中是否具有类别分布模式。

二、实验环境

项目	内容
编程语言	Python 3
核心依赖	scikit-learn 1.7.0、PyTorch 2.12.1、SciPy 1.16.0、NumPy 2.2.6、Matplotlib 3.10.6、pandas

项目	内容
操作系统	Windows 11
运行方式	`cd Exp1 && python exp1_main.py`（一键复现全部结果）

自编码器使用 PyTorch 实现（指导书允许使用 Python/R/Matlab）；mRMR 在 scikit-learn 中没有内置实现，按指导书步骤自行实现。

三、实验数据与预处理

3.1 数据概况

实验数据为肝癌（HCC）研究收集的血浆 cfDNA（cell-free DNA）片段模式数据，包含两个文件：

文件	内容
`PNAS_HCC.mat`	`ma` 特征矩阵 (1008, 122)，`co` 类别编码，`sample` 样本 ID
`PNAS_id_inforamtion.xlsx`	样本 ID、组名（healthy/HCC/Cirrhosis/HBV）、编码

指导书说明 `ma` 是”一行为一个特征，一列为一个样本”。因此读入后需**转置**为 `X (122 样本 × 1008 特征)` 才能按样本做降维和可视化。

本实验使用的 122 个样本由 **90 例肝癌（HCC）**与 **32 例健康对照（healthy）**组成，共 1008 个特征，无缺失值。

3.2 标签对齐（重要）

原始 `co` 变量的编码方向容易踩坑，实际交叉校验结果如下：

来源	HCC（肝癌）	healthy（对照）
`.mat` 中的 `co`	**0**	**1**
`.xlsx` 中的 `code`	2	1

即 `co` 与 xlsx 的编码**恰好相反**，且不能靠样本 ID 首字母判断类别（例如 `GM1100` 是 G 前缀，实际为 HCC 样本）。

本实验以 `co` 为准，并与 xlsx 的组名**逐样本交叉校验**（122/122 全部一致），再统一转换为内部约定：

$$y = 1 - co, \qquad y = 1 \text{ 表示 HCC（肝癌）}, \quad y = 0 \text{ 表示 healthy（对照）}$$

代码中该映射配有断言，一旦数据版本变化导致映射失效会直接报错而非静默错配。

3.3 标准化

原始各特征的方差差异很大（0.0102 ~ 1.4678，相差逾 140 倍）。PCA、t-SNE 和自编码器都对特征尺度敏感，因此对 `X` 按特征做 z-score 标准化（均值 0、标准差 1）。

需要特别说明的是：**实验内容 3 的”方差法”必须使用未标准化的原始矩阵 `X_raw`**——若先做 z-score，所有特征的方差都恒等于 1，排序将完全失去意义。这一区别在代码中通过传入不同矩阵显式处理。

四、实验内容 2：数据降维

4.1 方法与步骤

对**全部 1008 个特征**分别使用三种方法降维，取前 2 个成分做二维散点图，健康的对照用蓝色圆点、肝癌用红色三角表示。

1. **PCA**：线性、无监督、确定性。计算全部 122 个主成分的方差贡献率，绘制碎石图与累计贡献率曲线，取前 2 个主成分可视化。
2. **t-SNE**：非线性、无监督、随机（固定随机种子）。扫描 perplexity = 5/15/30。
3. **自编码器**：欠完备自编码器，结构为

$$1008 \to 256 \to 64 \to \text{latent}(k) \to 64 \to 256 \to 1008$$

隐层激活 GELU，损失为重构 MSE，优化器 Adam，训练 500 轮，取**编码器输出**作为低维表示。分别取 $k = 2$ 与 $k = 8$ 对比。

4.2 结果

（1）PCA 方差贡献率

指标	数值
PC1 方差贡献率	21.41%
PC2 方差贡献率	6.67%
PC1+PC2 累计	**28.08%**
累计贡献率达 80% 所需主成分数	26
累计贡献率达 90% 所需主成分数	51
前 2 维轮廓系数	**−0.026**

前两个主成分合计只解释了 28.08% 的方差，要解释 80% 需要 26 个主成分。这说明数据的信息分散在很多个方向上，**不存在少数几个占绝对主导的变异方向**。

（2）t-SNE（不同 perplexity）

perplexity	轮廓系数
5	0.138
15	0.080
30	0.113

（3）自编码器

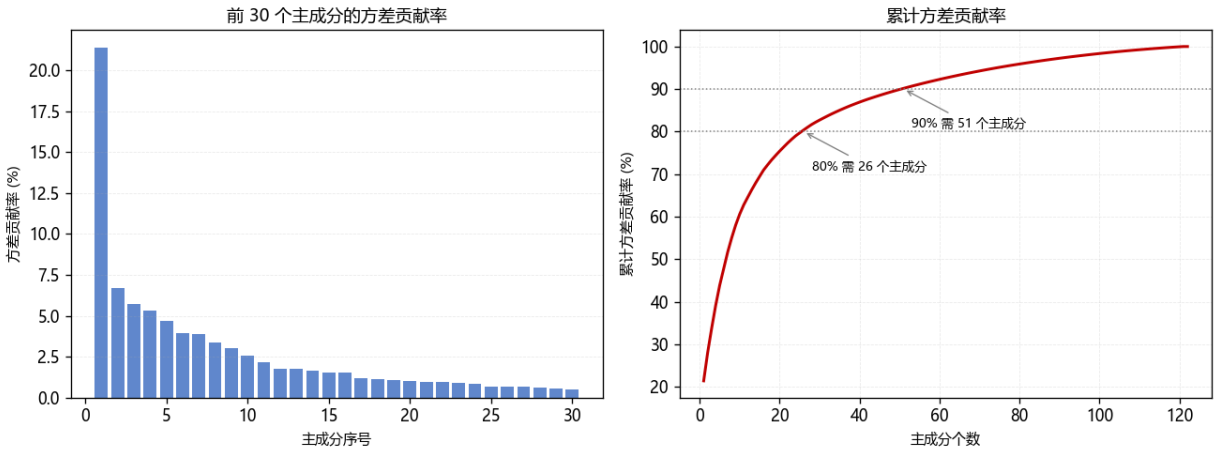


图 1　PCA 碎石图与累计方差贡献率曲线。前 2 个主成分仅解释 28.08% 的方差，累计达 80% 需 26 个主成分。

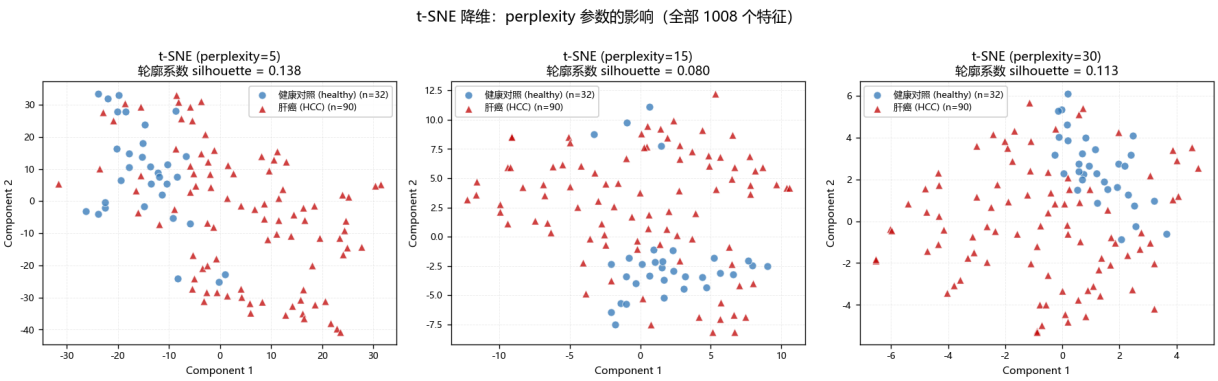


图 2　t-SNE 在不同 perplexity 下的降维结果。健康对照（蓝圆点）有聚成小团的倾向，但两类重叠依然明显。

隐层维度 k	重构 MSE（训练集）	轮廓系数
2	0.1174	−0.097
8	0.0014	—

（4）三种方法对比汇总

降维方法	轮廓系数（前 2 维）	kNN 5 折 CV 准确率	说明
PCA (PC1−PC2)	−0.026	0.8985	前 2 维解释方差 28.1%
t-SNE (perp=5)	0.138	0.8149	非线性，保留局部结构
t-SNE (perp=15)	0.080	0.8431	非线性，保留局部结构
t-SNE (perp=30)	0.113	0.8645	非线性，保留局部结构
自编码器 (隐层 2)	−0.097	0.8415	重构 MSE 0.1174
自编码器 (隐层 8)	—	0.8857	重构 MSE 0.0014
全部 1008 特征（基线）	−0.026	0.8103	—

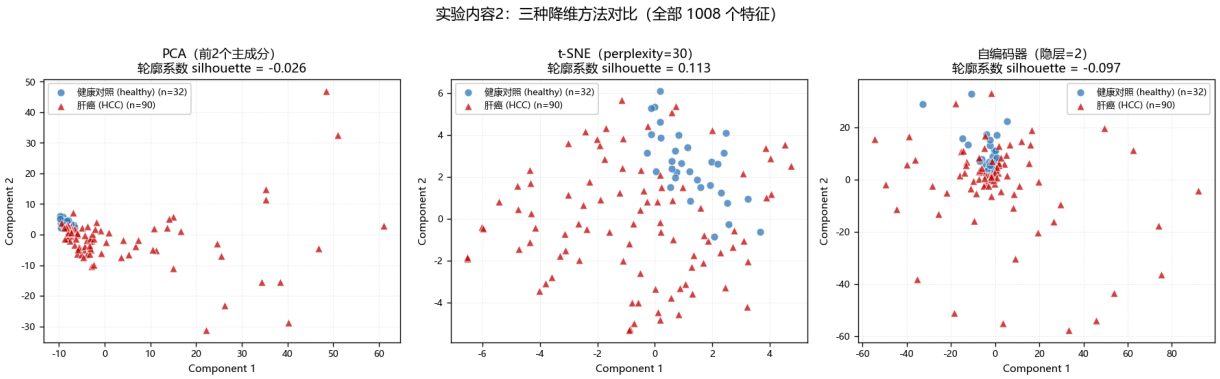


图 3　三种降维方法在全部 1008 个特征上的对比。三者都无法清晰分开肝癌与健康对照——PCA 与自编码器的轮廓系数均为负值，说明两类在二维空间中严重重叠。

自编码器的训练损失曲线如图 4，呈稳定下降后收敛，训练过程本身是正常的：

（5）关于自编码器重构误差的重要修正

上表中自编码器隐层 8 维的训练重构 MSE 低至 0.0014，单看这个数字，它似乎比线性 PCA 强得多（PCA 要 26 个主成分才能解释 80% 的方差）。**但这个结论是错的**：该数字是在**训练集自身**上计算的，而本网络约有 50 万个参数，样本却只有 122 个，网络完全有能力把训练样本”背下来”。

为得到可靠结论，我们做了 5 折交叉验证：每折在训练集上拟合、在**未参与训练的测试集**上计算重构 MSE，结果如下（特征已标准化，故 MSE 可直接读作”未解释方差比例”）：

隐层/主成分维度 k	PCA 留出集 MSE	自编码器留出集 MSE	自编码器训练集 MSE
2	**0.8372**	1.0134	0.2507
8	**0.6965**	0.8043	0.0283

结论完全反转过来了：**在留出集上，自编码器的重构误差反而高于线性 PCA**（k=8 时 0.8043 vs 0.6965）。隐层 8 维的训练 MSE 0.0014 与留出 MSE 0.8043 相差约 570 倍，是典型的过拟合表现。

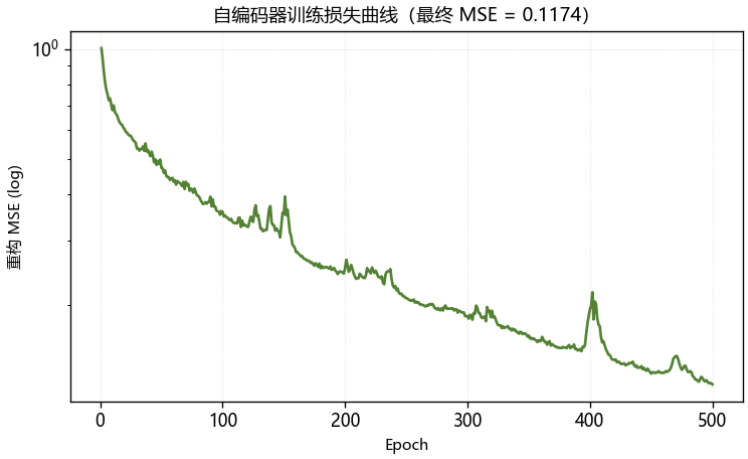


图 4　自编码器（隐层 2 维）的训练损失曲线，最终重构 MSE 为 0.1174。

因此在本数据规模下（122 样本），**自编码器并没有带来优于 PCA 的降维能力**，其看似极低的重构误差只是记住了训练样本。

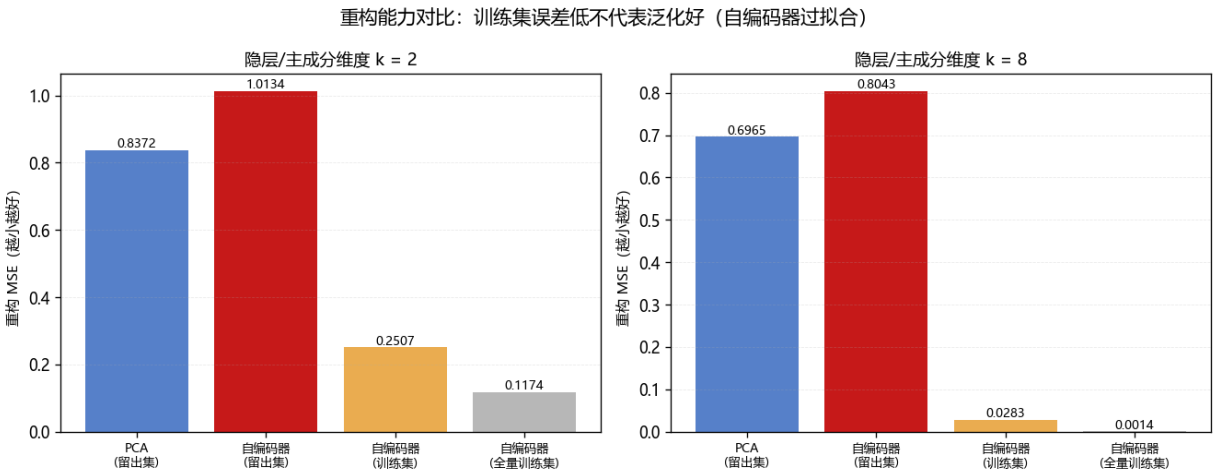


图 5　重构能力对比：训练集误差低不代表泛化好。自编码器在训练集上的重构误差（黄、灰柱）远低于 PCA，但在留出集上（红柱）反而高于 PCA（蓝柱），是典型的过拟合表现。

4.3 小结

- **三种方法在二维平面上都无法把肝癌与对照清晰分开。** PCA 的轮廓系数为 −0.026（负值意味着两类在二维空间中严重重叠，甚至比随机分布更交错），自编码器（隐层 2）为 −0.097，同样为负。t-SNE 的轮廓系数略高（0.080~0.138），在图中能看到健康对照有聚成小团的倾向，但重叠依然明显。
- **“二维图上分不开”不等于“数据里没有类别信息”。**一个关键佐证是：同样这批全特征数据，直接用 kNN 在**完整的 1008 维空间**中做 5 折交叉验证，准确率就已达 0.8103，远高于随机猜测（若全预测为多数类 HCC，准确率约为 90/122 = 73.8%）。这说明区分类别的信息是存在的，只是分散在许多个维度上，被前两个主成分（仅 28.08% 方差）严重稀释了。
- t-SNE 的结果对 perplexity 敏感且非单调（5→0.138，15→0.080，30→0.113）。需要注意 t-SNE 主要保留**局部邻域**结构，簇与簇之间的距离不具可比性，且算法本身是随机的，因此其轮廓系数只能作为粗略参考，不宜过度解读。

五、实验内容 3：非监督学习特征筛选

5.1 方法与步骤

不使用任何样本标签信息，按以下两种准则对特征排序，各取排名前 N 个特征（N = 50/100/200/500），再用 PCA 降到 2 维做可视化并与实验内容 2 对比。

1. **方差法**：对每个特征计算其在所有样本中的方差（对应 Matlab 的 `VAR`），按方差**降序**排列。必须使用未标准化的 `X_raw`。
2. **熵法**：对每个特征将其取值范围等分为 20 个区间，统计各区间样本数得到概率分布 p，计算 Shannon 熵

$$H = -\sum_{i} p_i \log_2 p_i$$

除以 $\log_2 20$ 归一化到 $[0, 1]$，按熵**降序**排列（熵越大表示取值分布越均匀、信息量越大）。等宽分箱对特征的线性缩放是等变的，因此熵法结果在标准化前后完全一致。

5.2 结果

（1）两种方法选出的特征几乎不重叠

N	方差法 ∩ 熵法	Jaccard
50	0	0.000
100	2	0.010
200	21	0.055
500	225	0.290

在 top-50 和 top-100 上，两种无监督准则选出的特征**几乎完全不重合**，说明”方差大”和”分布均匀”是两种互不相关的特征属性。

（2）筛选前后的量化对比

方法	N	轮廓系数	kNN 5 折 CV 准确率
全部特征（基线）	1008	−0.026	0.8103
方差法	50	−0.135	0.8267
方差法	100	−0.128	0.8053
方差法	200	−0.117	0.8137
方差法	500	−0.106	0.7858
熵法	50	0.040	0.8003
熵法	100	**0.088**	0.8003
熵法	200	0.039	0.8121
熵法	500	0.083	0.8007

（3）可视化对比

方差法 top100 的散点图与全部特征的基线图**几乎一模一样**——肝癌样本依然大幅分散，健康对照依然挤在原点附近。熵法 top100 的图形略有改善，健康对照开始聚成相对紧凑的一团。

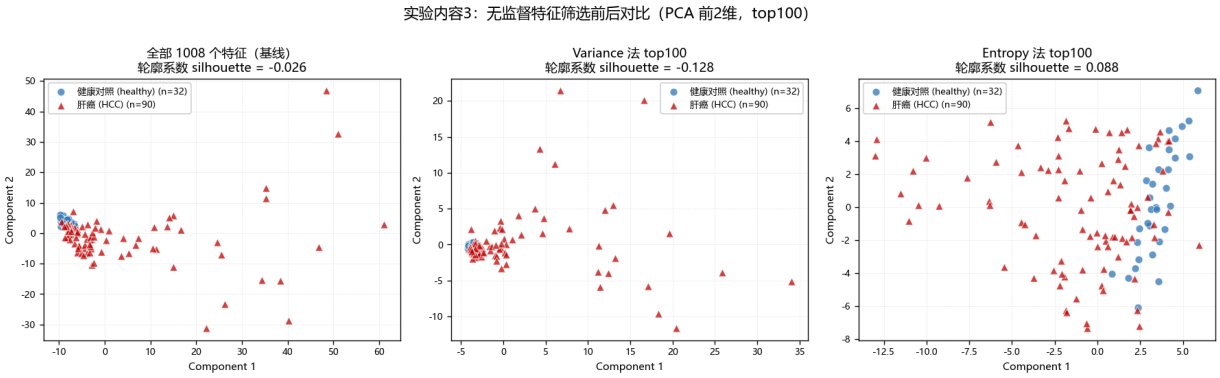


图 6　无监督特征筛选前后对比（PCA 前 2 维，top100）。方差法 top100 的散点图与全部特征的基线图几乎一模一样；熵法略有改善，健康对照开始聚成相对紧凑的一团。

5.3 与实验内容 2 的对比及原因分析（对应指导书 3-E）

对比结论：熵法较基线略有改善，方差法反而使结果变差。

具体地，方差法所有 N 下的轮廓系数（−0.106 ~ −0.135）都比基线（−0.026）**更差**；熵法在 N=100 时达到 0.088，是把负值拉正了，但提升幅度有限。

原因分析：

第一，方差法衡量的”变异大”与”能区分类别”是两件事。方差法完全不看标签，它挑出的是”在所有样本中波动最大”的特征。而生物数据中最大的变异来源未必是疾病状态，也可能是个体差异、测序深度、批次效应等。方差最大的特征可能只是”噪声大”，而不是”区分力强”。

第二，更关键的是方差法与 PCA 的目标高度重合。 PCA 本身就是**按方差排序**的——第一主成分就是方差最大的方向。因此”先用方差筛掉低方差特征、再做 PCA”，与”直接对全部特征做 PCA”看到的是几乎同一批变异方向：前者并没有改变 PC1/PC2 的朝向，只是砍掉了对它们贡献较小的特征。这正好解释了为什么方差法的散点图与基线几乎完全一致，且轮廓系数同样为负。

这个”重合”还带来一个额外损失：被方差法丢弃的那些特征，单个来看方差很小，但**联合起来可能携带类别信息**。丢掉它们等于既没有换到新的视角，又损失了信息，所以方差法的表现不但没有提升，反而比基线更差。

第三，熵法为什么略好一些？熵衡量的是取值分布的均匀程度，与特征的量纲和绝对波动幅度无关，捕捉的是一个与”方差”正交的属性（两者 top-100 交集仅 2 个特征，见 5.2 节）。正因为视角不同，熵挑出的特征子集里恰好包含了一部分与类别相关的特征，使二维可视化略有改善。

但必须指出一个反差：熵法让”图更好看”，却没有让”分类更准”。熵法的 kNN 准确率（0.8003~0.8121）与基线（0.8103）基本持平，甚至略低。这说明熵法带来的二维散点图改善很可能是偶然的——它在 2 维可视化上恰好把健康对照聚得紧了一些，但这种改善并未转化为真实判别能力的提升。**这提示我们：不能只看散点图”好不好看”就下结论，必须结合量化指标。**（这正是本报告在指导书要求之外补充 kNN 交叉验证指标的原因。）

总体结论：不使用标签的无监督筛选（方差、熵）对本数据的类别区分能力**几乎没有帮助**，甚至可能有害。原因在于它们优化的目标（方差最大、分布最均匀）与真正想要的目标（区分肝癌与对照）无关。

六、实验内容 4：监督学习特征筛选

6.1 方法与步骤

使用样本标签信息，实现了指导书列出的全部 5 种方法（要求为 2~3 种），各取排名前 N 个特征（N = 50/100/200/500）再做 PCA 降维可视化：

（1）t 检验：逐特征做两独立样本 t 检验（Welch 法，不假设方差齐性），按 $|t|$ 降序。对 1008 个特征同时检验会产生大量假阳性，故额外做 Benjamini-Hochberg FDR 校正。

（2）Mann-Whitney U 检验：非参数检验，不要求正态分布。注意直接按 p 值排序会遇到大量并列（p 极小时的数值精度问题），故改用效应量 $|\text{AUC} - 0.5|$（其中 $\text{AUC} = U/(n_1 n_0)$）作为得分——它与 p 值单调等价，但取值连续、无并列。

（3）互信息：用 kNN 估计器计算每个特征与标签的互信息，能捕捉非线性依赖。

（4）mRMR（最大相关最小冗余），严格按指导书步骤：

- A. 按各特征在所有样本中的**中值**做二值离散化；
- B. 在离散空间上做贪心前向选择，每一步在剩余特征中选取使下列准则最大者：

$$\text{MID (互信息差)：} \quad \max_f \left[I(f;c) - \frac{1}{|S|} \sum_{s \in S} I(f;s) \right]$$

$$\text{MIQ (互信息商)：} \quad \max_f \left[\frac{I(f;c)}{\frac{1}{|S|} \sum_{s \in S} I(f;s)} \right]$$

  其中 $I(f;c)$ 是特征与类的”相关项”，$I(f;s)$ 是特征间的”冗余项”。

- C. 取排名前 N 个特征降维并可视化。

  注：scikit-learn 没有内置 mRMR，本实验自行实现。为提高 1008×1008 特征两两互信息矩阵的计算效率，对二值特征用 2×2 列联表做了向量化计算，并已与 `sklearn.metrics.mutual_info_score` 逐项比对，误差在 10^{-16} 量级。

（5）Lasso 回归：L1 正则逻辑回归，把不重要特征的系数压到精确的 0。

这里有一个实现上的陷阱需要说明。若按单一 C 值下的 |系数| 排序，在本数据上取 C=0.05 时 1008 个特征只有 3 个非零，**其余 1005 个得分完全相同（都是 0）**，排序结果将完全由”并列如何打破”决定，并不反映 Lasso 本身的选择倾向。为此本实验改用**正则化路径**排序（stability selection 的常用做法）：

$$\text{score}_j = \text{特征} j \text{ 首次变为非零时的那个} C$$

（注意 sklearn 中 C 是正则强度的倒数：C 越小惩罚越强、非零系数越少。故 C 从小往大扫，特征会依次”进入”模型；越重要的特征越能扛住强惩罚，首次进入的 C 越小、得分越高。）这样 1008 个特征都能得到有区分度的得分，且不需要引入任何外部信息来打破并列。

6.2 结果

（1）各方法的筛选规模

方法	结果
t 检验	p<0.05 的特征 **594** 个；BH-FDR 校正后 q<0.05 的 **554** 个
Mann-Whitney U	p<0.05 的特征 **529** 个
Lasso	C=0.1 时严格入选 **16** 个特征
Lasso 正则路径	C=0.005:0 个，0.01:0 个，0.05:3 个，0.1:16 个，0.5:37 个，1.0:47 个

值得注意的是：即使经过 FDR 校正，仍有 554 个特征（超过总数一半）与类别显著相关。这说明**单变量检**

验的”显著”门槛在本数据上过于宽松——1008 个特征里有 554 个显著，等于没怎么筛掉东西，这也解释了为什么 t 检验需要配合“取 top-N”而不是”取所有显著特征”来使用。

（2）不同 N 下的量化指标

方法	N	轮廓系数	kNN 5 折 CV 准确率
全部特征（基线）	1008	−0.026	0.8103
t 检验	50	0.207	0.9089
t 检验	100	0.194	0.9072
t 检验	200	0.161	0.8843
t 检验	500	0.101	0.8757
Mann-Whitney U	50	0.201	0.8922
Mann-Whitney U	100	0.212	0.8939
Mann-Whitney U	200	0.196	0.8923
Mann-Whitney U	500	0.124	0.8661
互信息	50	0.181	0.8659
互信息	100	0.156	0.8873
互信息	200	0.124	0.8806
互信息	500	0.086	0.8463
mRMR-MID	50	0.213	**0.9251**
mRMR-MID	100	**0.230**	0.9087
mRMR-MID	200	0.204	0.8923
mRMR-MID	500	0.129	0.8675
Lasso（L1 路径）	50	**0.307**	**0.9411**
Lasso（L1 路径）	100	**0.241**	**0.9397**
Lasso（L1 路径）	200	0.122	0.9170
Lasso（L1 路径）	500	0.053	0.8611

（3）各方法 top-10 特征

方法	top-10 特征编号
方差法	471, 0, 284, 278, 24, 25, 283, 304, 529, 329
熵法	679, 46, 44, 91, 47, 1002, 926, 881, 54, 361
t 检验	910, 803, 806, 926, 927, 406, 522, 821, 510, 554
Mann-Whitney U	910, 545, 522, 803, 510, 774, 667, 926, 806, 787
互信息	668, 910, 803, 806, 927, 522, 510, 546, 702, 696
mRMR-MID	803, 283, 927, 662, 561, 772, 910, 406, 926, 36
Lasso	926, 910, 64, 821, 92, 501, 554, 416, 161, 510

（4）方法间 top-100 特征集合的重叠度（Jaccard）

	MW	MI	mRMR	Lasso
t 检验	**0.681**	0.333	0.429	0.143
Mann-Whitney U	—	0.439	0.515	0.130
互信息	—	—	0.408	**0.093**
mRMR-MID	—	—	—	0.149

（5）五种方法的共识特征

五种监督方法 top-100 的**交集恰好有 12 个特征**：F142, F406, F487, F510, F554, F561, F629, F662, F821, F910, F923, F926。

（6）可视化对比

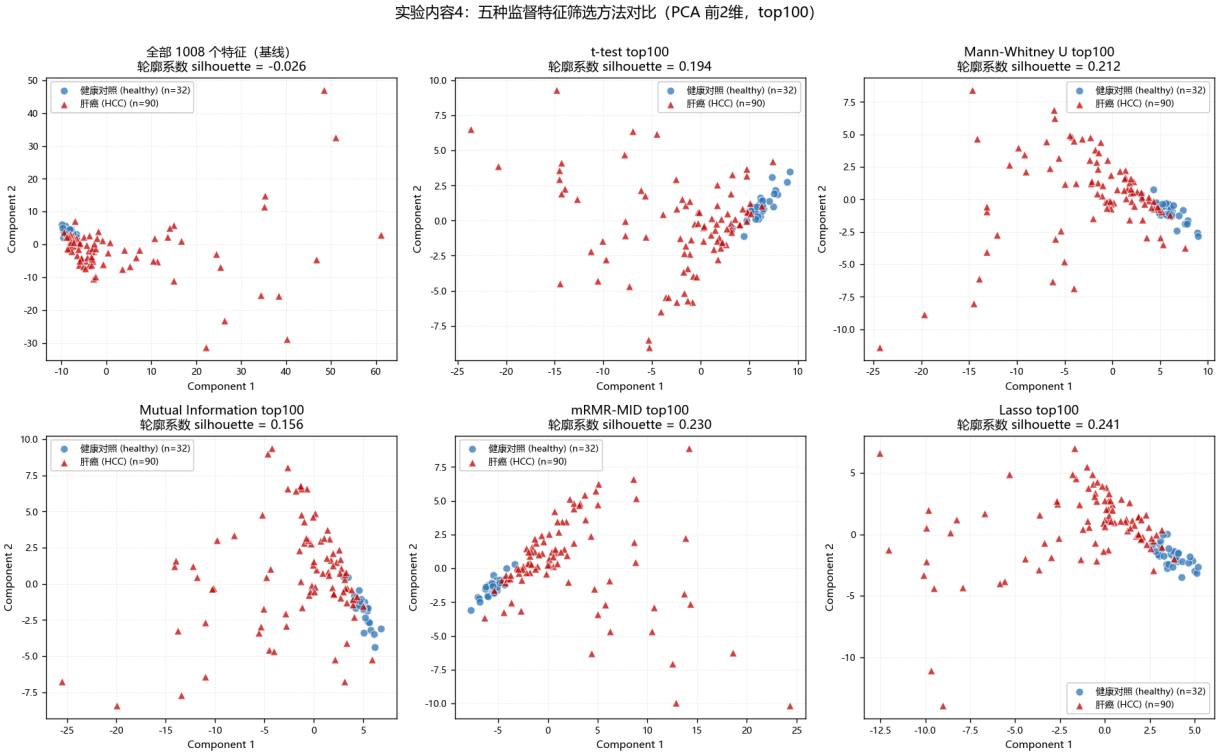


图 7　五种监督特征筛选方法对比（PCA 前 2 维，top100）。与左上角完全混杂的基线（轮廓系数 −0.026）相比，五种方法下健康对照都聚成一团并与肝癌样本拉开明显距离，其中 mRMR-MID 与 Lasso 最清晰。

与基线（轮廓系数 −0.026，完全混杂）相比，五种监督方法 top-100 的散点图上**健康对照都聚成了一团、并与肝癌样本拉开明显距离**，其中 mRMR-MID 和 Lasso 的效果最为清晰。

6.3 与实验内容 2、3 的对比及原因分析（对应指导书 4-E）

对比结论：监督筛选显著优于无监督筛选，也显著优于不做筛选的基线。

类别	代表方法	轮廓系数	kNN CV 准确率
基线（不筛选）	全部 1008 特征	−0.026	0.8103
无监督筛选（最佳）	熵法 top100	0.088	0.8003

类别	代表方法	轮廓系数	kNN CV 准确率
无监督筛选	方差法 top100	−0.128	0.8053
监督筛选	t 检验 top100	0.194	0.9072
监督筛选	mRMR-MID top100	0.230	0.9087
监督筛选	Lasso top100	0.241	0.9397

原因分析：

第一，监督方法”瞄准了正确的方向”。无监督准则（方差、熵）的优化目标与”区分肝癌和对照”无关，所以它们在 1008 个特征里挑出的”方差最大”或”分布最均匀”的特征，很可能与类别无关。监督方法则直接把”特征与标签的关联强度”作为打分依据，相当于把筛选方向对准了类别轴，因此能选出**方差不大、但两类差异显著**的特征——这类特征恰恰是无监督方法系统性忽略的。

第二，三类监督准则的差异体现了”单变量 vs 多变量”的层次。

- **单变量过滤式（t 检验、Mann-Whitney U、互信息）**：逐个特征独立打分，优点是简单、可解释（有 p 值、AUC 等统计量），缺点是完全忽略特征之间的冗余，容易选出高度相关的一批特征。证据很直观：t 检验与 Mann-Whitney U 的 top-100 Jaccard 高达 **0.681**，两者本质上在测量同一个东西（两类分布的位置差异），只是一个用参数法、一个用秩；t 检验 p 值最小的特征（$p = 8.65\times10^{-18}$）对应的 Mann-Whitney U 的 AUC 低至 0.094，说明这些特征在两类间几乎完全分离。
- **mRMR**：在”相关”之外**显式惩罚冗余**，倾向于选出彼此互补的特征。它 top-100 与 t 检验的 Jaccard 只有 0.429（明显低于 t 检验与 MW 之间的 0.681），说明它确实选出了一套更分散的特征。而且 mRMR 在**所有 N 下**准确率都稳定偏高（top50 达 0.9251），体现出”既相关又不冗余”这一策略的价值。
- **Lasso**：做的是**多变量联合**选择——所有特征同时进入模型，由 L1 惩罚在联合拟合的前提下决定谁留下，因此能捕捉单变量检验看不到的联合效应。它的表现最好（top50 准确率 0.9411、轮廓系数 0.307），且与互信息的 top-100 重叠率低至 0.093、与 t 检验只有 0.143，说明它选的确实是一套很不一样的特征。

第三，N 的选择规律：几乎所有方法都是”N 越小指标越好”。 t 检验准确率随 N 从 50 增到 500 由 0.9089 降到 0.8757，Lasso 由 0.9411 降到 0.8611，所有监督方法在 N=500 时都明显回落。这符合直觉：排序靠前的特征信息密度最高，继续往后加只会引入噪声和冗余。**本数据下最优的 N 在 50~100 量级。**（这也解释了为什么”取所有 554 个 FDR 显著特征”是错的做法。）

第四，共识特征最有价值。五种原理完全不同的准则，top-100 的交集只有 12 个特征。这 12 个特征是”无论用哪种方法都被认为与类别最相关”的高置信特征，是后续实验（分类器构建与验证）最值得优先考虑的候选特征。

6.4 一个必须说明的局限

本节的 kNN 交叉验证准确率存在**选择偏倚（selection bias）**：特征筛选是在使用**全部样本**的标签完成的，之后才做交叉验证。这意味着测试集的信息通过“特征选择”这一步间接泄漏到了模型中，因此表中的准确率是**乐观估计**，绝对值会偏高。

要得到无偏估计，必须把特征筛选过程放进交叉验证的每一折内部（即在每折的训练集上重新做特征筛选）。本实验遵循指导书的做法，在交叉验证之外完成筛选，因此**这些数字只适合用于在相同协议下横向比较各方法的相对优劣，不宜当作分类器性能的无偏报告**。

同时，样本量只有 122 例，1 个样本约合 0.82% 的准确率。因此像 Lasso （0.9411）与 t 检验（0.9089）之间 3.2% 的差距只相当于约 4 个样本，不宜过度解读具体名次。可靠的结论是**定性的**：监督筛选大幅优于无监督筛选，而不是”Lasso 一定比 t 检验好”。

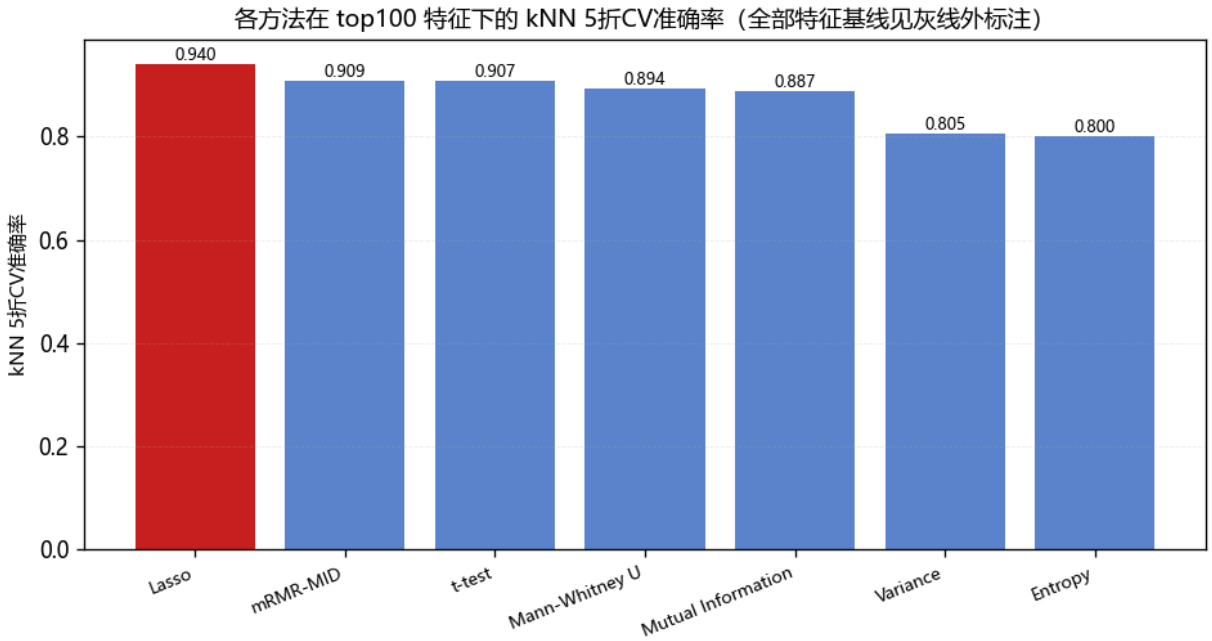


图 8　各方法在 top100 特征下的 kNN 5 折交叉验证准确率对比（红色为最高）。监督方法（右五列）明显高于无监督方法（左两列）与基线。

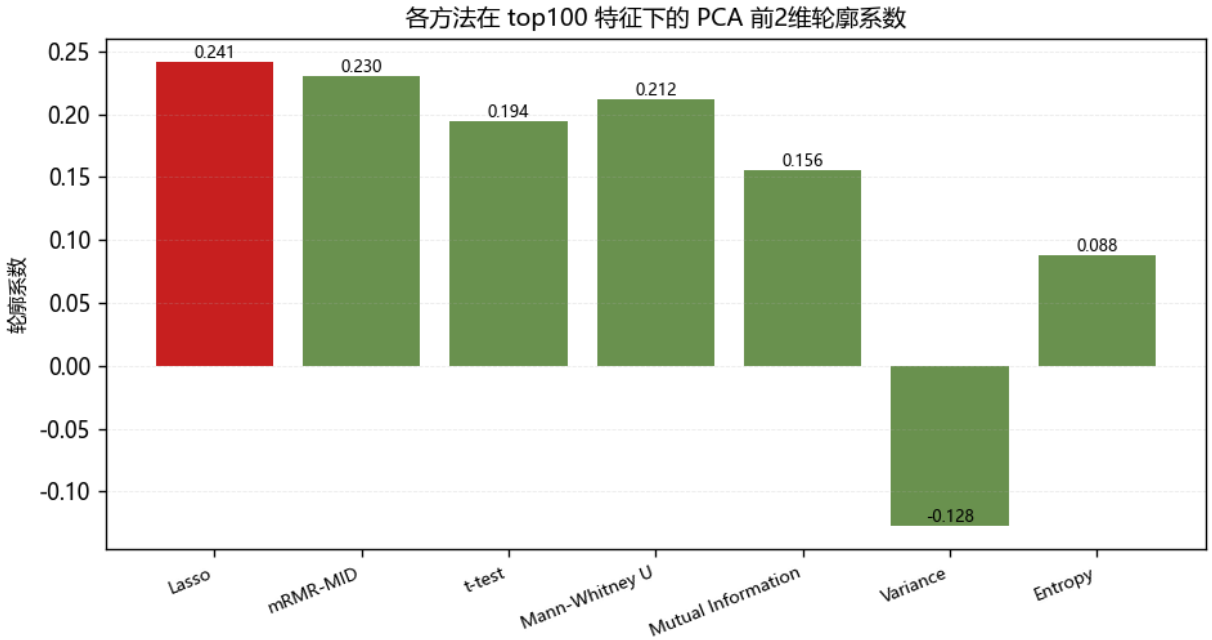


图 9　各方法在 top100 特征下的 PCA 前 2 维轮廓系数对比。方差法为负值，说明它甚至使类别可分性变差。

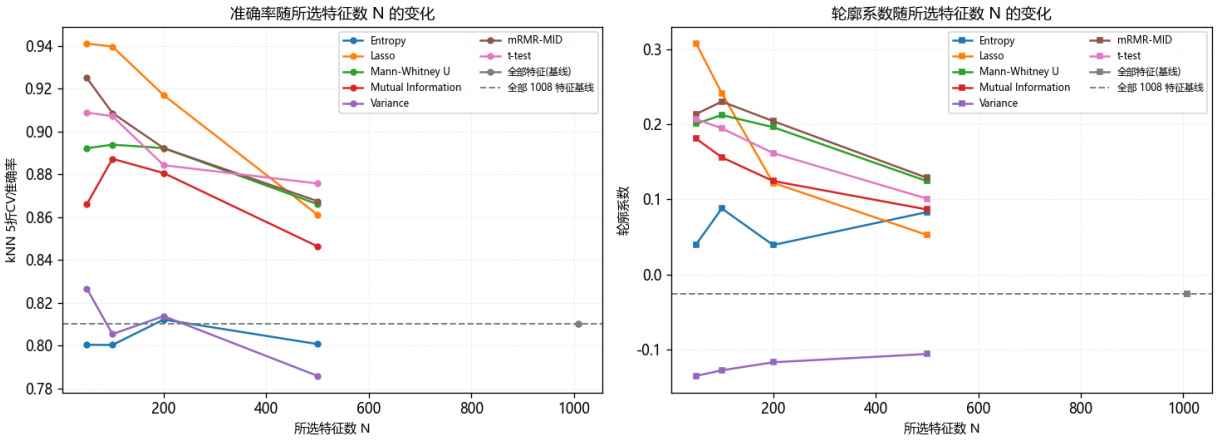


图 10　两项指标随所选特征数 N 的变化。几乎所有方法都是 N 越小指标越好，说明排序靠前的特征信息密度最高；灰色虚线为不筛选的基线。

七、实验结论

1. **降维方面**：PCA、t-SNE、自编码器三种方法在二维平面上都无法清晰分开肝癌与健康对照。前两个主成分只解释 28.08% 的方差，类别信息分散在大量维度上，二维可视化会严重稀释它。但直接用全部 1008 维做 kNN 交叉验证准确率已达 0.8103，证明类别信息确实存在——**“图上分不开”不等于”数据里没有信号”**。
2. **自编码器方面**：隐层 8 维的训练重构 MSE 低至 0.0014，看似远优于 PCA，但 5 折交叉验证的留出集 MSE（0.8043）反而**高于**线性 PCA（0.6965）。在 122 个样本上训练约 50 万参数的网络发生了严重过拟合。**只看训练集重构误差会得出完全错误的结论。**
3. **无监督特征筛选方面**：方差法与熵法对本数据帮助甚微，方差法甚至使结果变差（轮廓系数 −0.106 ~ −0.135，低于基线的 −0.026），根本原因是它们的优化目标与”区分类别”无关。方差法还与 PCA 的目标高度重合（PCA 本就按方差排序），因此筛选前后几乎无变化。**熵法让散点图好看了一些，但 kNN 准确率并未提升**，说明不能只凭可视化判断效果。
4. **监督特征筛选方面**：五种监督方法均大幅优于无监督方法与基线。其中基于正则化路径的 Lasso 表现最好（top50 轮廓系数 0.307、kNN 准确率 0.9411），mRMR 次之且在各 N 下最稳定。体现了使用标签信息以及”考虑特征间冗余/联合效应”的价值。
5. **方法学收获**：
   - 特征筛选应以**类别关联**为目标，而非方差、熵等与任务无关的统计量；
   - 评估降维/筛选效果不能只看散点图，必须结合量化指标，且两者可能不一致；
   - 高维小样本下要警惕过拟合，必须使用**留出集**而非训练集误差；
   - 每次筛选都要注意**选择偏倚**，本报告的准确率为相对比较用的乐观估计。

附录 A：实验代码

完整可运行代码位于 `Exp1/` 目录：

```
Exp1/
├── exp1_main.py              主程序：一键跑完全部实验
├── src/
│   ├── data_loader.py        数据加载与标签对齐（含断言校验）
│   ├── dim_reduction.py      PCA / t-SNE / 自编码器
│   ├── feat_selection.py     方差、熵、t 检验、MW、互信息、mRMR、Lasso
```

├── evaluate.py	轮廓系数、kNN 交叉验证、留出集重构误差
└── visualize.py	绘图（中文字体配置）
├── results/figures/	全部结果图（17 张）
├── results/tables/	全部指标表（4 个 CSV）
├── results/metrics.json	全部原始指标
└── report/	本报告

下面是几个关键实现片段（完整代码见上述文件）。

A.1 数据加载与标签校验（src/data_loader.py）

```
# ma 是 (特征, 样本)，转置成 (样本, 特征)
ma = np.asarray(mat["ma"], dtype=np.float64)
co = np.asarray(mat["co"]).ravel()
X_raw = ma.T.copy()                    # (122, 1008)

# 与 xlsx 交叉校验：co == 0 应对应 HCC，co == 1 应对应 healthy
df = _load_label_table()
id2group = dict(zip(df["sample_id"], df["group"]))
group_names = np.array([id2group[s] for s in sample_ids])

expect = np.where(co == 0, "HCC", "healthy")
mismatch = np.where(expect != group_names)[0]
assert len(mismatch) == 0, f"{len(mismatch)} 个样本的 co 与 xlsx 组名矛盾"

# 统一标签：y = 1 - co，使 1 = HCC
y = (1 - co).astype(np.int64)
X = StandardScaler().fit_transform(X_raw)   # 按特征 z-score
```

A.2 熵法特征筛选（src/feat_selection.py）

```
def shannon_entropy_per_feature(X, n_bins=20):
    """ 逐特征计算归一化 Shannon 熵（等宽分箱）。"""
    n_samples, n_features = X.shape
    out = np.zeros(n_features)
    max_entropy = np.log2(n_bins)
    for j in range(n_features):
        col = X[:, j]
        lo, hi = col.min(), col.max()
        if not np.isfinite(lo) or hi <= lo:
            out[j] = 0.0                    # 常数特征无信息
            continue
        counts, _ = np.histogram(col, bins=n_bins, range=(lo, hi))
        p = counts / counts.sum()
        p = p[p > 0]                        # 约定 0 * log0 = 0
        out[j] = -np.sum(p * np.log2(p)) / max_entropy
    return out
```

A.3 二值互信息的向量化计算（mRMR 的核心）

1008 个特征两两互信息共约 50 万对，逐个调用 `mutual_info_score` 太慢。由于 mRMR 的特征已按中值二值化，可用 2×2 列联表一次性向量化求解：

```
def _mi_from_binary_counts(n11, n10, n01, n00, n):
    """ 由 2x2 列联表的四个计数向量化计算互信息 I(X;Y)。"""
    n = float(n)
    p11, p10, p01, p00 = n11/n, n10/n, n01/n, n00/n
    p1_, p0_ = p11 + p10, p01 + p00      # X 的边缘分布
    p_1, p_0 = p11 + p01, p10 + p00      # Y 的边缘分布

    def term(pab, pa, pb):
        den = pa * pb
        with np.errstate(divide="ignore", invalid="ignore"):
            return np.where((pab > 0) & (den > 0), pab * np.log(pab/den), 0.0)

    return (term(p11, p1_, p_1) + term(p10, p1_, p_0)
            + term(p01, p0_, p_1) + term(p00, p0_, p_0))

# 两两互信息矩阵：n11 用矩阵乘法一次算出
n11_mat = Xb.astype(float).T @ Xb.astype(float)
redundancy = _mi_from_binary_counts(
    n11_mat, n1_col - n11_mat, n1_row - n11_mat,
    n - n1_col - n1_row + n11_mat, n)
```

该实现已与 `sklearn.metrics.mutual_info_score` 逐项比对，最大误差 6×10^{-16}。

A.4 自编码器（`src/dim_reduction.py`）

```python
class _AutoEncoderNet(nn.Module):
    """ 对称欠完备自编码器: 1008 -> 256 -> 64 -> latent -> 64 -> 256 -> 1008"""
    def __init__(self, n_features, latent_dim, hidden=(256, 64)):
        super().__init__()
        dims = [n_features, *hidden]
        enc, prev = [], dims[0]
        for h in dims[1:]:
            enc += [nn.Linear(prev, h), nn.GELU()]
            prev = h
        enc.append(nn.Linear(prev, latent_dim))
        self.encoder = nn.Sequential(*enc)

        dec, prev = [], latent_dim
        for h in reversed(dims[1:]):
            dec += [nn.Linear(prev, h), nn.GELU()]
            prev = h
        dec.append(nn.Linear(prev, n_features))
        self.decoder = nn.Sequential(*dec)

    def forward(self, x):
        z = self.encoder(x)
        return self.decoder(z), z
```

A.5 留出集重构误差评估（揭示过拟合）

```python
def holdout_reconstruction(X, latent_dims=(2, 8), n_splits=5, n_epochs=500):
    """5 折交叉验证，比较 PCA 与自编码器的留出集重构误差。"""
    kf = KFold(n_splits=n_splits, shuffle=True, random_state=42)
    out = {}
    for k in latent_dims:
        pca_ho, ae_ho, ae_tr = [], [], []
        for tr, te in kf.split(X):
            # PCA：在训练集上拟合，在测试集上重构
            pca = PCA(n_components=k).fit(X[tr])
            pca_ho.append(((X[te] - pca.inverse_transform(pca.transform(X[te])))**2).mean())
            # 自编码器：在训练集上训练，在测试集上重构
            model, _ = fit_autoencoder(X[tr], latent_dim=k, n_epochs=n_epochs)
            ae_ho.append(ae_reconstruct_error(model, X[te]))
            ae_tr.append(ae_reconstruct_error(model, X[tr]))
        out[int(k)] = {"pca_holdout_mse": np.mean(pca_ho),
                       "ae_holdout_mse": np.mean(ae_ho),
                       "ae_train_mse": np.mean(ae_tr)}
    return out
```

A.6 Lasso 正则化路径排序

```python
# 指数搜索框出路径两端：c_min 处无特征进入，c_max 处几乎全部进入
c_min = 1.0
while n_nonzero(c_min) > 0:  c_min /= 2.0
c_max = 1.0
while n_nonzero(c_max) < 0.98 * n_features:  c_max *= 2.0

# 沿路径记录每个特征的" 首次进入点"
entry_C = np.full(n_features, np.inf)
entered = np.zeros(n_features, dtype=bool)
for c in np.geomspace(c_min, c_max, n_alphas):   # C 由小到大
    active = np.abs(_fit_l1_logistic(X, y, c)) > 0
    entry_C[active & ~entered] = c               # 首次进入，记下该 C
    entered |= active

# entry_C 越小越重要 -> 取负号作得分
scores = np.where(np.isfinite(entry_C), -entry_C, -np.inf)
```

附录 B：各方法 top20 特征得分图

B.1 无监督方法

B.2 监督方法

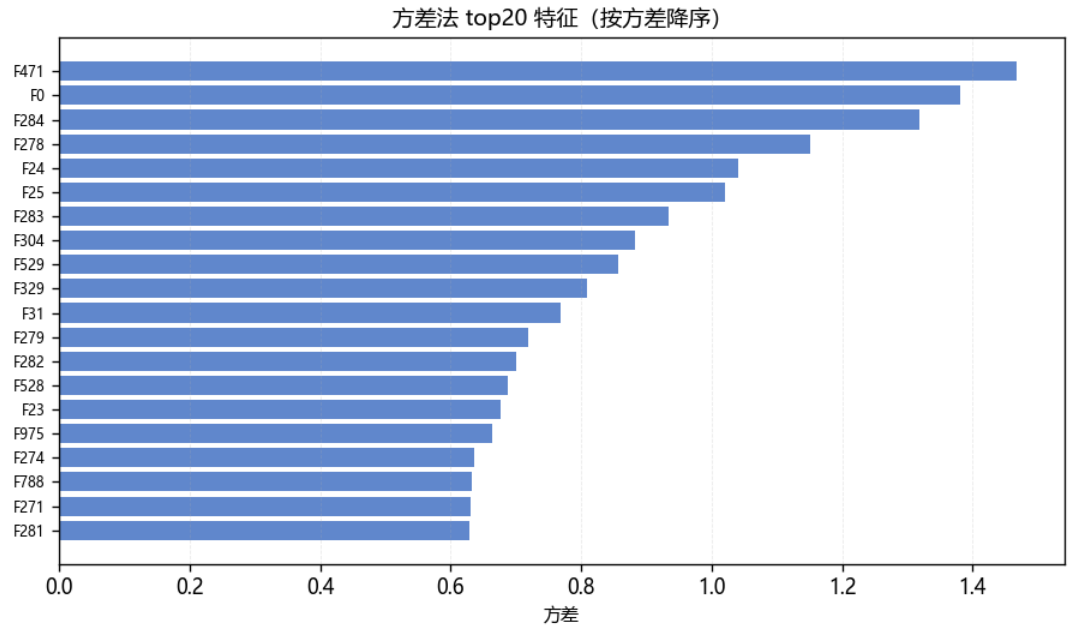


图 11　方差法 top20 特征（按方差降序）。方差最大的特征集中在少数几个编号上，与类别无关。

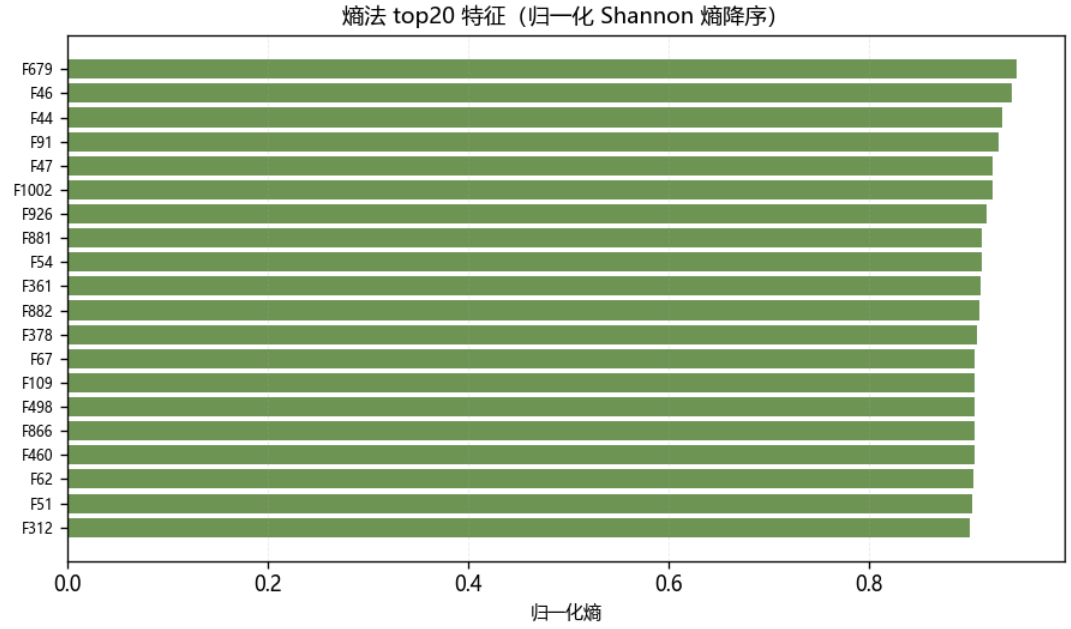


图 12　熵法 top20 特征（按归一化 Shannon 熵降序）。与方差法选出的特征几乎完全不重叠。

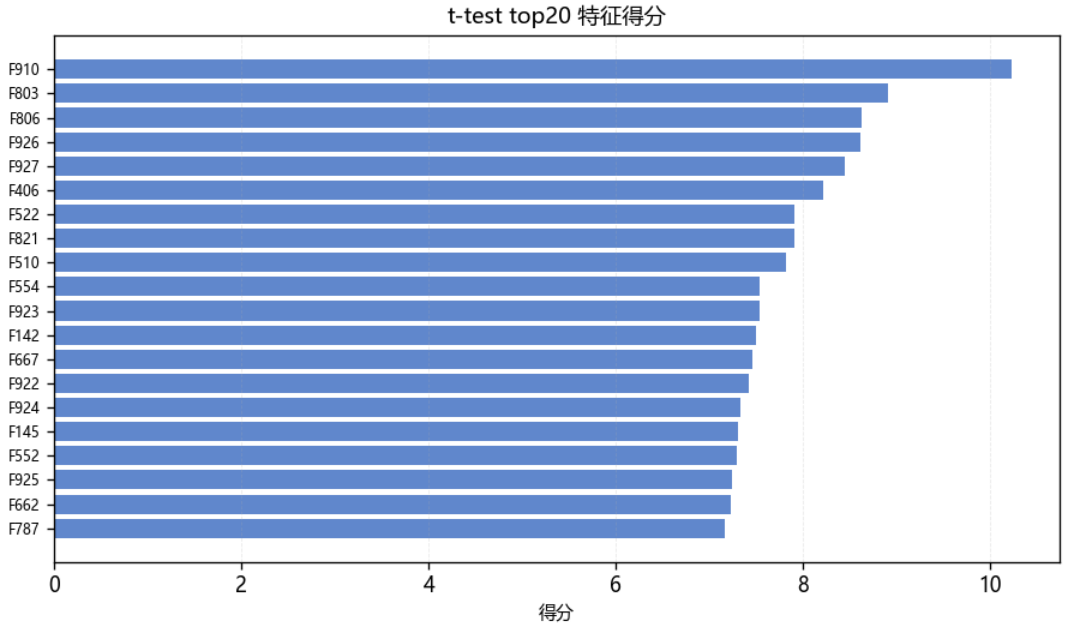


图 13　t 检验 top20 特征（按 |t| 降序）

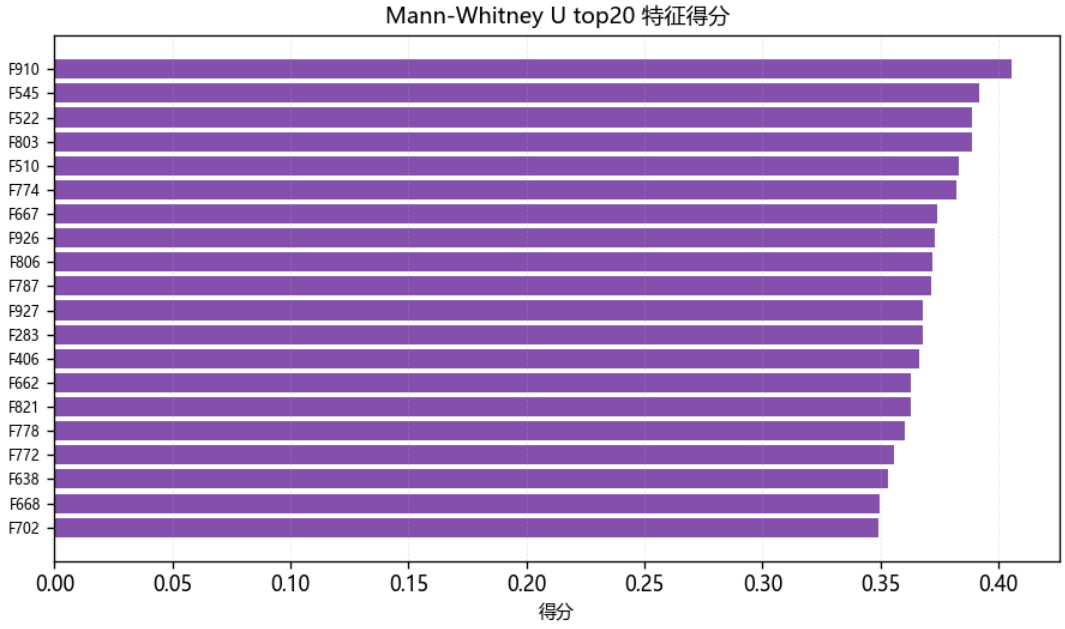


图 14　Mann-Whitney U top20 特征（按 |AUC−0.5| 降序）

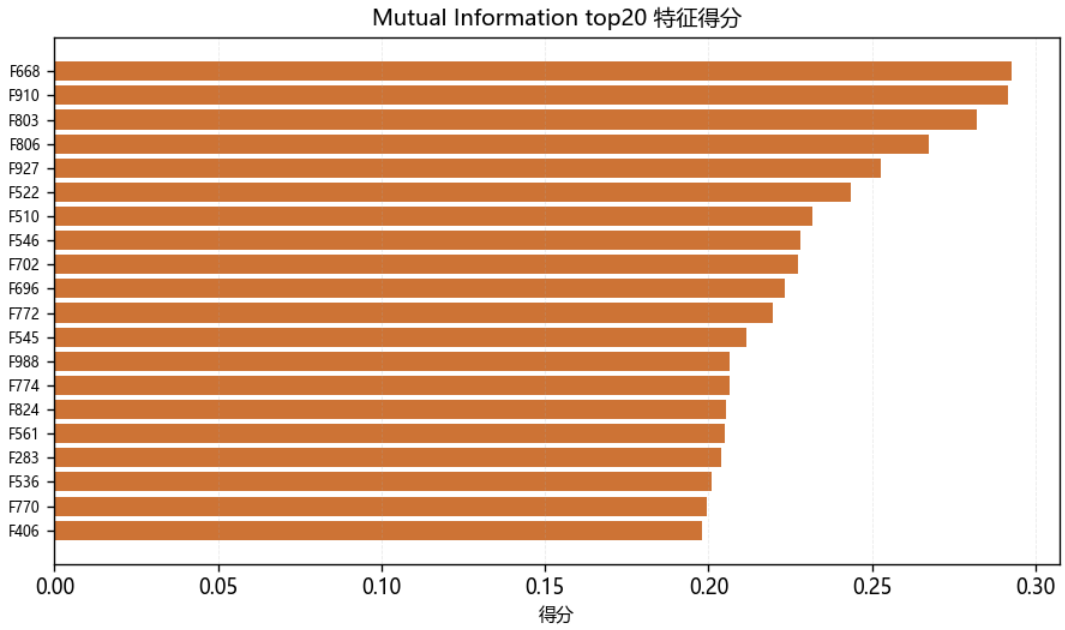


图 15　互信息 top20 特征（按互信息降序）

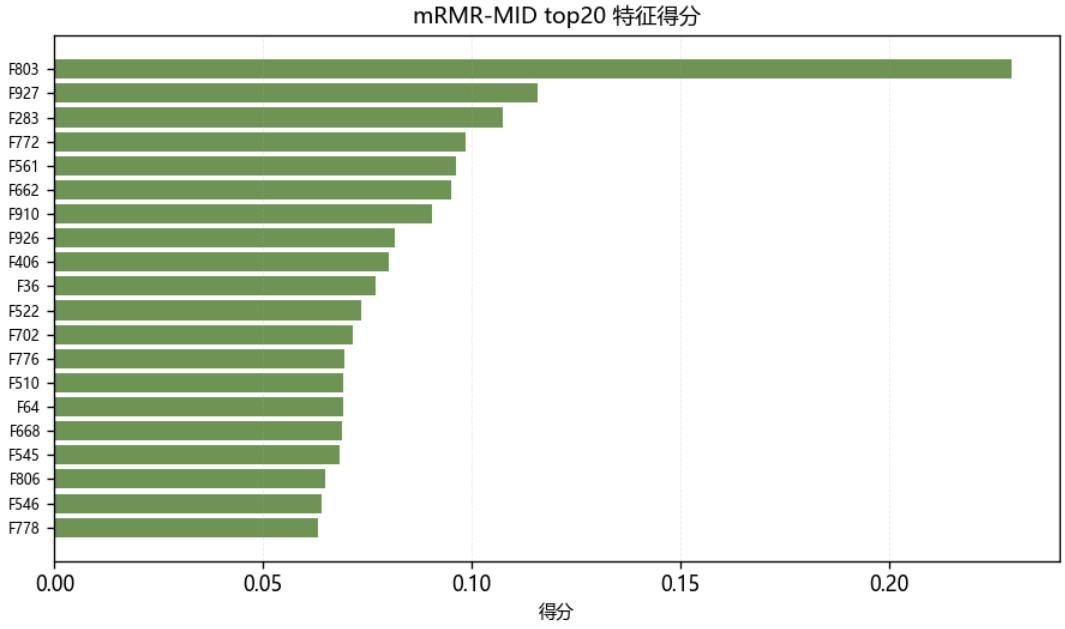


图 16　mRMR-MID top20 特征（按互信息差准则降序）

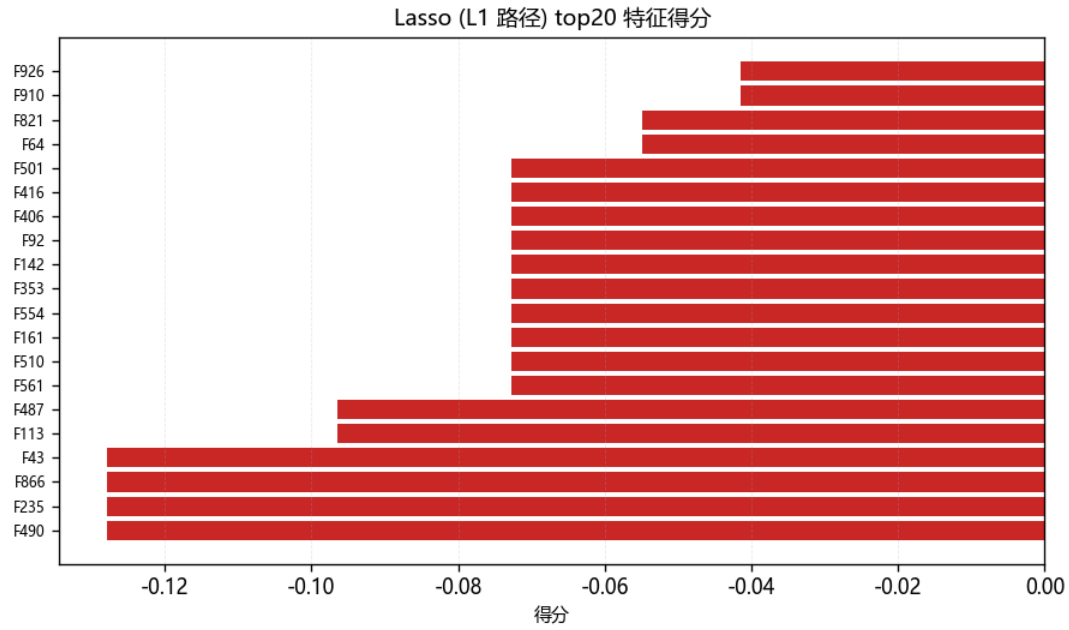


图 17　Lasso（L1 路径）top20 特征。得分 = 特征首次进入模型时的 C 值，得分越高说明越能扛住强惩罚。

附录 C：结果文件清单

结果图（`results/figures/`）

文件	内容
`fig02_pca_spectrum.png`	PCA 碎石图 + 累计方差贡献率曲线
`fig03_dr_comparison.png`	三种降维方法对比（PCA / t-SNE / 自编码器）
`fig04_tsne_perplexity.png`	t-SNE 在 perplexity=5/15/30 下的对比
`fig05_ae_loss.png`	自编码器训练损失曲线
`fig05b_holdout_reconstruction.png`	重构能力对比：训练集 vs 留出集（过拟合证据）
`fig06_unsup_fs_pca.png`	无监督筛选前后对比（基线 / 方差 / 熵）
`fig06b_variance_scores.png`	方差法 top20 特征得分
`fig06c_entropy_scores.png`	熵法 top20 特征得分
`fig07_sup_fs_pca.png`	五种监督筛选方法对比
`fig07b~fig07f_*_scores.png`	五种监督方法各自 top20 特征得分
`fig08_knn_acc_comparison.png`	各方法 top100 下 kNN 准确率对比
`fig09_silhouette_comparison.png`	各方法 top100 下轮廓系数对比
`fig10_metric_vs_N.png`	指标随所选特征数 N 的变化曲线

指标表（`results/tables/`）

文件	内容
tab01_dr_metrics.csv	降维方法指标对比
tab02_unsup_fs_metrics.csv	无监督特征筛选指标
tab03_sup_fs_metrics.csv	监督特征筛选指标
tab04_all_methods_metrics.csv	全部方法汇总

原始指标（results/metrics.json）

包含本报告引用的全部数值，便于核对与复现。