From Co-occurrence to Signal: Auditing and Correcting Research-Attention Bias in Cross-Kingdom Literature-Mined Gene–Trait Knowledge Bases

从共现到信号：跨物种文献挖掘基因–性状知识库中研究注意力偏差的审计与校正

陈佳伸

2023317220404

人工智能*2302* 邮箱: smiletrashbag@webmail.hzau.edu.cn

摘要—文献挖掘型知识库正被当作事实性资源广泛复用，但其关联强度的底层是共现计数，而共现同时混入了生物学效应与研究注意力两个来源。本文提出一项跨物种研究设想：以 RiceMind（水稻）与 CancerAlterome（人类癌症）这两个出自同一实验室、共享同一「共现抽取 + 本体归一化」范式的资源为对象，用库外文献基线为基因–性状对建立期望共现模型，并以残差作为注意力校正后的信号。设想的关键在于一个方法学处理：经查证，RiceMind 的 Tier 2/Tier 3 分层本身即由文章数阈值定义（>10 与 ≤ 10 篇），故基于该分层验证任何基于计数的校正都将构成循环；本文据此仅以与文献量无关的 Tier 1 作为标签，并对比较按文章数分层。预期贡献为：一套可移植的校正协议、对分层循环性的显式处理，以及首次对文献挖掘知识库注意力偏差的跨物种量化。

***Index Terms*—文献挖掘, 知识库偏差, 共现归一化, 发表偏倚, 本体归一化, 跨物种迁移**

I. 研究背景与问题 BACKGROUND

生物医学文献的规模已远超人工阅读能力，文献挖掘因此成为构建结构化知识的主要手段。 CancerAlterome 与 RiceMind 是该范式下两个成熟的资源：前者面向人类癌症，将**遗传改变→下游调控事件**归一化到 GO/HPO；后者面向水稻，将基因–性状关联归一化到 GO/TO/PO/RTO。两者出自同一实验室（HZAU-BioNLP Lab），共享同一套「共现抽取 + 本体归一化 + 来源分级」的方法论，区别仅在于物种与表型空间。

这类资源被下游直接当作「已知事实」使用——用于候选基因排序、通路富集、以及作为机器学习模型的弱标签。然而其关联强度的底层量是 **文献共现计数**。一个基因–性状对共现得多，可能因为该关联在生物学上强，也可能仅仅因为**这个基因和这个性状都被研究得多**。后者即**研究注意力**，它与生物学效应在计数中被不可分辨地混合。

这一偏差会带来一个具有实际后果的反馈回路：若知识库被不加校正地用于下游，其输出将系统性偏向已被充分研究的实体，从而**放大而非缩小**现有研究格局的不均衡—— 研究得多的基因被预测为更重要，进而获得更多研究。在作物育种与癌症靶点发现两个场景中，这意味着前者会忽视地方品种中未被充分研究的耐逆基因，后者会重复聚焦于已饱和的靶点。

现有资源普遍以置信度分层应对该问题，但这些分层并未与文献量解耦。经查证 RiceMind 的官方文档，其 Tier 2 与 Tier 3 的划分标准分别是「>10 篇独立文章」与「≤ 10 篇文章」[1]，**即某一层的定义本身就是文章数的函数**。这一事实尚未被既有文献指出，却直接影响下游对分层的使用方式。

本文要回答的三个问题：

- **RQ1（量化）** 研究注意力对关联强度的影响有多大？它与生物学信号在多大程度上可分离？

[1] http://lit-evi.hzau.edu.cn/ricemind-webpage/dataset/

课程论文支持使用 Agent 生成内容，
这只是开始。人工内容审查
和驾驭才是终点。

- **RQ2（校正）** 用外部文献基线对共现做归一化，能否得到比原始计数更接近生物学真值的排序？
- **RQ3（迁移）** 在一个物种上确定的校正，能否无损迁移到另一物种及其表型空间？

II. 主要研究设想 Main Research Idea

核心设想：把「超出研究注意力所能解释的部分」定义为关联信号。

设基因 g 与性状（或癌症过程）t 的库内共现计数为 $n(g,t)$，库内边缘频次为 n_g、n_t，总量为 N；另设 m_g、m_t 为 PubMed 中 g 与 t 各自的独立文献量，M 为检索空间总量。则**仅由注意力驱动**的期望共现为

$$E_{\text{ext}}[n(g,t)] = N \cdot \frac{m_g}{M} \cdot \frac{m_t}{M} \tag{1}$$

残差

$$r(g,t) = n(g,t) - E_{\text{ext}}[n(g,t)] \tag{2}$$

即为本文所定义的注意力校正后信号。

设想的要点不在于提出新的归一化公式，而在于主张**期望值的边缘频次应取自库外**：库内计数本身即是被污染的观测量，以它构造期望无法区分「该基因被研究得多」与「该关联真实且强」。

由此形成一个可直接实施的实验设计： 在同一测试集上比较三种排序—— 原始计数 n、仅用库内边缘频次的 PMI_{int}、以及用库外基线的 PMI_{ext}。其中 PMI_{int} 与 PMI_{ext} 的 **排名差异即构成文献注意力偏差的直接测量值**，该差值在既有文献中尚未被报告。

验证方案的立意：规避分层的循环性。 如第一节所述，RiceMind 的 Tier 2/Tier 3 由文章数阈值定义，故基于该二分层的验证是循环的，这是本设想在方法学上必须处理的核心障碍。应对方式有三：（i）**标签选择**上仅使用 **Tier 1** 作为正例—— 其定义依据是人工审编来源（Oryzabase/RAP-DB）或实验证据码（EXP/IDA/IMP），**与文献量无关**，故可作为干净标签，而 Tier 2/3 仅作分层变量；（ii）**按文章数区间分层**（如 1–5、6–10、11–50、>50），在各区间**内部**比较排序质量，以控制「Tier 1 基因本来就被研究得多」这一残余混淆；（iii）以**跨物种迁移**作为独立检验—— 在水稻侧确定的校正参数直接应用于癌症侧，该检验不依赖任何一方的分层体系，因而不受循环性影响。

待检验假设：

- **H1（校正有效性）** 分层条件下，PMI_{ext} 对 Tier 1 关联的 $P@k$ 显著高于原始计数且不低于 PMI_{int}；
- **H2（偏差可量化）** 两种 PMI 的排名差异与实体级文献量显著相关，且该相关在两库中具有可比的函数形式；
- **H3（跨物种迁移）** 水稻侧校正参数应用于癌症侧时排序质量无显著下降；
- **H4（漏检回收）** 外部基线驱动的残差排序能提升「高文献量、零库内记录」实体的关联召回率。

说明：本文为研究设想，上述 H1–H4 为待检验假设，本文不预设任何实验结果。

课程论文支持使用 Agent 生成内容，
这只是起点。人工内容审查
和驾驭才是终点。