From Co-occurrence to Signal: Auditing and Correcting Research-Attention Bias in Cross-Kingdom Literature-Mined Gene–Trait Knowledge Bases

从共现到信号：跨物种文献挖掘基因–性状知识库中研究注意力偏差的审计与校正

陈佳伸

2023317220404

人工智能*2302* 邮箱: smiletrashbag@webmail.hzau.edu.cn

摘要—文献挖掘型知识库正被当作事实性资源广泛复用，但其关联强度的底层是共现计数，而共现同时混入了生物学效应与研究注意力两个来源。本文提出一项跨物种研究设想：以 RiceMind（水稻）与 CancerAlterome（人类癌症）这两个出自同一实验室、共享同一「共现抽取 + 本体归一化」范式的资源为对象，用库外文献基线为基因–性状对建立期望共现模型，并以残差作为注意力校正后的信号。设想的关键在于一个方法学处理：经查证，RiceMind 的 Tier 2/Tier 3 分层本身即由文章数阈值定义（>10 与 ≤ 10 篇），故基于该分层验证任何基于计数的校正都将构成循环；本文据此仅以与文献量无关的 Tier 1 作为标签，并对比较按文章数分层。预期贡献为：一套可移植的校正协议、对分层循环性的显式处理，以及首次对文献挖掘知识库注意力偏差的跨物种量化。

***Index Terms*—文献挖掘, 知识库偏差, 共现归一化, 发表偏倚, 本体归一化, 跨物种迁移**

I. 研究背景与问题 BACKGROUND

生物医学文献的规模已远超人工阅读能力，文献挖掘因此成为构建结构化知识的主要手段。 CancerAlterome 与 RiceMind 是该范式下两个成熟的资源：前者面向人类癌症，将**遗传改变→下游调控事件**归一化到 GO/HPO；后者面向水稻，将基因–性状关联归一化到 GO/TO/PO/RTO。两者出自同一实验室（HZAU-BioNLP Lab），共享同一套「共现抽取 + 本体归一化 + 来源分级」的方法论，区别仅在于物种与表型空间。

这类资源被下游直接当作「已知事实」使用——用于候选基因排序、通路富集、以及作为机器学习模型的弱标签。然而其关联强度的底层量是 **文献共现计数**。一个基因–性状对共现得多，可能因为该关联在生物学上强，也可能仅仅因为**这个基因和这个性状都被研究得多**。后者即**研究注意力**，它与生物学效应在计数中被不可分辨地混合。

这一偏差会带来一个具有实际后果的反馈回路：若知识库被不加校正地用于下游，其输出将系统性偏向已被充分研究的实体，从而**放大而非缩小**现有研究格局的不均衡—— 研究得多的基因被预测为更重要，进而获得更多研究。在作物育种与癌症靶点发现两个场景中，这意味着前者会忽视地方品种中未被充分研究的耐逆基因，后者会重复聚焦于已饱和的靶点。

现有资源普遍以置信度分层应对该问题，但这些分层并未与文献量解耦。经查证 RiceMind 的官方文档，其 Tier 2 与 Tier 3 的划分标准分别是「>10 篇独立文章」与「≤ 10 篇文章」[1]，**即某一层的定义本身就是文章数的函数**。这一事实尚未被既有文献指出，却直接影响下游对分层的使用方式。

本文要回答的三个问题：

- **RQ1（量化）** 研究注意力对关联强度的影响有多大？它与生物学信号在多大程度上可分离？

[1] http://lit-evi.hzau.edu.cn/ricemind-webpage/dataset/

课程论文支持使用 Agent 生成内容，
这只是开始。人工内容审查
和驾驭才是终点。

- **RQ2（校正）** 用外部文献基线对共现做归一化，能否得到比原始计数更接近生物学真值的排序？
- **RQ3（迁移）** 在一个物种上确定的校正，能否无损迁移到另一物种及其表型空间？

II. 主要研究设想 Main Research Idea

核心设想：把「超出研究注意力所能解释的部分」定义为关联信号。

设基因 g 与性状（或癌症过程）t 的库内共现计数为 $n(g,t)$，库内边缘频次为 n_g、n_t，总量为 N；另设 m_g、m_t 为 PubMed 中 g 与 t 各自的独立文献量，M 为检索空间总量。则**仅由注意力驱动**的期望共现为

$$E_{\text{ext}}[n(g,t)] = N \cdot \frac{m_g}{M} \cdot \frac{m_t}{M} \tag{1}$$

残差

$$r(g,t) = n(g,t) - E_{\text{ext}}[n(g,t)] \tag{2}$$

即为本文所定义的注意力校正后信号。

设想的要点不在于提出新的归一化公式，而在于主张**期望值的边缘频次应取自库外**：库内计数本身即是被污染的观测量，以它构造期望无法区分「该基因被研究得多」与「该关联真实且强」。

由此形成一个可直接实施的实验设计： 在同一测试集上比较三种排序—— 原始计数 n、仅用库内边缘频次的 PMI_{int}、以及用库外基线的 PMI_{ext}。其中 PMI_{int} 与 PMI_{ext} 的 **排名差异即构成文献注意力偏差的直接测量值**，该差值在既有文献中尚未被报告。

验证方案的立意：规避分层的循环性。 如第一节所述，RiceMind 的 Tier 2/Tier 3 由文章数阈值定义，故基于该二分层的验证是循环的，这是本设想在方法学上必须处理的核心障碍。应对方式有三：（i）**标签选择**上仅使用 **Tier 1** 作为正例—— 其定义依据是人工审编来源（Oryzabase/RAP-DB）或实验证据码（EXP/IDA/IMP），**与文献量无关**，故可作为干净标签，而 Tier 2/3 仅作分层变量；（ii）**按文章数区间分层**（如 1–5、6–10、11–50、>50），在各区间**内部**比较排序质量，以控制「Tier 1 基因本来就被研究得多」这一残余混淆；（iii）以**跨物种迁移**作为独立检验—— 在水稻侧确定的校正参数直接应用于癌症侧，该检验不依赖任何一方的分层体系，因而不受循环性影响。

待检验假设：

- **H1（校正有效性）** 分层条件下，PMI_{ext} 对 Tier 1 关联的 $P@k$ 显著高于原始计数且不低于 PMI_{int}；
- **H2（偏差可量化）** 两种 PMI 的排名差异与实体级文献量显著相关，且该相关在两库中具有可比的函数形式；
- **H3（跨物种迁移）** 水稻侧校正参数应用于癌症侧时排序质量无显著下降；
- **H4（漏检回收）** 外部基线驱动的残差排序能提升「高文献量、零库内记录」实体的关联召回率。

III. 实验设计 Experimental Design

本节给出检验 H1–H4 的具体方案，涵盖数据构建、标签设定、对比方法、实验矩阵、评价指标与稳健性检验。

A. 数据构建 *Data Construction*

三个数据面分别对应式 (1)(2) 所需的量：

- **库内关联与计数**（$n(g,t)$、n_g、n_t、N）：RiceMind 经 MCP 服务取全部 GTA 记录，字段含 `ontology_id`、`confidence_tier`、`evidence_codes`、`article_count`；CancerAlterome 经 `gene_var_table_update_paginator/` 与 `_by_cancer/` 两个端点按基因、按癌症分别拉取。**须避开**无 `_paginator` 后缀的端点—— 实测其静默忽略查询参数并返回固定的 315 条 ERBB2 数据，返回码仍为 HTTP 200。
- **库外文献基线**（m_g、m_t、M）：经 NCBI E-utilities `esearch.fcgi` 对每个实体检索 PubMed，记录命中数。检索式须预先固定并随代码公开。
- **实体对齐**：RiceMind 侧统一到 RAP ID，CancerAlterome 侧沿用其基因符号。两库之间**不做**基因层面的同源映射；跨物种迁移仅在**分布层面**（相关参数与函数形式）进行。

评估单元为三元组 $(g,t,\text{库})$。两库实测规模：RiceMind 基因 18,983 个、性状 5,371 条；CancerAlterome 基因 5,474 个。

B. 标签设定：正–未标注框架 *Label Construction*

本研究没有可靠的负例，这是实验设计的首要约束。

课程论文支持使用 Agent 生成内容，
这只是起点。人工内容审查
和驾驭才是终点。

「某基因与某性状不存在关联」无法从库中确证：库中未出现既可能是关联不存在，也可能是文献未被挖掘。若把「非 Tier 1」直接当作负例，则假阴性会被计入假阳性，从而系统性低估校正方法的收益。

据此采用**正–未标注**（positive–unlabeled, PU）设定：

- **正例**：Tier 1 关联。其判据为人工审编来源（Oryzabase/RAP-DB）或实验证据码（EXP/IDA/IMP），**与文献量无关**。
- **未标注**：其余全部关联。Tier 2/3 **不参与**正例或负例的构造，仅作为**分层变量**使用。

该设定直接规避了第一节指出的循环性：由于 Tier 2/3 由文章数阈值定义，任何以「Tier 1 对 Tier 3」为二分类标签的评测，其难度都部分等价于「模型能否数到 10」。

C. 对比方法 *Baselines*

表 I
对比方法。B4 为循环性对照，用于实证分层的循环性，不是竞争方法。

编号	方法	说明
B1	原始计数 n	现状基线
B2	$\mathrm{PMI}_{\mathrm{int}}$	仅校正库内密度
B3	$\mathrm{PMI}_{\mathrm{ext}}$	本文主张
B4	`article_count`	循环性对照

B4 的作用。由于 RiceMind 的 Tier 2/3 边界本身即文章数阈值，仅用 `article_count` 单一变量预测「Tier 2 对 Tier 3」即可取得接近完美的表现。B4 不参与方法优劣的比较，而是**作为循环性的实证演示**：若 B4 在该任务上显著优于全部真实方法，则说明该任务测的是文献量而非知识质量；据此可进一步量化「既有分层作为评测基准的失效程度」。

D. 实验矩阵 *Experiment Matrix*

E1（对应 H2）在全部评估单元上计算 $\mathrm{PMI}_{\mathrm{int}}$ 与 $\mathrm{PMI}_{\mathrm{ext}}$ 的排名差 Δrank，并对实体级文献量 $\log m_g$ 做回归，比较两库所得函数的形状与量级。 **E2（对应 H1）**在各文章数区间**内部**比较 B1–B3 对 Tier 1 的排序质量。 **E3**单独运行，其结论不用于评判方法，而用于说明分层作为基准的局限性。 **E4（对应 H3）**把水稻侧确定的参数直接施加于癌症侧，做非劣性检验。 **E5（对应 H4）**构造「高 PubMed 文献量、库内记录为零或极少」的实体集，比较残差排序对相关 Tier 1 关联的召回。

表 II
实验矩阵。E3 为方法学对照，其余四项分别对应 H1–H4。

编号	目的	对比	指标
E1	偏差量化	B1/B2/B3	Δrank 对 $\log m_g$
E2	校正有效性	B1/B2/B3	分层 $P@k$、$EF@k$
E3	循环性实证	B4 对其余	Tier 2/3 上 $P@k$
E4	跨物种迁移	B3 跨库应用	非劣性检验
E5	漏检回收	B1 对 B3	Recall@k

E. 评价指标 *Metrics*

由于负例不可靠，主指标选用不依赖真负例的排序指标：

- $P@k$：前 k 位中 Tier 1 的比例，$k \in \{10, 25, 50, 100\}$；
- 富集倍数 $EF@k$：前 k 位 Tier 1 比例除以全库 Tier 1 比例；
- Recall@k：前 k 位覆盖的 Tier 1 占全部 Tier 1 的比例；
- Kendall τ：校正前后排名的整体漂移幅度，用于 E1 的偏差度量，**不**用作准确率。

不以 AUC-ROC 作主指标。在 PU 设定下真负例集不可知， AUC 的数值依赖人为构造负例的方式，跨实验不可比。

F. 统计检验与稳健性 *Robustness*

- **置信区间**：对评估单元做 $B = 1000$ 次自助重采样，报告 95% 百分位置信区间。
- **配对检验**：在同一评估单元上比较 B1 与 B3，使用配对自助法差值检验，不依赖正态假设。
- **非劣性检验（E4）**：预设边界 δ，若跨物种应用后 $P@k$ 下降不超过 δ 则判定迁移成功。 δ 须在实验前固定并说明依据，**不得事后调整**。
- **敏感性分析**：分别改变（i）PubMed 检索式的同义词扩展策略，（ii）分层区间边界，（iii）k 的取值，观察结论是否稳定。
- **多重比较**：跨库、跨 k、跨分层区间构成多重比较，报告 Benjamini–Hochberg 校正后的 q 值。

课程论文支持使用 Agent 生成内容，
这只是起点。人工内容审查
和驾驭才是终点。

G. 可复现性 *Reproducibility*

公开两库的接口版本与访问日期、全部 PubMed 检索式、分层边界、随机种子，以及按端点原始返回解析的中间数据。所有计数均可由公开接口重新取得，不依赖私有快照。

说明：本文为研究设想，上述 H1–H4 为待检验假设；本节给出检验方案，本文不预设任何实验结果。

课程论文支持使用 Agent 生成内容，
这只是起点。人工内容审查
和驾驭才是终点。