


决策树

目录


- 基本流程
- 划分选择
- 剪枝处理



基本流程


决策树例子

➤ 相亲决策树：见或不见



决策树例子

西瓜决策树



决策树例子

如何设计算法让计算机根据数据
自动画出这样的决策树呢？

决策树例子


表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

如何根据上表数据画出决策树呢？

决策树例子

➤ 相亲决策树：见或不见



画出该决策树需要确定什么？

决策树

➤ 需要解决的问题：

◆ 属性顺序：

哪些属性在前面，哪些属性在后面？

◆ 属性选择：

哪些属性用，哪些属性不用？

划分选择

剪枝处理

决策树--算法原理

决策树基于“树”结构进行决策

- ❑ 每个“内部结点”对应于某个属性上的“测试” (test)
- ❑ 每个分支对应于该测试的一种可能结果（即该属性的某个取值）
- ❑ 每个“叶结点”对应于一个“预测结果”

学习过程：通过对训练样本的分析来确定“划分属性”（即内部结点所对应的属性）

预测过程：将测试示例从根结点开始，沿着划分属性所构成的“判定测试序列”下行，直到叶结点




图 4.1 西瓜问题的一棵决策树

决策树简史

- 第一个决策树算法：CLS (Concept Learning System)

[E. B. Hunt, J. Marin, and P. T. Stone's book "*Experiments in Induction*" published by Academic Press in 1966]

- 使决策树受到关注、成为机器学习主流技术的算法：ID3

[J. R. Quinlan's paper in a book "*Expert Systems in the Micro Electronic Age*" edited by D. Michie, published by Edinburgh University Press in 1979]

- 最常用的决策树算法：C4.5

[J. R. Quinlan's book "*C4.5: Programs for Machine Learning*" published by Morgan Kaufmann in 1993]



决策树简史

- 可以用于回归任务的决策树算法：CART (Classification and Regression Tree)

[L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone's book "Classification and Regression Trees" published by Wadsworth in 1984]

- 基于决策树的最强大算法：RF (Random Forest)

[L. Breiman's MLJ'01 paper "Random Forest"]

这是一种“集成学习”方法→第8章

决策树简史


➤ 决策树奠基人: Ross Quinlan



R. Quinlan是数据挖掘和人工智能领域的科学家。他于1965年于悉尼大学获得物理和计算学士学位, 1968年于美国华盛顿大学获得计算机科学博士学位。他的主要贡献是提出了决策树经典算法ID3和C4.5。

- ID3 (Iterative Dichotomiser 3)
- C4.5 (Classification 4.5 or C programming language 4.5?)

决策树简史



决策树--算法原理

策略：“分而治之” (divide-and-conquer)

自根至叶的递归过程

在每个中间结点寻找一个“划分” (split or test)属性

三种停止条件：

- (1) 当前结点包含的样本全属于同一类别，无需划分；
- (2) 当前属性集为空，或是所有样本在所有属性上取值相同，无法划分；
- (3) 当前结点包含的样本集合为空，不能划分。

决策树--算法

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;

属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

1: 生成结点 node;

2: if D 中样本全属于同一类别 C then

3: 将 node 标记为 C 类叶结点; return

4: end if

递归返回,
情形(1)

5: if $A = \emptyset$ OR D 中样本在 A 上取值相同 then

6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return

7: end if

递归返回,
情形(2)

8: 从 A 中选择最优划分属性 a_* ;

利用当前结点的后验分布

9: for a_* 的每一个值 a_*^v do

10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;

11: if D_v 为空 then

12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return

递归返回,
情形(3)

13: else

14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点

将父结点的样本分布作为
当前结点的先验分布

15: end if


16: end for


决策树算法的

输出: 以 node 为根结点的一棵决策树

核心

决策树--算法





划分选择

决策树--算法原理

➤ 信息增益

信息熵 (entropy) 是度量样本集合“纯度”最常用的一种指标
假定当前样本集合 D 中第 k 类样本所占的比例为 p_k , 则 D 的信息熵定义为

$$\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

计算信息熵时约定: 若
 $p = 0$, 则 $p \log_2 p = 0$.

$\text{Ent}(D)$ 的最小值为 0,
最大值为 $\log_2 |\mathcal{Y}|$.

$\text{Ent}(D)$ 的值越小, 则 D 的纯度越高

信息增益直接以信息熵为基础, 计算当前划分对信息熵所造成的变化

信息熵

什么是信息和信息熵呢？

信息

什么是信息？


“信息”一词在英文中是“information”，日文中为“情报”，我国台湾称之为“资讯”，我国古代用的是“消息”。作为科学术语最早出现在哈特莱于1928年撰写的《信息传输》一文中。

20世纪40年代，信息论的奠基人香农（C.E.Shannon）给出了信息的明确定义：

“信息是用来消除随机不确定性的东西。”

信息

什么是信息？



信息熵

1. 信息的多少是否可以量化呢？

信息不能称重，也不能拿尺子量，要怎么量化呢？

- 是否内容越多信息量就越大呢？不一定
同一句话写一万遍；中国获得足球世界杯冠军
- 不同形式的信息怎么对比量的大小呢？比如文字和图像

信息熵

1. 信息的多少是否可以量化呢？

生活中常见的例子

- A: 明天太阳从东方升起。
B: 你这句话没什么信息量啊。
- A: 中国获得足球世界杯冠军。
B: 什么？！你这句话信息量巨大啊！

直觉告诉我们，信息应该是可以量化的，而且事件发生的概率越大，信息量越小。

信息与信息熵

1. 信息的多少是否可以量化呢？



- 骰子的点数大于0
- 骰子的点数大于3
- 骰子的点数是5

信息熵

2. 如何量化一个信息的含量多少呢？

信息量 $I(x)$ 应该满足的条件：

(1) 非负


(2) 信息量可以相加 $I(xy) = I(x) + I(y)$

(3) 与事件概率 $p(x)$ 关系：概率越大，信息量越小

什么函数可以同时满足上述条件呢？

信息与信息熵

2. 如何量化一个信息的含量多少呢？




➤ 抽取的小球是1吗？

YES --- 1

NO --- 2

信息与信息熵

2. 如何量化一个信息的含量多少呢？




➤ 抽取的小球是大于2吗？

YES --- 是3吗？

NO --- 是1吗？

信息与信息熵

2. 如何量化一个信息的含量多少呢？




➤ 8个小球呢，需要问几个问题？



信息与信息熵

2. 如何量化一个信息的含量多少呢？



$$I = f(p)$$

与事件概率 p 关系：概率越大，信息量越小

$$I = \log_2 \frac{1}{p}$$

信息与信息熵

2. 如何量化一个信息的含量多少呢？



➤ 骰子的点数大于0

$$p = 1, I = 0$$

➤ 骰子的点数大于3

$$p = 1/2, I = 1$$

➤ 骰子的点数大于5

$$p = 1/6, I = 2.58$$

信息熵

2. 如何量化一个信息的含量多少呢？




$$I(x) = -\log_2 p(x)?$$

三条性质都满足，其中第二条推导过程如下：

$$\begin{aligned} I(xy) &= -\log_2 p(xy) = -\log_2 (p(x)p(y)) \\ &= -\log_2 p(x) + (-\log_2 p(y)) = I(x) + I(y) \end{aligned}$$

信息与信息熵

3. 如果一个消息有多种结果，如何计算其信息量？



$$p = 0$$

➤ 观察值： 2 2 2 2 2

➤ 概率值： 1 1 1 1 1


$$p = 1$$

➤ 信息量： 0 0 0 0 0

平均信息量为0

信息与信息熵

3. 如果一个消息有多种结果，如何计算其信息量？



$$p = 0.2$$

➤ 观察值： 2 2 1 2 2

➤ 概率值： 0.8 0.8 0.2 0.8 0.8


$$p = 0.8$$

➤ 信息量： 0.3 0.3 2.3 0.3 0.3

平均信息量为0.7

信息与信息熵

3. 如果一个消息有多种结果，如何计算其信息量？



$$p = 0.5$$

➤ 观察值： 2 1 1 2 2

➤ 概率值： 0.5 0.5 0.5 0.5 0.5

$$p = 0.5$$

➤ 信息量： 1 1 1 1 1

平均信息量为1


信息与信息熵

3. 如果一个消息有多种结果，如何计算其信息量？

信息熵（也称为香农熵，平均信息量）：

$$\begin{aligned} H(x) &= \sum_{i=1}^n I(x_i)p(x_i) \\ &= - \sum_{i=1}^n p(x_i) \log_2 p(x_i) \end{aligned}$$

设 x 的定义域为 $\{x_1, x_2, \dots, x_n\}$



信息论之父
C. E. Shannon 香农
1916-2001

信息熵

例1. 文字

汉字常用的有2500个，假如每个汉字在文章中出现次数平均的话，每个汉字的信息量为：

$$I(x_i) = -\log_2 \frac{1}{2500} = 11.3$$
$$H(x) = -\sum_{i=1}^{2500} I(x_i) \frac{1}{2500} = 11.3$$

英语有26个字母，假如每个字母在文章中出现次数平均的话，每个字母的讯息量为：

$$I(x) = -\log_2 \frac{1}{26} = 4.7$$

语言学家告诉我们英文的信息熵是4.03

信息熵


例2. 图像

灰度图像中像素的取值范围为0~255的整数，假设图像中的每个像素出现次数平均的话，则一副100x100的灰度图像的信息量为：

$$I(x) = -\log_2 \frac{1}{256} \times 10,000 = 80,000$$

信息熵

例3. 纯黑图像




一副100x100的纯黑色图像的信息量为：

$$I(x) = -\log_2 1 \times 10,000 = 0$$

信息熵

例4. 黑白图像




一副100x100的黑白色图像的信息量为：

$$I(x) = -\log_2 \frac{1}{2} \times 10,000 = 10,000$$

信息熵

例5. 国际象棋棋盘图像



一副8x8的国际象棋棋盘图像的信息量？

决策树--算法原理

➤ 信息增益

离散属性 a 的取值: $\{a^1, a^2, \dots, a^V\}$

D^v : D 中在 a 上取值 $= a^v$ 的样本集合

以属性 a 对 数据集 D 进行划分所获得的信息增益为:

$$\text{Gain}(D, a) = \underbrace{\text{Ent}(D)}_{\text{划分前的信息熵}} - \sum_{v=1}^V \underbrace{\frac{|D^v|}{|D|}}_{\substack{\text{第 } v \text{ 个分支的权重,} \\ \text{样本越多越重要}}} \underbrace{\text{Ent}(D^v)}_{\text{划分后的信息熵}}$$

决策树--算法原理

➤ 信息增益：一个简单的例子

编号	色泽	纹理	好瓜
1	乌黑	清晰	是
2	乌黑	模糊	是
3	浅白	清晰	否
4	浅白	模糊	否

$\text{Gain}(D, \text{色泽}) = ?$

$\text{Gain}(D, \text{纹理}) = ?$

决策树--算法原理

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

根结点的信息熵为

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17} \right) = 0.998$$

决策树--算法原理

- 以属性“色泽”为例，其对应的3个数据子集分别为
- 青绿： $D^1 = \{1, 4, 6, 10, 13, 17\}$ ， 好： 3； 坏： 3
- 乌黑： $D^2 = \{2, 3, 7, 8, 9, 15\}$ ， 好： 4； 坏： 2
- 浅白： $D^3 = \{5, 11, 12, 14, 16\}$ ， 好： 1； 坏： 4

上述3个结点的信息熵为：

$$\text{Ent}(D^1) = - \left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6} \right) = 1.000$$

$$\text{Ent}(D^2) = - \left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6} \right) = 0.918$$

$$\text{Ent}(D^3) = - \left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5} \right) = 0.722$$

决策树--算法原理

➤ 属性“色泽”的信息增益为：

$$\begin{aligned} & \text{Gain}(D, \text{色泽}) \\ &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) \\ &= 0.109 \end{aligned}$$

决策树--算法原理

- 类似地，其他属性的信息增益为：

$$\text{Gain}(D, \text{根蒂}) = 0.143 \quad \text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{纹理}) = 0.381 \quad \text{Gain}(D, \text{脐部}) = 0.289$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

- 显然，属性“纹理”的信息增益最大，被选为划分属性



决策树--算法原理

下一步呢，怎么做？



决策树--算法原理

➤ 考虑结点 “纹理=清晰”

该节点包含的样本集合

$$D^1 = \{1, 2, 3, 4, 5, 6, 8, 10, 15\},$$

共9个样本，7个好瓜，2个坏瓜。

根据信息增益准则进行该节点的划分，确定下一个节点是下面属性中的哪一个：色泽，根蒂，敲声，脐部，触感。

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 计算色泽属性的信息增益

$$D^1 = \{1, 2, 3, 4, 5, 6, 8, 10, 15\},$$

共9个样本，7个好瓜，2个坏瓜。

类似地，色泽有三个属性：青绿，乌黑，浅白
分别对应

□ 青绿： $D^{11} = \{1, 4, 6, 10\}$ ，好：3；坏：1

□ 乌黑： $D^{12} = \{2, 3, 8, 15\}$ ，好：3；坏：1

□ 浅白： $D^{13} = \{5\}$ ，好：1；坏：0

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^1, \text{色泽}) = \text{Ent}(D^1) - \sum_{v=1}^3 \frac{|D^{1v}|}{|D^1|} \text{Ent}(D^{1v})$$

D^1 共9个样本，7个好瓜，2个坏瓜。

$$\text{Ent}(D^1) = -\frac{7}{9} \log \frac{7}{9} - \frac{2}{9} \log \frac{2}{9} = 0.7642$$

D^{11} 共4个样本，3个好瓜，1个坏瓜。

$$\text{Ent}(D^{11}) = -\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4} = 0.8112$$

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^1, \text{色泽}) = \text{Ent}(D^1) - \sum_{v=1}^3 \frac{|D^{1v}|}{|D^1|} \text{Ent}(D^{1v})$$

D^{12} 共4个样本，3个好瓜，1个坏瓜。

$$\text{Ent}(D^{12}) = -\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4} = 0.8112$$

D^{13} 共1个样本，1个好瓜，0个坏瓜。

$$\text{Ent}(D^{13}) = -1 \log 1 = 0$$

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^1, \text{色泽}) = \text{Ent}(D^1) - \sum_{v=1}^3 \frac{|D^{1v}|}{|D^1|} \text{Ent}(D^{1v})$$

将算出的数值代入上述公式，可得。

$$\begin{aligned} \text{Gain}(D^1, \text{色泽}) &= 0.7642 - 0.8112 * \frac{4}{9} * 2 \\ &= 0.043 \end{aligned}$$

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 类似地，基于 D^1 可计算其他属性的信息增益

$$\text{Gain}(D^1, \text{色泽}) = 0.043$$

$$\text{Gain}(D^1, \text{根蒂}) = 0.458$$

$$\text{Gain}(D^1, \text{敲声}) = 0.331$$

$$\text{Gain}(D^1, \text{脐部}) = 0.458$$

$$\text{Gain}(D^1, \text{触感}) = 0.458$$

可选择根蒂，脐部
和触感其中之一作
为下一个结点

决策树--算法原理

➤ 考虑结点“纹理=稍糊”

请根据信息增益准则进行划分，并计算最大信息增益对应属性的信息增益值。



决策树--算法原理

➤ 考虑结点 “纹理=稍糊”



该节点包含的样本集合

$$D^2 = \{7, 9, 13, 14, 17\},$$

共5个样本，1个好瓜，4个坏瓜。

根据信息增益准则进行该节点的划分，确定下一个节点是下面属性中的哪一个：色泽，根蒂，敲声，脐部，触感。

决策树--算法原理

➤ 考虑结点 “纹理=稍糊”

◆ 计算色泽属性的信息增益

$$D^2 = \{7, 9, 13, 14, 17\},$$

共5个样本，1个好瓜，4个坏瓜。

色泽有三个属性：青绿，乌黑，浅白 分别对应

□ 青绿： $D^{21} = \{13, 17\}$ ，好：0；坏：2

□ 乌黑： $D^{22} = \{7, 9\}$ ，好：1；坏：1

□ 浅白： $D^{23} = \{14\}$ ，好：0；坏：1

决策树--算法原理

➤ 考虑结点 “纹理=稍糊”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^2, \text{色泽}) = \text{Ent}(D^2) - \sum_{v=1}^3 \frac{|D^{2v}|}{|D^2|} \text{Ent}(D^{2v})$$

D^2 共5个样本，1个好瓜，4个坏瓜。

$$\text{Ent}(D^2) = -\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5} = 0.7219$$

D^{21} 共2个样本，0个好瓜，2个坏瓜。

$$\text{Ent}(D^{21}) = -0 - 1 \log 1 = 0$$

决策树--算法原理

➤ 考虑结点 “纹理=稍糊”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^2, \text{色泽}) = \text{Ent}(D^2) - \sum_{v=1}^3 \frac{|D^{2v}|}{|D^2|} \text{Ent}(D^{2v})$$

D^{22} 共2个样本，1个好瓜，1个坏瓜。

$$\text{Ent}(D^{22}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 1$$

D^{23} 共1个样本，0个好瓜，1个坏瓜。

$$\text{Ent}(D^{23}) = -1 \log 1 = 0$$

决策树--算法原理

➤ 考虑结点 “纹理=稍糊”

◆ 计算色泽属性的信息增益

$$\text{Gain}(D^2, \text{色泽}) = \text{Ent}(D^2) - \sum_{v=1}^3 \frac{|D^{2v}|}{|D^2|} \text{Ent}(D^{2v})$$

将算出的数值代入上述公式，可得。

$$\begin{aligned} & \text{Gain}(D^2, \text{色泽}) \\ &= 0.7219 - \left(\frac{2}{5} * 0 + \frac{2}{5} * 1 + \frac{1}{5} * 0 \right) = 0.3219 \end{aligned}$$

决策树--算法原理

➤ 考虑结点 “纹理=清晰”

◆ 类似地，基于 D^2 可计算其他属性的信息增益

$$\text{Gain}(D^2, \text{色泽}) = 0.3219$$

$$\text{Gain}(D^2, \text{根蒂}) = 0.0729$$

$$\text{Gain}(D^2, \text{敲声}) = 0.3219$$


$$\text{Gain}(D^2, \text{脐部}) = 0.1709$$


$$\text{Gain}(D^2, \text{触感}) = 0.7219$$

可选择触感作为下一个结点

决策树--算法原理

对每个分支结点做进一步划分，最终得到决策树





剪枝处理

决策树--算法原理

➤ 剪枝

为了尽可能正确分类训练样本，有可能造成分支过多 → 过拟合

可通过主动去掉一些分支来降低过拟合的风险

基本策略：

- 预剪枝 (pre-pruning): 提前终止某些分支的生长
- 后剪枝 (post-pruning): 生成一棵完全树，再“回头”剪枝

剪枝过程中需评估剪枝前后决策树的优劣 → 第 2 章

现在我们假定使用“留出法”

决策树--算法原理


数据集

表 4.2 西瓜数据集 2.0 划分出的训练集(双线上部)与验证集(双线下部)

训练集	编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
	1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
	2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
	3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
	6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
	7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
	10	青绿	硬挺	清脆	清晰	平坦	软粘	否
	14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
	15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
	16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
	17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否
验证集	编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
	4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
	5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
	8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
	9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
	11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
	12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
	13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

决策树--算法原理

➤ 未剪枝的决策树



决策树--算法原理

➤ 预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1: 若不划分, 则将其标记为叶结点, 类别标记为训练样例中最多的类别, 若选“好瓜”。验证集中, {4, 5, 8} 被分类正确, 得到验证集精度为 $\frac{3}{7} \times 100\% = 42.9\%$

1

脐部=?

验证集精度

“脐部=?” 划分前: 42.9%

决策树--算法原理


预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1: 若划分, 根据结点②, ③, ④的训练样例, 将这3个结点分别标记为“好瓜”、“好瓜”、“坏瓜”。此时, 验证集中编号为{4, 5, 8, 11, 12}的样例被划分正确, 验证集精度为 $\frac{5}{7} \times 100\% = 71.4\%$

验证集精度




决策树--算法原理

预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否


对结点②, ③, ④ 分别进行剪枝判断, 结点②, ③ 都禁止划分, 结点④ 本身为叶子结点。最终得到仅有一层划分的决策树, 称为“**决策树桩**” (decision stump)



决策树--算法原理

➤ 后剪枝


先生成一棵完整的决策树，其验证集精度测得为 42.9%



决策树--算法原理

➤ 后剪枝


首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样例 {7, 15} 将其标记为“好瓜”，测得验证集精度提高至 57.1%，于是决定剪枝



决策树--算法原理

➤ 后剪枝


首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样例 {7, 15} 将其标记为“好瓜”，测得验证集精度提高至 57.1%，于是决定剪枝



决策树--算法原理

➤ 后剪枝


然后考虑结点⑤，若将其替换为叶结点，根据落在其上的训练样例 {6,7,15} 将其标记为“好瓜”，测得验证集精度仍为 57.1%，可以不剪枝



决策树--算法原理

➤ 后剪枝


然后考虑结点⑤，若将其替换为叶结点，根据落在其上的训练样例 {6,7,15} 将其标记为“好瓜”，测得验证集精度仍为 57.1%，可以不剪枝



决策树--算法原理

➤ 后剪枝


对结点②，若将其替换为叶结点，根据落在其上的训练样例 {1, 2, 3, 14}，将其标记为“好瓜”，测得验证集精度提升至 71.4%，决定剪枝



决策树--算法原理

➤ 后剪枝


对结点③和①，先后替换为叶结点，均未测得验证集精度提升，
于是不剪枝



决策树--算法原理

➤ 后剪枝

最终，后剪枝得到的决策树：



决策树--算法原理

➤ 预剪枝 vs. 后剪枝

□ 时间开销:

- 预剪枝: 训练时间开销降低, 测试时间开销降低
- 后剪枝: 训练时间开销增加, 测试时间开销降低

□ 过/欠拟合风险:

- 预剪枝: 过拟合风险降低, 欠拟合风险增加
- 后剪枝: 过拟合风险降低, 欠拟合风险基本不变

□ 泛化性能: 后剪枝 通常优于 预剪枝

谢 谢!