

课程：机器学习

◆ 总结:

- 你怎么看机器学习/人工智能:
- 你觉得从这门课学到什么:





课程内容

课程内容

人工智能： 机器展现的人类智能

机器学习： 计算机利用已有的数据(经验)，得出了某种模型，并利用此模型预测未来的一种方法。

深度学习： 实现机器学习的一种技术



课程内容



◆ 是什么 能否用通俗易懂的语言解释

◆ 怎么做 能否独立实现或复现

◆ 为什么 能否独立推导证明

讲出来
!


例如：推导线性回归的显式解；
支持向量机的目标函数
和对偶问题...

5



背景知识

机器学习的定义




机器学习

- What is machine learning?

(1) Arthur Samuel (1959): Fields of study that gives computers the ability to learn without being explicitly programmed.

机器学习是这样的领域，它赋予计算机学习的能力，
(这种学习能力) 不是通过显著式编程获得的。



机器学习

经典定义

Machine learning (ML) is the study of computer algorithms that improve automatically through experience.

--Wiki

机器学习研究能够从经验中自动提升自身性能的计算机算法。

--Wiki

有没有更加直观形象的解释呢？



发展历程

发展历程

机器学习源自“人工智能”

Artificial Intelligence (AI), 1956 -

1956年夏 美国达特茅斯学院

J. McCarthy, M. Minsky, N. Lochester, C. E. Shannon,
H.A. Simon, A. Newell, A. L. Samuel 等10余人



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖

达特茅斯会议标志着人工智能这一学科的诞生

John McCarthy (1927 - 2011):

1971年获图灵奖, 1985年获IJCAI终身成就奖。人工智能之父。他提出了“人工智能”的概念, 设计出函数型程序设计语言Lisp, 发展了递归的概念, 提出常识推理和情境演算。出生于共产党家庭, 从小阅读《10万个为什么》, 中学时自修CalTech的数学课程, 17岁进入CalTech时免修两年数学, 22岁在Princeton获博士学位, 37岁担任Stanford大学AI实验室主任。

发展历程

1956年人工智能的创立



1956年，于达特茅斯学院，Allen Newell (CMU)，Herbert Simon (CMU)，John McCarthy (MIT)，Marvin Minsky (MIT) and Arthur Samuel (IBM) 创立人工智能

发展历程

AI@50 Conference in 2006



The five attendees at the AI@50 conference in 2006 who were part of the Dartmouth Summer of 1956: Trenchard More, John McCarthy, Marvin Minsky, Oliver Selfridge, Ray Solomonoff.

发展历程

第一阶段：推理期

1956-1960s: Logic Reasoning

- ◆ 出发点：“数学家真聪明！”
- ◆ 主要成就：自动定理证明系统（例如，西蒙与纽厄尔的“Logic Theorist”系统）

渐渐地，研究者们意识到，仅有逻辑推理能力是不够的 ...



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

发展历程

第二阶段：知识期

1970s -1980s: Knowledge Engineering

- ◆ 出发点：“知识就是力量！”
- ◆ 主要成就：专家系统（例如，费根鲍姆等人的“DENDRAL”系统）



爱德华 费根鲍姆
(1936-)
1994年图灵奖

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 ...

发展历程

第三阶段：学习期

1990s -now: Machine Learning


◆ 出发点：“让系统自己学！”

◆ 主要成就：……

机器学习是作为“突破知识工程瓶颈”
之利器而出现的



恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切



基本术语

基本术语--数据

		特征				标记
		色泽	根蒂	敲声	好瓜	
训练集	1	青绿	蜷缩	浊响	是	
	2	乌黑	蜷缩	沉闷	是	
	3	青绿	硬挺	清脆	否	
	4	乌黑	稍蜷	沉闷	否	
测试集	1	青绿	蜷缩	沉闷	?	



基本术语--任务

□ 预测目标:

- 分类:离散值
 - 二分类: 好瓜; 坏瓜
 - 多分类: 哈密瓜; 冬瓜; 西瓜
- 回归:连续值
 - 瓜的成熟度
- 聚类:无标记信息



基本术语--泛化能力

机器学习的目标是使得学到的模型能很好的适用于“新样本”，而不仅仅是训练集合，我们称模型适用于新样本的能力为泛化 (generalization)能力。

通常假设样本空间中的样本服从一个未知分布 Q ，样本从这个分布中独立获得，即“独立同分布” (i.i.d)。一般而言训练样本越多越有可能通过学习获得强泛化能力的模型



模型评估和选择

目录

- 经验误差与过拟合 (Empirical error & overfitting)
- 评估方法 (Evaluation method)
- 性能度量 (Performance measure)
- 偏差与方差 (Bias and Variance)

泛化误差和经验误差

经验误差 (Empirical Error) :

学习器 f 在训练集 $\{(x_i, y_i), i = 1, \dots, m\}$ 上的误差

$$R_{emp}(f) = \frac{1}{m} \sum_{i=1}^m L(f(x_i), y_i)$$

泛化误差 (Generalization Error) :

学习器 f 在“未来”样本上的误差


$$R(f) = \mathbb{E}[L(f(x), y)] = \int L(f(x), y) dP(x, y)$$

经验误差是不是越小越好?

No!

可能会出现过拟合

泛化误差和经验误差




- 欠拟合：相较于数据而言，模型参数过少或者模型结构过于简单，以至于无法捕捉到数据中的规律的现象。
- 过拟合：模型过于紧密或精确地匹配特定数据集，以至于无法良好地拟合其他数据或预测未来的观察结果的现象。
- 合适的拟合：模型能够恰当地拟合和捕捉到数据中规律的现象。



评估方法

评估方法

- 留出法 (hold-out)
- 交叉验证法 (Cross validation)
- 自助法 (Bootstrapping)
- 调参与最终模型 (Parameter tuning and final model)



性能度量

性能度量

- 错误率与精度
- 查准率、查全率与F1
- ROC与AUC
- 代价敏感错误率与代价曲线

性能度量


➤ 查准率、查全率与F1

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

- 查准率: $P = \frac{TP}{TP + FP}$
- 查全率: $R = \frac{TP}{TP + FN}$
- F1: $F1 = \frac{2 \times P \times R}{P + R}$

真实情况: 左正右负
分类结果: 内正外负



性能度量

➤ ROC与AUC

- ROC (Receiver Operating Characteristic)

中文翻译为受试者工作特征，最早源于“二战”中用于敌机检测的雷达信号分析技术，之后被引入机器学习领域。

表 2.1 分类结果混淆矩阵


真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

- 真正例率: $TPR = \frac{TP}{TP + FN}$
- 假正例率: $FPR = \frac{FP}{FP + TN}$

性能度量

➤ ROC与AUC

- AUC (Area Under ROC Curve): ROC曲线下面的面积。



性能度量

假如某个垃圾邮件识别算法对如下 10 封邮件样本上的打分结果和真实情况如下：

编号	1	2	3	4	5	6	7	8
垃圾邮件	否	是	否	是	否	是	是	是
得分	0.1	0.2	0.3	0.4	0.5	0.7	0.8	0.9

1. 设分类阈值为 0.6，请写出分类结果的混淆矩阵。
2. 设分类阈值为 0.6，请计算分类结果的查准率，查全率和 F1 分数。
3. 请画出该分类器的 ROC 曲线。
4. 请计算其 AUC 值。

线性模型

目录

- 线性回归
- 对数几率回归
- 线性判别分析
- 类别不平衡问题

线性回归--算法原理

令 $\nabla E(\hat{\mathbf{w}}) = 2\mathbf{X}^T(\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}) = 0$ ，可得到

$$\mathbf{X}^T\mathbf{X}\hat{\mathbf{w}} = \mathbf{X}^T\mathbf{y}$$

当 $\mathbf{X}^T\mathbf{X}$ 为满秩矩阵时，可得

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

由于 $\hat{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$ ，因此

$$\mathbf{w}^* = \hat{\mathbf{w}}^*(1:d) \quad b^* = \hat{\mathbf{w}}^*(d+1)$$

例子

请利用数据集 $D=\{(0, 1.4), (1, 2.8), (-1, -1.2)\}$ 构建线性回归模型。


设线性回归模型为 $y = wx + b$ 。利用最小二乘法可得如下目标函数

$$\min_{w, b} f(w, b) = (1.1 - b)^2 + (w + b - 2.8)^2 + (-w + b - 1.2)^2$$

令 $f(w, b)$ 关于 w 和 b 的偏导均为0，可得

$$\begin{aligned} w + b - 2.8 - (-w + b - 1.2) &= 0 \\ b - 1.1 + w + b - 2.8 + (-w + b - 1.2) &= 0 \end{aligned}$$


通过解上述方程组可得 $w = 0.8, b = 1.7$



线性判别分析

线性判别分析--算法原理

线性判别分析(Linear Discriminant Analysis, LDA)



线性判别分析--算法原理

线性判别分析思想：寻找一个直线（或者低维子空间），使得同类样本的投影点尽可能接近，异类样本的投影点尽可能远离。


同类近，异类远。

如何量化“同类近，异类远”？

线性判别分析：例子

类别1: (4,2), (2,4), (2,3), (3,6), (4,4)

类别2: (9,10), (6,8), (9,5), (8,7), (10,8)



线性判别分析：例子

➤ 每个类别的均值：

$$\mu_0 = \frac{1}{N_0} \sum_{\mathbf{x} \in X_0} \mathbf{x} = \frac{1}{5} \left[\begin{pmatrix} 4 \\ 2 \end{pmatrix} + \begin{pmatrix} 2 \\ 4 \end{pmatrix} + \begin{pmatrix} 2 \\ 3 \end{pmatrix} + \begin{pmatrix} 3 \\ 6 \end{pmatrix} + \begin{pmatrix} 4 \\ 4 \end{pmatrix} \right] = \begin{pmatrix} 3 \\ 3.8 \end{pmatrix}$$

$$\mu_1 = \frac{1}{N_1} \sum_{\mathbf{x} \in X_1} \mathbf{x} = \frac{1}{5} \left[\begin{pmatrix} 9 \\ 10 \end{pmatrix} + \begin{pmatrix} 6 \\ 8 \end{pmatrix} + \begin{pmatrix} 9 \\ 5 \end{pmatrix} + \begin{pmatrix} 8 \\ 7 \end{pmatrix} + \begin{pmatrix} 10 \\ 8 \end{pmatrix} \right] = \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix}$$

线性判别分析：例子

➤ 类别0的协方差矩阵：

$$\begin{aligned}\Sigma_0 &= \frac{1}{N_0} \sum_{\mathbf{x} \in X_0} (\mathbf{x} - \boldsymbol{\mu}_0)(\mathbf{x} - \boldsymbol{\mu}_0)^T = \left[\begin{pmatrix} 4 \\ 2 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right] \left[\begin{pmatrix} 4 \\ 2 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right]^T \\ &\quad + \left[\begin{pmatrix} 2 \\ 4 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right] \left[\begin{pmatrix} 2 \\ 4 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right]^T + \left[\begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right] \left[\begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right]^T \\ &\quad + \left[\begin{pmatrix} 3 \\ 6 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right] \left[\begin{pmatrix} 3 \\ 6 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right]^T + \left[\begin{pmatrix} 4 \\ 4 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right] \left[\begin{pmatrix} 4 \\ 4 \end{pmatrix} - \begin{pmatrix} 3 \\ 3.8 \end{pmatrix} \right]^T \\ &= \begin{pmatrix} 4 & -1 \\ -1 & 8.8 \end{pmatrix}\end{aligned}$$

42

线性判别分析：例子

➤ 类别1的协方差矩阵：

$$\begin{aligned}\Sigma_1 &= \frac{1}{N_1} \sum_{\mathbf{x} \in X_1} (\mathbf{x} - \boldsymbol{\mu}_1)(\mathbf{x} - \boldsymbol{\mu}_1)^T = \left[\begin{pmatrix} 9 \\ 10 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 9 \\ 10 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T \\ &\quad + \left[\begin{pmatrix} 6 \\ 8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 6 \\ 8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T + \left[\begin{pmatrix} 9 \\ 5 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 9 \\ 5 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T \\ &\quad + \left[\begin{pmatrix} 8 \\ 7 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 8 \\ 7 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T + \left[\begin{pmatrix} 10 \\ 8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 10 \\ 8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T \\ &= \begin{pmatrix} 9.2 & -0.2 \\ -0.2 & 13.2 \end{pmatrix}\end{aligned}$$

43

线性判别分析：例子

➤ 类内散度矩阵(Within-class scatter matrix):

$$\begin{aligned}\mathbf{S}_w &= \mathbf{\Sigma}_0 + \mathbf{\Sigma}_1 \\ &= \begin{pmatrix} 4 & -1 \\ -1 & 8.8 \end{pmatrix} + \begin{pmatrix} 9.2 & -0.2 \\ -0.2 & 13.2 \end{pmatrix} \\ &= 4 \begin{pmatrix} 3.3 & -0.3 \\ -0.3 & 5.5 \end{pmatrix}\end{aligned}$$

44

线性判别分析：例子

➤ 类内散度矩阵(Within-class scatter matrix):

$$\begin{aligned}\mathbf{S}_b &= (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \\ &= \left[\begin{pmatrix} 3 \\ 3.8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right] \left[\begin{pmatrix} 3 \\ 3.8 \end{pmatrix} - \begin{pmatrix} 8.4 \\ 7.6 \end{pmatrix} \right]^T \\ &= 4 \begin{pmatrix} 7.29 & 5.13 \\ 5.13 & 3.61 \end{pmatrix}\end{aligned}$$

45

线性判别分析：例子

➤ 求解如下广义特征值问题：

$$S_w^{-1} S_b \mathbf{w} = \lambda \mathbf{w}$$

线性判别分析：例子

➤ 求解如下广义特征值问题：

$$|\mathbf{S}_w^{-1}\mathbf{S}_b - \lambda\mathbf{I}| = 0$$

$$\Rightarrow \left| \begin{pmatrix} 3.3 & -0.3 \\ -0.3 & 5.5 \end{pmatrix}^{-1} \begin{pmatrix} 7.29 & 5.13 \\ 5.13 & 3.61 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right| = 0$$

$$\Rightarrow \left| \begin{pmatrix} 2.3053 & 1.6223 \\ 1.0585 & 0.7449 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right| = 0$$

线性判别分析：例子

➤ 求解如下广义特征值问题：

$$\Rightarrow \begin{vmatrix} 2.3053 - \lambda & 1.6223 \\ 1.0585 & 0.7449 - \lambda \end{vmatrix} = 0$$

$$\Rightarrow (2.3053 - \lambda)(0.7449 - \lambda) - 1.6223 \times 1.0585 = 0$$

$$\Rightarrow \lambda^2 - 3.0502\lambda = 0$$

$$\Rightarrow \lambda_1 = 0, \quad \lambda_2 = 3.0502.$$

选哪一个
?

线性判别分析：例子

➤ 特征向量：

$$\begin{pmatrix} 2.3053 & 1.6223 \\ 1.0585 & 0.7449 \end{pmatrix} \mathbf{w}_1 = 0 \mathbf{w}_1$$

$$\begin{pmatrix} 2.3053 & 1.6223 \\ 1.0585 & 0.7449 \end{pmatrix} \mathbf{w}_2 = 3.0502 \mathbf{w}_2$$

$$\mathbf{w}_1 = \begin{pmatrix} -0.5755 \\ 0.8178 \end{pmatrix} \quad \mathbf{w}_2 = \begin{pmatrix} 0.9088 \\ 0.4173 \end{pmatrix}$$

决策树

目录

- 基本流程
- 划分选择
- 剪枝处理

决策树

➤ 需要解决的问题：

◆ 属性顺序：

哪些属性在前面，哪些属性在后面？

◆ 属性选择：

哪些属性用，哪些属性不用？



划分选择



剪枝处理

决策树--算法原理

➤ 信息增益

信息熵 (entropy) 是度量样本集合“纯度”最常用的一种指标
假定当前样本集合 D 中第 k 类样本所占的比例为 p_k , 则 D 的信息熵定义为

$$\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

计算信息熵时约定: 若
 $p = 0$, 则 $p \log_2 p = 0$.

$\text{Ent}(D)$ 的最小值为 0,
最大值为 $\log_2 |\mathcal{Y}|$.

$\text{Ent}(D)$ 的值越小, 则 D 的纯度越高

信息增益直接以信息熵为基础, 计算当前划分对信息熵所造成的变化

决策树--算法原理

➤ 信息增益

离散属性 a 的取值: $\{a^1, a^2, \dots, a^V\}$

D^v : D 中在 a 上取值 $= a^v$ 的样本集合

以属性 a 对 数据集 D 进行划分所获得的信息增益为:

$$\text{Gain}(D, a) = \underbrace{\text{Ent}(D)}_{\text{划分前的信息熵}} - \sum_{v=1}^V \underbrace{\frac{|D^v|}{|D|}}_{\substack{\text{第 } v \text{ 个分支的权重,} \\ \text{样本越多越重要}}} \underbrace{\text{Ent}(D^v)}_{\text{划分后的信息熵}}$$

决策树--算法原理

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

根结点的信息熵为

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17} \right) = 0.998$$

决策树--算法原理

- 以属性“色泽”为例，其对应的3个数据子集分别为
- 青绿： $D^1 = \{1, 4, 6, 10, 13, 17\}$ ， 好： 3； 坏： 3
- 乌黑： $D^2 = \{2, 3, 7, 8, 9, 15\}$ ， 好： 4； 坏： 2
- 浅白： $D^3 = \{5, 11, 12, 14, 16\}$ ， 好： 1； 坏： 4

上述3个结点的信息熵为：

$$\text{Ent}(D^1) = - \left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6} \right) = 1.000$$

$$\text{Ent}(D^2) = - \left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6} \right) = 0.918$$

$$\text{Ent}(D^3) = - \left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5} \right) = 0.722$$

决策树--算法原理

➤ 属性“色泽”的信息增益为：

$$\begin{aligned} & \text{Gain}(D, \text{色泽}) \\ &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) \\ &= 0.109 \end{aligned}$$

决策树--算法原理

- 类似地，其他属性的信息增益为：


$$\text{Gain}(D, \text{根蒂}) = 0.143 \quad \text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{纹理}) = 0.381 \quad \text{Gain}(D, \text{脐部}) = 0.289$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

- 显然，属性“纹理”的信息增益最大，被选为划分属性





剪枝处理

决策树--算法原理

➤ 剪枝

为了尽可能正确分类训练样本，有可能造成分支过多 → 过拟合

可通过主动去掉一些分支来降低过拟合的风险

基本策略：

- 预剪枝 (pre-pruning): 提前终止某些分支的生长
- 后剪枝 (post-pruning): 生成一棵完全树，再“回头”剪枝

剪枝过程中需评估剪枝前后决策树的优劣 → 第 2 章

现在我们假定使用“留出法”

决策树--算法原理

数据集

表 4.2 西瓜数据集 2.0 划分出的训练集(双线上部)与验证集(双线下部)


	编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
训练集	1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
	2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
	3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
	6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
	7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
	10	青绿	硬挺	清脆	清晰	平坦	软粘	否
	14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
	15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
	16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
	17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否
验证集	4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
	5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
	8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
	9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
	11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
	12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
	13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

神经网络

目录

- 准备知识
- 问题描述
- 感知器
- 深度神经网络
- 深度卷积神经网络

感知器--算法原理



感知器--算法原理

输入：训练样本 $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)$
新的测试样本 $\mathbf{x}$

初始化：随机权重向量 $\mathbf{w}$ ，学习率 η

对于所有 n 个训练样本，执行下面步骤

步骤一：计算感知器估计结果

$$\hat{y}_i = f(\sum_{j=0}^d w_j x_{i,j}) = f(\mathbf{w}^T \mathbf{x}_i)$$
$$i = 1, 2, \dots, n$$

感知器--算法原理

输入： 训练样本 $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)$
新的测试样本 $\mathbf{x}$

初始化： 随机权重向量 $\mathbf{w}$ ，学习率 η

对于所有 n 个训练样本，执行下面步骤

步骤二： 更新权重向量 $\mathbf{w}$

情况1： 如果 $y_i = \hat{y}_i$ ， 不更新 $\mathbf{w}$

情况2： 如果 $y_i \neq \hat{y}_i$ ， 更新 $\mathbf{w}$ 如下

$$\mathbf{w} = \mathbf{w} + \eta y_i \mathbf{x}_i$$

$$i = 1, 2, \dots, n$$

注： 有些文献采用 $\mathbf{w} = \mathbf{w} + \eta(y_i - \hat{y}_i)\mathbf{x}_i$

感知器--算法原理

输入： 训练样本 $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)$
新的测试样本 $\mathbf{x}$

初始化： 随机权重向量 $\mathbf{w}$ ，学习率 η

对于所有 n 个训练样本，执行下面步骤

步骤二： 更新权重向量 $\mathbf{w}$

$$\mathbf{w} = \mathbf{w} + \eta y_i \mathbf{x}_i \quad \{i: y_i \neq \hat{y}_i\}$$

重复上述步骤直到对于所有训练样本没有分类错误
或者达到一定的迭代次数

输出： 权重向量 $\mathbf{w}$

思考

◆ 知其然，知其所以然

人跟机器最大的不同在于，机器只能做到前者，而人可以却可以做到后者。

68

思考

➤ 情况1: $y_i = 1, \hat{y}_i = -1$

更新前:

$\hat{y}_i = \text{sign}(\mathbf{w}^T \mathbf{x}_i) = -1$, 这说明 $\mathbf{w}^T \mathbf{x}_i < 0$



更新后:

$$\begin{aligned}\hat{y}_i^{new} &= \text{sign}((\mathbf{w} + \eta y_i \mathbf{x}_i)^T \mathbf{x}_i) \\ &= \text{sign}(\mathbf{w}^T \mathbf{x}_i + \eta y_i \mathbf{x}_i^T \mathbf{x}_i) \\ &= \text{sign}(\mathbf{w}^T \mathbf{x}_i + \eta \|\mathbf{x}_i\|_2^2)\end{aligned}$$

可选择合适的学习率 η 使得

$$\mathbf{w}^T \mathbf{x}_i + \eta \|\mathbf{x}_i\|_2^2 > 0$$

则 $\hat{y}_i^{new} = 1 = y_i$, 分类正确。

69

思考

➤ 情况2: $y_i = -1$, $\hat{y}_i = 1$

更新前:

$\hat{y}_i = \text{sign}(\mathbf{w}^T \mathbf{x}_i) = 1$, 这说明 $\mathbf{w}^T \mathbf{x}_i > 0$



更新后:

$$\begin{aligned}\hat{y}_i^{new} &= \text{sign}((\mathbf{w} + \eta y_i \mathbf{x}_i)^T \mathbf{x}_i) \\ &= \text{sign}(\mathbf{w}^T \mathbf{x}_i + \eta y_i \mathbf{x}_i^T \mathbf{x}_i) \\ &= \text{sign}(\mathbf{w}^T \mathbf{x}_i - \eta \|\mathbf{x}_i\|_2^2)\end{aligned}$$

可选择合适的学习率 η 使得

$$\mathbf{w}^T \mathbf{x}_i - \eta \|\mathbf{x}_i\|_2^2 < 0$$

则 $\hat{y}_i^{new} = -1 = y_i$, 分类正确。

70

例子


某个神经元从其它4各神经元接受的输入分别为-1.33, 1.15, 0.3, -2.3。该神经元的4个连接权重值分别为0.8, 0.4, -1.2和0.6。计算下列几种情况下该神经元的输出:

- (1) 激活函数为 $f(x)=x$, 阈值为0.27。
- (2) 激活函数为Sigmoid函数, 阈值为0.27。

多类别感知器

多类别感知器 (Multiclass Perceptron)

感知器本质上是一个二分类算法，如何将其推广至多类别的模式分类问题呢？



72

多类别感知器


多类别感知器 (Multiclass Perceptron)

感知器本质上是一个二分类算法，如何将其推广至多类别的模式分类问题呢？

- ◆ 一对一 (One vs. One, OvO)
- ◆ 一对多 (One vs. Rest, OvR)


多类别感知器

◆ 一对一 (One vs. One, OvO)



多类别感知器


◆ 一对一 (One vs. One, OvO)



75

多类别感知器

◆ 一对一 (One vs. One, OvO)



76

多类别感知器

◆ 一对一 (One vs. One, OvO)

类别1



类别2




类别3



多类别感知器


◆ 一对一 (One vs. One, OvO)



78

多类别感知器


◆ 一对一 (One vs. One, OvO)



79

多类别感知器

◆ 一对一 (One vs. One, OvO)



80

多类别感知器

◆ 一对一 (One vs. One, OvO)

类别1



类别2




类别3



多类别感知器


◆ 一对一 (One vs. One, OvO)



82

多类别感知器


◆ 一对一 (One vs. One, OvO)



83

多类别感知器

◆ 一对一 (One vs. One, OvO)



84

多类别感知器

◆ 一对一 (One vs. One, OvO)



多类别感知器


多类别感知器 (Multiclass Perceptron)

感知器本质上是一个二分类算法，如何将其推广至多类别的模式分类问题呢？

- ◆ 一对一 (One vs. One, OvO)
- ◆ 一对多 (One vs. Rest, OvR)

多类别感知器


◆ 一对多 (One vs. Rest, OvR)



87

多类别感知器


◆ 一对多 (One vs. Rest, OvR)



88

多类别感知器

◆ 一对多 (One vs. Rest, OvR)



89

多类别感知器

◆ 一对多 (One vs. Rest, OvR)

1. 那怎么分类呢?


2. 还能像一对一的方法那样采用投票法吗?

3. 如果得出的分类结果为既是苹果又是香蕉怎么办?

90

多类别感知器

◆ 一对多 (One vs. Rest, OvR)



91

多类别感知器

◆ 一对多 (One vs. Rest, OvR)

类别1



类别2



类别3



$$w_1^T x$$

$$w_2^T x$$

$$w_3^T x$$

x



测试样本

识别为橙子

支持向量机

目录

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

支持向量机

最大间隔：寻找参数，使得间隔最大

如何得到
目标函数？

$$\max_{\mathbf{w} \in \mathbb{R}^d} \frac{2}{\|\mathbf{w}\|_2}, \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m \quad (6.5)$$

为什么
？

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{2} \|\mathbf{w}\|_2^2, \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m \quad (6.6)$$

凸二次规划问题，能用优化计算包求解，但可以有更高效的办法。

支持向量机-对偶问题

回到SVM目标函数:

$$\max_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{2} \|\mathbf{w}\|_2^2, \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m \quad (6.6)$$

$$\text{令 } f(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|_2^2, \quad g_i(\mathbf{w}, b) = 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b), \quad i = 1, \dots, m$$

由KKT条件可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$g_i(\mathbf{w}, b) \leq 0, \quad i = 1, \dots, m$$

$$\alpha_i \geq 0, \quad i = 1, \dots, m$$

$$\alpha_i g_i(\mathbf{w}, b) = 0, \quad i = 1, \dots, m$$

支持向量机-对偶问题

SVM对偶问题:

$$\max_{\alpha \in \mathbb{R}^m} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j, \quad (6.11)$$

如何得到?

$$\text{s. t.} \quad \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, m$$

凸二次规划问题，规模正比于样本个数 m 。为提升算法效率，可设计特定快速算法，如SMO (Sequential Minimal Optimization)算法[Platt,1998]。

支持向量机-核函数

设样本 $\mathbf{x}$ 映射后的向量 $\phi(\mathbf{x})$ ，划分超平面为 $f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b$

原始问题

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{2} \|\mathbf{w}\|_2^2, \text{ s.t. } y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, i = 1, \dots, m$$

对偶问题

$$\begin{aligned} \max_{\alpha \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j), \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, m \end{aligned}$$

只以内积形式出现

最终模型

$$f(\mathbf{x}) = \sum_{i=1}^m \alpha_i^* y_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b^*$$

支持向量机

硬间隔**SVM**目标函数:

$$\min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} \frac{1}{2} \|\mathbf{w}\|_2^2, \text{ s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, m$$

软间隔**SVM**目标函数:

$$\min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

当 $C \rightarrow +\infty$ 时, 软间隔**SVM**退化为硬间隔**SVM**。

支持向量机

原始问题

$$\min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)),$$

引入松弛变量 $\xi_i = \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$ ，上式可转化为

$$\begin{aligned} \min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \xi_i, \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, \dots, m \end{aligned}$$

支持向量机

对偶问题

$$\begin{aligned} \max_{\alpha \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s. t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, i = 1, \dots, m \end{aligned}$$

与“硬间隔SVM”的区别

同样地，当 $C \rightarrow +\infty$ 时，软间隔SVM对偶问题退化为硬间隔SVM对偶问题。

由KKT条件可知，最终模型仅与支持向量有关，即仍保持了SVM解的稀疏性。



朴素贝叶斯分类器

朴素贝叶斯分类器

➤ 朴素贝叶斯分类器 (Naïve Bayes Classifier)

假设属性相互条件独立

基于贝叶斯思想的分类方法

朴素贝叶斯分类器

例3：西瓜分类

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

- 问题1：对于一个新瓜，色泽为“乌黑”，如何用朴素贝叶斯分类器判断它是否为好瓜？

朴素贝叶斯分类器

➤ 例3：西瓜分类

为方便表达，记 x 为色泽为“乌黑”新测试样本， c 为类别， $c = 1$ 表示好瓜， $c = 2$ 表示坏瓜。

$$P(c|\mathbf{x}) = P(c) \frac{P(\mathbf{x}|c)}{P(\mathbf{x})}$$

□ 估计 $P(c)$ $P(c = 1) = \frac{8}{17}$ $P(c = 2) = \frac{9}{17}$

□ 估计 $P(\mathbf{x}|c)$ $P(\mathbf{x}|c = 1) = \frac{4}{8} = \frac{1}{2}$ $P(\mathbf{x}|c = 2) = \frac{2}{9}$

□ 估计 $P(\mathbf{x})$ $P(\mathbf{x}) = \frac{6}{17}$

□ 估计 $P(c|\mathbf{x})$ $P(c = 1|\mathbf{x}) = P(c = 1) \frac{P(\mathbf{x}|c = 1)}{P(\mathbf{x})} = \frac{8}{17} \times \frac{1}{2} \times \frac{17}{6} = \frac{2}{3}$
 $P(c = 2|\mathbf{x}) = 1 - P(c = 1|\mathbf{x}) = \frac{1}{3}$ 因此识别 x 为好瓜！

朴素贝叶斯分类器

➤ 例3：西瓜分类

- 问题2：对于一个色泽为“乌黑”，根蒂为“蜷缩”的新瓜，如何用朴素贝叶斯分类器判断它是否为好瓜？

为方便表达，记 $\mathbf{x} = (x_1, x_2)$ 为新测试样本， x_1 表示色泽属性为“乌黑”， x_2 表示根蒂属性为“蜷缩”。

□ 估计 $P(c)$ $P(c = 1) = \frac{8}{17}$ $P(c = 2) = \frac{9}{17}$

□ 估计 $P(\mathbf{x}|c)$ $P(\mathbf{x}|c = 1) = P(x_1|c = 1)P(x_2|c = 1) = \frac{4}{8} \times \frac{5}{8} = \frac{5}{16}$
 $P(\mathbf{x}|c = 2) = P(x_1|c = 2)P(x_2|c = 2) = \frac{2}{9} \times \frac{3}{9} = \frac{2}{27}$

□ 估计 $P(\mathbf{x})$ $P(\mathbf{x}) = \sum_{c=1}^2 P(\mathbf{x}|c)P(c) = \frac{19}{102}$

朴素贝叶斯分类器

➤ 例3：西瓜分类

- 问题2：对于一个色泽为“乌黑”，根蒂为“蜷缩”的新瓜，如何用朴素贝叶斯分类器判断它是否为好瓜？

为方便表达，记 $\mathbf{x} = (x_1, x_2)$ 为新测试样本， x_1 表示色泽属性为“乌黑”， x_2 表示根蒂属性为“蜷缩”。

□ 估计 $P(c|\mathbf{x})$

$$P(c = 1|\mathbf{x}) = P(c = 1) \frac{P(\mathbf{x}|c = 1)}{P(\mathbf{x})} = \frac{8}{17} \times \frac{5}{16} \times \frac{102}{19} = \frac{15}{19}$$

$$P(c = 2|\mathbf{x}) = 1 - P(c = 1|\mathbf{x}) = \frac{4}{19}$$

因此识别 x 为好瓜！

朴素贝叶斯分类器

➤ 例3：西瓜分类

- 问题3：对于一个色泽为“乌黑”，根蒂为“稍蜷”的新瓜，如何用朴素贝叶斯分类器判断它是否为好瓜？
- 问题4：对于一个色泽为“乌黑”，根蒂为“稍蜷”，敲声为“清脆”的新瓜，如何用朴素贝叶斯分类器判断它是否为好瓜？

请自行完成。

朴素贝叶斯分类器

➤ 拉普拉斯修正 (Laplacian correction)

若某个属性值在训练集中没有与某个类同时出现过，则直接计算会出现问题，因为概率连乘将“抹去”其他属性提供的信息

例如，若训练集中未出现“敲声=清脆”的好瓜

令 K 表示训练集 D 中可能的类别数， N_i 表示第 i 个属性可能的取值数

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + K} \quad \hat{P}(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

朴素贝叶斯分类器

➤ 例3：西瓜分类

- 问题4：对于一个色泽为“乌黑”，根蒂为“稍蜷”，敲声为“清脆”的新瓜，如何用朴素贝叶斯分类器判断它是否为好瓜？

修正前：

$$P(c = 1) = \frac{8}{17} \quad P(c = 2) = \frac{9}{17}$$

$$P(x_3|c = 1) = 0 \quad P(x_3|c = 2) = \frac{2}{9}$$

修正后：

$$\hat{P}(c = 1) = \frac{8 + 1}{17 + 2} = \frac{9}{19} \quad \hat{P}(c = 2) = \frac{9 + 1}{17 + 2} = \frac{10}{19}$$

$$\hat{P}(x_3|c = 1) = \frac{0 + 1}{8 + 3} = \frac{1}{11} \quad \hat{P}(x_3|c = 2) = \frac{2 + 1}{9 + 3} = \frac{1}{4}$$

集成学习

目录

- 个体与集成
- Boosting
- Bagging与随机森林

集成学习

➤ 有哪些成功的集成学习方法？

▪ 序列化方法

- **AdaBoost** [Freund & Schapire, JCSS97]
- GradientBoost [Friedman, AnnStat01]
- LPBoost [Demiriz, Bennett, Shawe-Taylor, MLJ06]
-

▪ 并行化方法

- **Bagging** [Breiman, MLJ96]
- Random Forest [Breiman, MLJ01]
- Random Subspace [Ho, TPAMI98]
-

113

AdaBoost

➤ AdaBoost

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

1: $\mathcal{D}_1(\mathbf{x}) = 1/m$.

2: **for** $t = 1, 2, \dots, T$ **do**

3: $h_t = \mathcal{L}(D, \mathcal{D}_t)$;

4: $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$;

5: **if** $\epsilon_t > 0.5$ **then break**

6: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$;

7:
$$\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$$
$$= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$$

8: **end for**

输出: $H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

AdaBoost算法

➤ AdaBoost优缺点

优点Strengths	缺点Weaknesses
参数少	需要设置停止条件
易实现	对噪声和异常值敏感（为什么？）
不易过拟合（当噪声较小）	不能直接处理多分类问题
不需要先验信息	依赖于基学习器的性能

Bagging


➤ Bagging算法



Bagging

➤ 自助法 (bootstrapping, 有放回采样)

自助法也被称为有放回采样。给定包含 m 个样本的数据集 D ，我们对它进行采样产生数据集 D' ：每次随机从 D 中挑选一个样本，将其拷贝放入，这就是自助采样的结果。



Bagging

➤ Bagging算法

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

1: **for** $t = 1, 2, \dots, T$ **do**
2: $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$
3: **end for**

输出: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y)$

$\mathcal{D}_{bs}$ 为采用自助法采样(bootstrap sampling)产生的样本分布。

集成学习

RF 主要特性

- 生成完全不同的树:
 - 训练集生成: 随机 bootstrap 样本
 - 属性结点: 随机变量的子集
- 属性 (变量) 的数量
 - 平方根 (K)
 - K: 总的变量个数
 - 可以极大地加快建树过程。
- 树的数目
 - 500 或者更多
- 自我测试
 - 大约有一分之一的原始数据被遗漏了
 - Out of Bag (OOB)
 - 相似于交叉验证 (Cross-Validation)

集成学习

RF 优点

- 所有数据都可以用来训练
 - 不需要留下一些数据进行测试。
 - 无需进行常规交叉验证。
 - OOB中的数据用于评估当前树。
- 整个随机森林RF的性能
 - 取决于它是否在OOB中。
- 高水平的预测精度
 - 需要调整的参数很少
 - 适用于分类和回归
- 避免过训练（过拟合）。
- 不需要做特征选择。

聚类

目录

- 聚类分析概述
- K-均值聚类方法
- K-中心点聚类方法
- 层次聚类方法
- 基于密度的方法

降维与度量学习

目录

- 降维概述
- 主成分分析
- 核化线性降维
- 流形学习

谢 谢!