

模型评估和选择

目录

- 经验误差与过拟合 (Empirical error & overfitting)
- 评估方法 (Evaluation method)
- 性能度量 (Performance measure)
- 偏差与方差 (Bias and Variance)



经验误差与 过拟合

泛化误差和经验误差

经验误差 (Empirical Error) :

学习器 f 在训练集 $\{(x_i, y_i), i = 1, \dots, m\}$ 上的误差

$$R_{emp}(f) = \frac{1}{m} \sum_{i=1}^m L(f(x_i), y_i)$$

泛化误差 (Generalization Error) :

学习器 f 在“未来”样本上的误差


$$R(f) = \mathbb{E}[L(f(x), y)] = \int L(f(x), y) dP(x, y)$$

经验误差是不是越小越好?

No!

可能会出现过拟合


泛化误差和经验误差



- 欠拟合：相较于数据而言，模型参数过少或者模型结构过于简单，以至于无法捕捉到数据中的规律的现象。
- 过拟合：模型过于紧密或精确地匹配特定数据集，以至于无法良好地拟合其他数据或预测未来的观察结果的现象。
- 合适的拟合：模型能够恰当地拟合和捕捉到数据中规律的现象。

过拟合和欠拟合

- 模型的学习过程实际是学习的训练数据的特征，数据特征中有的是一般性的，有的是特殊性的。
- 随着训练过程的持续，为了提升精度，模型不可避免地会把特殊特征作为预测指标，这样就导致泛化性下降，泛化误差提高，我们称这种现象叫过拟合。



过拟合和欠拟合





评估方法

评估方法

- 留出法 (hold-out)
- 交叉验证法 (Cross validation)
- 自助法 (Bootstrapping)
- 调参与最终模型 (Parameter tuning and final model)

评估方法

➤ 留出法 (hold-out)

留出法直接将数据集 D 划分为两个互斥的集合，分别为训练集 S 和测试集 T 。在 S 上训练出模型后，用 T 来评估其测试误差。

以二分类为例，假设 D 包含1000个样本，将其划分为 S 包含700个样本， T 包含300个样本。用 S 训练后，如果模型在 T 上有90个样本分类错误，则错误率为

$$(90/300) \times 100\% = 30\%$$

评估方法

➤ 留出法 (hold-out)

以课本84页的西瓜数据集3.0为例

该数据集中，如果使用前12条样本为S，后5条样本为T，则我们称该数据集按12/17=70.5%划分训练集。


如果在T上测试，对了4条错了1条，则称该模型错误率为20%

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

评估方法

➤ 交叉验证法 (Cross Validation)

训练样本 Training samples



评估方法

➤ 交叉验证法

验证集合
Validation
Set

训练样本 Training samples



评估方法

➤ 交叉验证法

验证集合
Validation
Set

训练样本 Training samples



评估方法

➤ 交叉验证法

验证集合
Validation
Set

训练样本 Training samples




评估方法

➤ 交叉验证法

验证集合
Validation
Set

训练样本 Training samples



评估方法

➤ 交叉验证法

验证集合
Validation
Set

训练样本 Training samples



评估方法

➤ 交叉验证法

例如：

假设某个学习算法在四个验证集合上的识别率分别


50%, 100%, 50%, 50%,

则平均识别率为62.5%

评估方法

➤ 自助法 (bootstrapping, 有放回采样)

自助法也被称为有放回采样。给定包含 m 个样本的数据集 D ，我们对它进行采样产生数据集 D' ：每次随机从 D 中挑选一个样本，将其拷贝放入，这就是自助采样的结果。



评估方法

➤ 自助法 (bootstrapping, 有放回采样)

假设采用均匀采样, 每次采样某个样本未被采样的概率为 $1 - \frac{1}{m}$, 重复 m 次采样, 该样本仍未被采样的概率为 $\left(1 - \frac{1}{m}\right)^m$, 取极限得到


$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m = \frac{1}{e} \approx 0.368$$

因此, 通过自助法, 初始数据集 D 中约有 36.8% 的样本未被采样到数据集 D' 中。

评估方法


➤ 调参与最终模型


大多数学习算法都有些参数(parameter)需要设定, 如KNN算法中的邻近数K, DNN中的学习率等。在实际应用中, 既要选择合适的学习算法, 也要设定合适的参数, 也被称为参数调节, 或简称为调参(parameter tuning)。



评估方法

➤ 调参与最终模型





性能度量

性能度量

- 错误率与精度
- 查准率、查全率与F1
- ROC与AUC
- 代价敏感错误率与代价曲线

性能度量

➤ 错误率与精度

- 错误率:

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) \neq y_i)$$

- 精度:

$$\begin{aligned} \text{acc}(f; D) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) = y_i) \\ &= 1 - E(f; D) \end{aligned}$$

性能度量


➤ 查准率、查全率与F1

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)


- 查准率: $P = \frac{TP}{TP + FP}$
- 查全率: $R = \frac{TP}{TP + FN}$
- F1: $F1 = \frac{2 \times P \times R}{P + R}$

真实情况: 左正右负
分类结果: 内正外负



性能度量

➤ 例：垃圾邮件识别



- 真正例 (TP): 7
- 假正例 (FP): 1
- 假反例 (FN): 4
- 真反例 (TN): 18
- 查准率: $P = \frac{TP}{TP + FP} = \frac{7}{7 + 1} \approx 0.88$
- 查全率: $R = \frac{TP}{TP + FN} = \frac{7}{7 + 4} \approx 0.64$

性能度量

已知西瓜数据集如图所示，请计算该数据集的混淆矩阵、查准率（准确率）、查全率（召回率）和分类精度。

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜	预测
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是	✓
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是	✓
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是	×
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是	✓
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是	✓
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是	×
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是	✓
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是	✓
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否	×
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否	✓
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否	✓
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否	×
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否	×
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否	✓
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否	×
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否	×
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否	×

性能度量

➤ ROC与AUC

- ROC (Receiver Operating Characteristic)

中文翻译为受试者工作特征，最早源于“二战”中用于敌机检测的雷达信号分析技术，之后被引入机器学习领域。

表 2.1 分类结果混淆矩阵


真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

- 真正例率: $TPR = \frac{TP}{TP + FN}$
- 假正例率: $FPR = \frac{FP}{FP + TN}$

性能度量

➤ ROC与AUC


- ROC (Receiver Operating Characteristic)



性能度量


➤ ROC与AUC

- AUC (Area Under ROC Curve): ROC曲线下面的面积。



性能度量

➤ 例：垃圾邮件识别



- 真正例 (TP): 7
- 假正例 (FP): 1
- 假反例 (FN): 4
- 真反例 (TN): 18
- 真正例率: $TPR = \frac{TP}{TP + FN} = \frac{7}{7 + 4} \approx 0.64$
- 假正例率: $FPR = \frac{FP}{TN + FP} = \frac{1}{18 + 1} \approx 0.05$

性能度量

➤ 代价敏感错误率与代价曲线

不同错误不同代价：如门禁系统错误地将小区居民识别为陌生人和将陌生人错误地识别为该小区居民。

$$E(f; D; cost) = \frac{1}{m} \left(\sum_{x_i \in D^+} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{01} + \sum_{x_i \in D^-} \mathbb{I}(f(\mathbf{x}_i) \neq y_i) \times cost_{10} \right)$$

- D^+ : 样例集 D 的正例子集
- D^- : 样例集 D 的负例子集
- $cost_{01}$: 将负例样本预测为正例样本的代价
- $cost_{10}$: 将正例样本预测为负例样本的代价



偏差和方差

偏差-方差分解

偏差: **bias**, 方差: **variance**

对回归任务, 泛化误差可通过“偏差-方差分解”拆解为:

$$E(f; D) = \underbrace{bias^2(x)}_{\text{期望输出与真实输出的差别}} + \underbrace{var(x)}_{\text{同样大小的训练集的变动, 所导致的性能变化}} + \underbrace{\varepsilon^2}_{\text{训练样本的标记与真实标记有区别}}$$

$bias^2(x) = (\bar{f}(x) - y)^2$

$var(x) = \mathbb{E}_D \left[(f(x; D) - \bar{f}(x))^2 \right]$

$\varepsilon^2 = \mathbb{E}_D \left[(y_D - y)^2 \right]$


表达了当前任务上任何学习算法所能达到的期望泛化误差下界

泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度共同决定

37

偏差-方差分解


偏差: bias, 方差: variance



- 偏差: 假设空间中能找到的最接近目标 f_* 的函数 $\bar{f}$, 与目标 f_* 的差异
- 方差: 模型基于数据集 D 找到的函数 f_D 与 $\bar{f}$ 的差异

偏差-方差分解

偏差: bias, 方差: variances



偏差-方差分解

偏差: bias, 方差: variances

一般而言, 偏差与方差存在冲突:

- 训练不足时, 学习器拟合能力不强, 偏差主导
- 随着训练程度加深, 学习器拟合能力逐渐增强, 方差逐渐主导
- 训练充足后, 学习器的拟合能力很强, 方差主导




图 2.9 泛化误差与偏差、方差的关系示意图

谢 谢!