

特征选择与稀疏学习

特征


□ 特征

- 描述物体的属性

□ 特征的分类

- 相关特征：对当前学习任务有用的属性
- 无关特征：与当前学习任务无关的属性
- 冗余特征：其所包含信息能够由其他特征推演出来

举例：西瓜的特征



特征选择


□ 特征选择

- 从给定的特征集合中选出**任务相关**特征子集
- 必须确保不丢失重要特征

□ 原因

- 减轻维度灾难：在少量属性上构建模型
- 降低学习难度：留下关键信息

举例：判断是否好瓜时的特征选择



特征选择的一般方法

❑ 遍历所有可能的子集

- 计算上遭遇组合爆炸，不可行

❑ 可行方法



两个关键环节：子集搜索和子集评价


子集搜索

用贪心策略选择包含重要信息的特征子集

- 前向搜索：逐渐增加相关特征
- 后向搜索：从完整的特征集合开始，逐渐减少特征
- 双向搜索：每一轮逐渐增加相关特征，同时减少无关特征

前向搜索

- 最优子集初始为空集，特征集合初始时包括所有给定特征



子集评价

- 特征子集确定了对数据集的一个划分
 - 每个划分区域对应着特征子集的某种取值
- 样本标记对应着对数据集的真实划分

通过估算这两个划分的差异，就能对特征子集进行评价；与样本标记对应的划分的差异越小，则说明当前特征子集越好

用信息熵进行子集评价

□ 特征子集 A 确定了对数据集的 D 一个划分

- A 上的取值将数据集 D 分为 V 份，每一份用 D^v 表示
- $\text{Ent}(D^v)$ 表示 D^v 上的信息熵

□ 样本标记 Y 对应着对数据集 D 的真实划分

- $\text{Ent}(D)$ 表示 D 上的信息熵

D 上的信息熵定义为

$$\text{Ent}(D) = - \sum_{i=1}^{|Y|} p_k \log_2 p_k$$

第 i 类样本所占比例为 p_i

特征子集 A 的信息增益为：

$$\text{Gain}(A) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

常见的特征选择方法

将特征子集搜索机制与子集评价机制相结合，即可得到特征选择方法

常见的特征选择方法大致分为如下三类：

- 过滤式
- 包裹式
- 嵌入式

过滤式选择

先用特征选择过程过滤原始数据，再用过滤后的特征来训练模型；特征选择过程与后续学习器无关

□ Relief (Relevant Features) 方法[Kira and Rendell, 1992]

- 为每个初始特征赋予一个“**相关统计量**”，度量特征的重要性
- 特征子集的重要性由子集中每个特征所对应的相关统计量之和决定
- 设计一个阈值，然后选择比阈值大的相关统计量分量所对应的特征
- 或者指定欲选取的特征个数，然后选择相关统计量分量最大的指定个数特征

如何确定相关统计量？

Relief方法中相关统计量的确定

- 猜中近邻 (near-hit): x_i 的同类样本中的最近邻 $x_{i,nh}$
- 猜错近邻 (near-miss): x_i 的异类样本中的最近邻 $x_{i,nm}$
- 相关统计量对应于属性 j 的份量为

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

若 j 为离散型, 则 $x_a^j = x_b^j$ 时
 $\text{diff}(x_a^j, x_b^j) = 0$, 否则为 1;

若 j 为连续型, 则
 $\text{diff}(x_a^j, x_b^j) = |x_a^j - x_b^j|$, 注意 x_a^j
, x_b^j 已经规范化到 $[0,1]$ 区间

- 相关统计量越大, 属性 j 上猜对近邻比猜错近邻越近, 即属性 j 对区分对错越有用
- Relief方法的时间开销随采样次数以及原始特征数呈线性增长, 运行效率很高

Relief方法的多类拓展

Relief方法是为二分类问题设计的，其扩展变体Relief-F[Knnonenko,1994]能处理多分类问题

- 数据集中的样本来自 $|y|$ 个类别，其中 x_i 属于第 k 类
- 猜中近邻：第 k 类中的 x_i 的同类样本中的最近邻 $x_{i,nh}$
- 猜错近邻：第 k 类之外的每个类中找到一个 x_i 的最近邻作为猜错近邻 $x_{i,l,nm}$ ($l = 1, 2, \dots, |y|; l \neq k$)
- 相关统计量对应于属性的份量为

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \sum_{l \neq k} (p_l \times \text{diff}(x_i^j, x_{i,nm}^j)^2)$$

p_l 为第 l 类样本在数据集 D 所占的比例

包裹式选择

包裹式选择直接把最终将要使用的学习器的性能作为特征子集的评价准则

- 包裹式特征选择的目的是为给定学习器选择最有利其性能、“量身定做”的特征子集
- 包裹式特征选择方法直接针对给定学习器进行优化，因此从最终学习器性能来看，包裹式特征选择比过滤式特征选择更好
- 包裹式特征选择过程中需多次训练学习器，计算开销通常比过滤式特征选择大得多

LVW包裹式特征选择方法

LVW (Las Vegas Wrapper) [Liu and Setiono, 1996] 在拉斯维加斯方法框架下使用随即策略来进行子集搜索，并以最终分类器的误差作为特征子集评价准则

基本步骤

- 在循环的每一轮随机产生一个特征子集
- 在随机产生的特征子集上通过交叉验证推断当前特征子集的误差
- 进行多次循环，在多个随机产生的特征子集中选择误差最小的特征子集作为最终解

嵌入式选择

嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，在学习器训练过程中自动地进行特征选择

- 考虑最简单的线性回归模型，以平方误差为损失函数，并引入 L_2 范数正则化项防止过拟合，则有

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2$$


岭回归 (ridge regression)
[Tikhonov and Arsenin, 1977]

- 将 L_2 范数替换为 L_1 范数，则有**LASSO** [Tibshirani, 1996]

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_1$$

易获得稀疏解，是一种嵌入式特征选择方法

使用 L_1 范数正则化易获得稀疏解



假设 $\mathbf{x}$ 仅有两个属性, 那么 $\mathbf{w}$ 有两个分量 w_1 和 w_2 . 那么目标优化的解要在平方误差项与正则化项之间折中, 即出现在图中平方误差项等值线与正则化等值线相交处.

从图中看出, 采用 L_1 范数时交点常出现在坐标轴上, 即产生 w_1 或者 w_2 为0的稀疏解.

等值线即取值相同的点的连线

L₁正则化问题的求解(1)

$$\min_{\mathbf{x}} f(\mathbf{x}) + \lambda \|\mathbf{x}\|_1$$

近端梯度下降 (Proximal Gradient Descend, 简称PGD) 解法
[Boyd and Vandenberghe, 2004]

□ 写出 $f(\mathbf{x})$ 的二阶泰勒展式

$$f(\mathbf{x}) = f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \rangle + \frac{1}{2}(\mathbf{x} - \mathbf{x}_k)^\top \frac{\delta^2 f(\mathbf{x}_k)}{\delta \mathbf{x}_k^2} (\mathbf{x} - \mathbf{x}_k)$$

□ 假设 $f(\mathbf{x})$ 满足L-Lipschitz条件, 即存在常数 $L > 0$, 使得

$$\|\nabla f(\mathbf{x}') - \nabla f(\mathbf{x})\| \leq L \|\mathbf{x}' - \mathbf{x}\|_2$$

L1正则化问题的求解(2)

□ L-Lipschitz条件代入泰勒展式, 可得

$$\begin{aligned} f(\mathbf{x}) &\cong f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{x}_k\|^2 \\ &= \frac{L}{2} \|\mathbf{x} - (\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k))\|^2 + \text{const} \end{aligned}$$

□ 将上式关于 $f(\mathbf{x})$ 的近似代入到原优化问题中, 得

$$\min_{\mathbf{x}} \sum_{i=1}^m \frac{L}{2} \|\mathbf{x} - (\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k))\|^2 + \lambda \|\mathbf{x}\|_1$$

L1正则化问题的求解(3)

□ 每次在 $\mathbf{x}_k$ 的附近寻找最优点，不断迭代，即寻找

$$\mathbf{x}_{k+1} = \min_{\mathbf{x}} \sum_{i=1}^n \frac{L}{2} \|\mathbf{x} - (\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k))\|^2 + \lambda \|\mathbf{x}\|_1$$

□ 假设 $\mathbf{z} = \mathbf{x}_k - 1/L \nabla f(\mathbf{x}_k)$ ，上式有闭式解

$$\mathbf{x}_{k+1}^i = \begin{cases} z^i - \frac{\lambda}{L}, & z^i > \frac{\lambda}{L} \\ 0, & |z^i| \leq \frac{\lambda}{L} \\ z^i + \frac{\lambda}{L}, & z^i \leq -\frac{\lambda}{L} \end{cases}$$

- 1.简述查准率和查全率的计算方法和具体意义。
- 2.说明什么是有监督学习和无监督学习，并各举一个算法例子。
- 3.简述层次聚类的原理及其相关应用。
- 4.分析如何利用集成学习策略提升单个弱分类器如决策树的性能。
- 5.说明什么是主成分分析和线性判别分析，并比较它们的不同点。

稀疏表示

- 将数据集考虑成一个矩阵，每一行对应一个样本，每一列对应一个特征
- 矩阵中有很多零元素，且非整行整列出现
- 稀疏表达的优势：
 - 文本数据线性可分
 - 存储高效

能否将稠密表示的数据集转化为“稀疏表示”，使其享受稀疏表达的优势？

字典学习

为普通稠密表达的样本找到合适的**字典**，将样本转化为稀疏表示，这一过程称为**字典学习**

- 给定数据集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, $\mathbf{x}_i \in \mathbb{R}^d$
- 学习目标是字典矩阵 $\mathbf{B} \in \mathbb{R}^{d \times k}$ 以及样本的稀疏表示 $\boldsymbol{\alpha}_i \in \mathbb{R}^k$
- k 称为字典的词汇量，通常由用户指定
- 则最简单的字典学习的优化形式为

$$\min_{\mathbf{B}, \boldsymbol{\alpha}_i} \sum_{i=1}^m \|\mathbf{x}_i - \mathbf{B}\boldsymbol{\alpha}_i\|_2^2 + \lambda \sum_{i=1}^m \|\boldsymbol{\alpha}_i\|_1$$

字典学习的解法(1)

- 固定字典 $\mathbf{B}$, 参考LASSO的方法求解

$$\min_{a_i} \| \mathbf{x}_i - \mathbf{B} a_i \|_2^2 + \lambda \| a_i \|_1$$

- 以 a_i 为初值求解字典 $\mathbf{B}$,

$$\min_{\mathbf{B}} \| \mathbf{X} - \mathbf{B} \mathbf{A} \|_F^2$$

$\| \cdot \|$ 是矩阵的Frobenius 范数

$$\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m) \in \mathbb{R}^{d \times m}$$

$$\mathbf{A} = (a_1, a_2, \dots, a_m) \in \mathbb{R}^{k \times m}$$

- 基于逐列更新策略的KSVD [Aharon et al., 2006]

$$\min_{b_i} \left\| \mathbf{X} - \sum_{j=1}^k \mathbf{b}_j \alpha^j \right\|_F^2$$

$\mathbf{b}_j$ 表示字典矩阵 $\mathbf{B}$ 的第 j 列, α^j 表示稀疏矩阵 $\mathbf{A}$ 的第 j 行

字典学习的解法(2)

□ 上式可以变化为

$$\min_{b_i} \left\| \left(X - \sum_{j \neq i} b_j \alpha^j \right) - b_i \alpha^i \right\|_F^2 = \min_{b_i} \|E_i - b_i \alpha^i\|_F^2$$


□ 对 E_i 进行奇异值分解，取得最大奇异值对应的正交向量

为了不破坏 A 的稀疏性， α^i 仅保留非零元素， E_i 仅保留 b_i 与 α^i 非零元素的乘积项

□ 反复迭代以获得最优解

压缩感知

传统的信号处理过程



1. 根据 Nyquist-Shannon 采样定律，采样速率需达到信号带宽的两倍以上才能精确重构信号。而现实生活中，随着信息技术的高速发展，信息量的需求增加，携带信息的信号所占带宽也越来越大，因此对采样的硬件设备的要求也越来越高。

2. 为了降低存储、处理和传输的成本，人们常采用压缩方式以较少的比特数表示信号，大量的非重要的数据被抛弃。这种高速采样再压缩的过程浪费了大量的采样资源。

压缩感知

能否利用部分数据恢复全部数据？

- 大部分冗余信息在采集后被丢弃采样时造成很大的资源浪费能否直接采集不被丢弃的信息？
- 数据传输中，能否利用接收到的压缩、丢包后的数字信号，精确重构出原信号？
- 压缩感知 (**compressive sensing**) [Cándes et al., 2006, Donoho, 2006] 为解决此类问题提供了新的思路.

压缩感知



名词解释： 压缩感知—**直接**感知压缩后的信息

基本方法： 信号在某一个正交空间具有稀疏性（**即可压缩性**），就能以较低的频率（**远低于奈奎斯特采样频率**）采样该信号，并可能以高概率重建该信号。

压缩感知



2006 《Robust Uncertainty Principles:
Exact Signal Reconstruction from
Highly Incomplete Frequency
Information》

Terence Tao、Emmanuel Candès



2006 《Compressed Sensing》David Donoho



2007 《Compressive Sensing》Richard
Baraniuk


上述文章奠定了压缩感知的理论基础。
国内也将其翻译成**压缩传感**或**压缩采样**。

压缩感知

基本思想：

- 1. 信号是可压缩的或者在某个变换域是稀疏的；
- 2. 用一个与变换基不相关的观测矩阵将变换所得的高维信号投影到一个低维空间上；
- 3. 通过求解一个优化问题从这些少量的投影中以高概率重构出原信号。

压缩感知




x-原始信号
 Ψ -稀疏基
s-x的稀疏表示
 Φ -观测矩阵
 Θ -感知矩阵
y-测量所得向量

压缩感知

2维小波变换




原始图片



三层小波分解

小波分析可以对自然图像进行稀疏分解

压缩感知



(a) 具有（随机高斯）测量矩阵 Φ 和离散余弦变换（DCT）矩阵 Ψ 的压缩感测测量过程。系数向量 s 在 $K=4$ 时是稀疏的。(b) 矩阵乘积 $\Theta = \Phi \Psi$ 的测量过程与对应于非零的四列被突出显示。测量矢量 y 是这四列的线性组合。

$$y = \Phi x = \Phi \Psi s = \Theta s$$

$$x = \Psi s$$

- 长度为 m 的离散信号 x ，用远小于奈奎斯特采样定理的要求的采样率采样得到长度为 n 的采样后信号 y ， $n \ll m$ ，即

$$y = \Phi x$$

- 一般情况下， $n \ll m$ ，不能利用 y 还原 x ，但是
- 若存在某个线性变换 Ψ ，使得 $x = \Psi s$ ， s 是稀疏向量，即

$$y = \Phi \Psi s = A s$$

如傅里叶变换，余弦变换，小波变换等

A 具有“限定等距性”时，可以近乎完美地恢复 s

限定等距性

限定等距性 (Restricted Isometry Property, 即RIP) [Cándes, 2008]: $\mathbf{A} \in \mathbb{R}^{n \times m}$, 若存在常数 $\delta_k \in (0,1)$ 使得对于任意向量 $\mathbf{s}$ 和 $\mathbf{A}$ 的所有子矩阵 $\mathbf{A}_k \in \mathbb{R}^{n \times k}$ 有

$$(1 - \delta_k) \|\mathbf{s}\|_2^2 \leq \|\mathbf{A}_k \mathbf{s}\|_2^2 \leq (1 + \delta_k) \|\mathbf{s}\|_2^2$$

则称 $\mathbf{A}$ 满足 **k -限定等距性** (k -RIP)

压缩感知的优化目标和解法

若 $\mathbf{A}$ 满足 k 限定等距性，则可通过下面的优化问题近乎完美地从 $\mathbf{y}$ 中恢复出稀疏信号 $\mathbf{s}$ ，进而恢复出 $\mathbf{x}$ ：

$$\begin{aligned} \min_{\mathbf{s}} \|\mathbf{s}\|_0 \\ \text{s.t. } \mathbf{y} = \mathbf{A}\mathbf{s} \end{aligned}$$

□ L_0 范数最小化是NP难问题，将上式转化为共解的 L_1 范数最小化问题 [Cándes et al., 2006]：


$$\begin{aligned} \min_{\mathbf{s}} \|\mathbf{s}\|_1 \\ \text{s.t. } \mathbf{y} = \mathbf{A}\mathbf{s} \end{aligned}$$

□ 转化为LASSO的等价形式再通过近端梯度下降法求解，即使用 “基寻踪去噪” (Basis Pursuit De-Noising) [Chen et al., 1998]

压缩感知的优化目标和解法

压缩感知的求解：转化为0范数优化问题。

$$Y = \Phi X \implies \min \|X\|_0, \text{ s.t. } \|Y - \Phi X\|_2 \leq \xi$$




$$(1 - \delta_K) \leq \frac{\|\Phi x\|_2^2}{\|x\|_2^2} \leq (1 + \delta_K)$$

Candes, Tao (2006)

L0和L1等价性

$$\min \|X\|_1, \text{ s.t. } \|Y - \Phi X\|_2 \leq \xi$$




2GB数据量

迭代次数 优化方法	稀疏采样/全采样	
	50%	10%
0范数优化	10^3 亿	$10^{1.4}$ 亿
1范数优化	10^6	10^6


压缩感知

- 引入随机投影于监督学习算法研究，提出了基于随机投影的学习问题。



稀疏微波成像

微波成像典型系统复杂度





目前数传链路容量为100Mbps量级, 未来雷达卫星数据率将达到10Gbps量级。

稀疏微波成像


合成孔径雷达:

平台匀速直线运动，发射/接收电磁波，对地高分辨成像。



二维卷积成像


稀疏微波成像



稀疏微波成像 (Sparse Microwave Imaging)：基于压缩感知理论，利用观测的稀疏性，构建全新的微波成像系统，采集较少的数据，降低系统的复杂度，实现微波高分辨率成像。

微波成像的新概念、新理论、新体制、新方法

稀疏微波成像



稀疏微波成像模型

稀疏微波成像

提出稀疏微波成像Lq正则化算法

$$\hat{\mathbf{X}}_s = \left\{ \min |\alpha|_q \quad s.t. \quad \|\mathbf{Y}_s - \Phi \cdot \mathbf{X}\|_2 \leq \xi, \quad 0 < q \leq 1 \right\}$$


稀疏基

稀疏矢量的估计

进行稀疏矢量估计的Lq正则化算法

- 阈值迭代法
- 正交匹配跟踪法 (OMP)
- Laplace算法
-

稀疏微波成像



SCIENCE CHINA Information Sciences
**Efficient DPCA SAR imaging with fast iterative
spectrum reconstruction method**

本章小结

□ 特征选择：子集选择、子集评价

- 过滤式选择
- 包裹式选择
- 嵌入式选择：用 L_1 正则化

□ 稀疏表示

- 字典学习
- 压缩感知

谢 谢!