


绪论



背景知识

机器学习

机器学习的定义




机器学习

- What is machine learning?

(1) Arthur Samuel (1959): Fields of study that gives computers the ability to learn without being explicitly programmed.

机器学习是这样的领域，它赋予计算机学习的能力，
(这种学习能力) 不是通过显著式编程获得的。




机器学习

- 什么的“显著式编程”？



机器学习

■ 什么的“显著式编程”？



机器学习

■ 什么是机器学习？

让计算机自己总结菊花和玫瑰的区别。

计算机很有可能通过大量的图片，也能总结出菊花是黄色，玫瑰是红色的这个规律。

我们事先并不约束计算机必须总结出什么规律。

让计算机自己挑出最能区分菊花和玫瑰的一些规律。



机器学习

- 什么是机器学习?

让计算机自己总结的规律的编程方法，叫做**非显著式编程**。



机器学习

经典定义

Machine learning (ML) is the study of computer algorithms that improve automatically through experience.

--Wiki

机器学习研究能够从经验中自动提升自身性能的计算机算法。


--Wiki

有没有更加直观形象的解释呢？

机器学习



机器学习



机器学习

机器学习是从人工智能中产生的一个重要学科分支，是实现智能化的关键。

经典定义：利用经验改善系统自身的性能



经验 → 数据



随着该领域的发展，目前主要研究智能数据分析的理论和算法，并已成为智能数据分析技术的源泉之一

图灵奖连续授予在该方面取得突出成就的学者



Leslie Valiant
(1949 -)
(Harvard Univ.)

“计算学习理论” 奠基人

2011
年度



Judea Pearl
(1936 -)
(UCLA)

“图模型学习方法” 先驱

2012
年度

12

机器学习

从数学角度：机器学习就是从数据中学习一个函数 f

➤ 图像识别

$$f(\text{🍏}) = \text{“苹果”}$$

➤ 语音识别

$$f(\text{🗣️}) = \text{“你好啊”}$$

➤ 下围棋


$$f(\text{♟️}) = \text{“4-7”} \quad (\text{落子坐标})$$

➤ 房价预测

$$f(\text{🏠}) = \text{“1,000,000”} \quad \text{¥}$$

机器学习

机器学习的类型



机器学习

机器学习的类型-监督学习

- ✓ 分类 (Classification)
 - ✓ 身高1.65m, 体重100kg的男人肥胖吗?
 - ✓ 根据肿瘤的体积、患者的年龄来判断良性或恶性?
- ✓ 回归 (Regression、Prediction)
 - ✓ 如何预测上海浦东的房价?
 - ✓ 未来的股票市场走向?

机器学习

机器学习的类型-无监督学习

- ✓ 聚类 (Clustering)
 - ✓ 如何将教室里的学生按爱好、身高划分为5类?
- ✓ 降维 (Dimensionality Reduction)
 - ✓ 如何将原高维空间中的数据点映射到低维度的空间中?



发展历程

发展历程

机器学习源自“人工智能”

Artificial Intelligence (AI), 1956 -

1956年夏 美国达特茅斯学院

J. McCarthy, M. Minsky, N. Lochester, C. E. Shannon,
H.A. Simon, A. Newell, A. L. Samuel 等10余人



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖

达特茅斯会议标志着人工智能这一学科的诞生

John McCarthy (1927 - 2011):

1971年获图灵奖, 1985年获IJCAI终身成就奖。人工智能之父。他提出了“人工智能”的概念, 设计出函数型程序设计语言Lisp, 发展了递归的概念, 提出常识推理和情境演算。出生于共产党家庭, 从小阅读《10万个为什么》, 中学时自修CalTech的数学课程, 17岁进入CalTech时免修两年数学, 22岁在Princeton获博士学位, 37岁担任Stanford大学AI实验室主任。

发展历程

1956年人工智能的创立



1956年，于达特茅斯学院，Allen Newell (CMU)，Herbert Simon (CMU)，John McCarthy (MIT)，Marvin Minsky(MIT) and Arthur Samuel(IBM) 创立人工智能

发展历程

AI@50 Conference in 2006



The five attendees at the AI@50 conference in 2006 who were part of the Dartmouth Summer of 1956: Trenchard More, John McCarthy, Marvin Minsky, Oliver Selfridge, Ray Solomonoff.

发展历程

第一阶段：推理期

1956-1960s: Logic Reasoning

- ◆ 出发点：“数学家真聪明！”
- ◆ 主要成就：自动定理证明系统（例如，西蒙与纽厄尔的“Logic Theorist”系统）

渐渐地，研究者们意识到，仅有逻辑推理能力是不够的 ...



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

发展历程

第二阶段：知识期

1970s -1980s: Knowledge Engineering

- ◆ 出发点：“知识就是力量！”
- ◆ 主要成就：专家系统（例如，费根鲍姆等人的“DENDRAL”系统）



爱德华 费根鲍姆
(1936-)
1994年图灵奖

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 ...

发展历程

第三阶段：学习期

1990s -now: Machine Learning

◆ 出发点：“让系统自己学！”

◆ 主要成就：……

机器学习是作为“突破知识工程瓶颈”
之利器而出现的



恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切

发展历程

大数据时代的关键技术



奥巴马提出“大数据计划”后，美国NSF进一步加强资助UC Berkeley研究如何整合将“数据”转变为“信息”的三大关键技术——机器学习、云计算、众包(crowd sourcing)

National Science Foundation: In addition to funding the Big Data solicitation, and keeping with its focus on basic research, NSF is implementing a comprehensive, long-term strategy that includes new methods to derive knowledge from data; infrastructure to manage, curate, and serve data to communities; and new approaches to education and workforce development. Specifically, NSF is:

- Encouraging research universities to develop interdisciplinary graduate programs to prepare the next generation of researchers.
- Funding the National Science Foundation Expeditions in Computing project based at the University of California, Berkeley, that will integrate three powerful approaches for turning data into information - machine learning, cloud computing, and crowd sourcing;
- Providing the first round of grants to support "EarthCube" - a system that will allow geoscientists to access, analyze and share information about our planet;
- Issuing a \$2 million award for a research training group to support training for undergraduates to use graphical and visualization techniques for complex data.
- Providing \$1.4 million in support for a focused research group of statisticians and biologists to determine protein structures and biological pathways.
- Convening researchers across disciplines to determine how Big Data can transform teaching and learning.

整合三大关键技术


24

发展历程

大数据时代，机器学习必不可少


收集、传输、存储大数据的目的，
是为了“利用”大数据

没有机器学习技术分析大数据，
“利用”无从谈起



应用

在“循证医学”（evidence-based medicine）中，针对特定的临床问题，先要对相关研究报告进行详尽评估。



“文献筛选”的故事

在一项关于婴儿和儿童残疾的研究中，美国Tufts医学中心筛选了约 33,000 篇摘要

尽管Tufts医学中心的专家效率很高，对每篇摘要只需 30 秒钟，但该工作仍花费了 250 小时




a portion of the 33,000 abstracts

每项新的研究都要重复
这个麻烦的过程！

需筛选的文章数在不断显著增长！


“文献筛选”的故事

为了降低昂贵的成本, Tufts医学中心引入了机器学习技术



人类专家只需阅读 **50** 篇摘要, 系统的自动筛选精度就达到 **93%**
人类专家阅读 **1,000** 篇摘要, 则系统的自动筛选敏感度达到 **95%**
(人类专家以前需阅读 **33,000** 篇摘要才能获得此效果)

画作鉴别(painting authentication): 确定作品的真伪



勃鲁盖尔 (1525-1569)
的作品?

出自 [J. Hughes et al., PNAS 2009]

梵高 (1853-1890)
的作品?



出自 [C. Johnson et al., IEEE-SP, 2008]

例如：画作鉴别（艺术）

除专用技术手段外，**笔触分析** (brushstroke analysis) 是画作鉴定的重要工具；它旨在从视觉上判断画作中是否具有艺术家的特有“笔迹”。

该工作对专业知识要求极高

- 具有较高的绘画艺术修养
- 掌握画家的特定绘画习惯

很难同时掌握不同时期、不同流派多位画家的绘画风格！




Portions of van Gogh paintings

**只有少数专家花费很大精力
才能完成分析工作！**

例如：画作鉴别（艺术）

为了降低分析成本，机器学习技术被引入



Kröller Müller美术馆与Cornell等大学的学者对82幅梵高真迹和6幅赝品进行分析，自动鉴别精度达 **95%** [C. Johnson et al., IEEE-SP, 2008]

Dartmouth学院、巴黎高师的学者对8幅勃鲁盖尔真迹和5幅赝品进行分析，自动鉴别精度达 **100%** [J. Hughes et al., PNAS 2009][J. Mairal et al., PAMI'12]

(对用户要求低、准确高效、适用范围广)

例如：古文献修复（文化）

古文献是进行历史研究的重要素材，但是其中很多损毁严重

Dead Sea Scrolls (死海古卷)

- 1947年出土
- 超过30,000个羊皮纸片段



Cairo Genizah

- 19世纪末被发现
- 超过300,000个片段
- 散布于全球多家博物馆



高水平专家的大量精力
被用于古文献修复

例如：古文献修复（文化）

一个重要问题：

原书籍已经变成分散且混杂的多个书页，如何拼接相邻的书页？




人工完成书页拼接十分困难

- 书页数量大，且分布在多处
- 部分损毁较严重，字迹模糊
- 需要大量掌握古文字的专业人才

近年来，古文献的数字化浪潮给自动文学修复提供了机会

例如：古文献修复（文化）

以色列特拉维夫大学的学者将机器学习用于自动的书页拼接



在Cairo Genizah测试数据上，系统的自动判断精度超过 **93%**

新完成约 1,000 篇Cairo Genizah文章的拼接

（对比：过去整个世纪，数百人类专家只完成了几千篇文章拼接）

视频监控 (Video Surveillance)

- 近年来，越来越多的场合安装了监控摄像。
 - 例如电梯，ATM机，商场，马路。
- 在如此海量视频中进行信息检索是一件非常困难的工作。



皮肤癌的早期识别



美国每年都有 540 万人患皮肤癌，在早期检测到的黑色素瘤的 5 年生存率在 97—► 左右，如果晚期查出 5 年生存率将会下降 14—►，皮肤癌的早期发现可能会对其结果产生巨大的影响。

斯坦福Nature论文宣布新突破：深度学习皮肤癌诊断达专家水平


- 2018年1月25日的Nature杂志封面推荐论文发表了斯坦福大学的研究人员开发基于深度学习的皮肤癌早期识别算法，识别皮肤癌的准确率与专业的人类医生相当。



使用这一技术，有望制造出家用便携皮肤癌扫描仪，造福广大患者。

。

脑肿瘤的探测和识别



无人驾驶/自动驾驶 (Self-Driving)




Driverless vehicle with sensors
谷歌无人驾驶汽车



Environmental perception
无人汽车环境感知





基本术语

基本术语--数据

		特征				标记
		↑				↑
		色泽	根蒂	敲声	好瓜	
训练集 ←	1	青绿	蜷缩	浊响	是	
	2	乌黑	蜷缩	沉闷	是	
	3	青绿	硬挺	清脆	否	
	4	乌黑	稍蜷	沉闷	否	
测试集 ←	1	青绿	蜷缩	沉闷	?	



基本术语--任务

□ 预测目标:

- 分类:离散值
 - 二分类: 好瓜; 坏瓜
 - 多分类: 哈密瓜; 冬瓜; 西瓜
- 回归:连续值
 - 瓜的成熟度
- 聚类:无标记信息



基本术语--泛化能力

机器学习的目标是使得学到的模型能很好的适用于“新样本”，而不仅仅是训练集合，我们称模型适用于新样本的能力为泛化 (generalization)能力。

通常假设样本空间中的样本服从一个未知分布 Q ，样本从这个分布中独立获得，即“独立同分布” (i.i.d)。一般而言训练样本越多越有可能通过学习获得强泛化能力的模型



基本术语--假设空间

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	沉闷	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

$(\text{色泽} = ?) \wedge (\text{根蒂} = ?) \wedge (\text{敲声} = ?) \leftrightarrow \text{好瓜}$


在模型空间中搜索不违背训练集的假设

假设空间大小: $3 \times 4 \times 4 + 1 = 49$




基本术语--归纳偏好

假设空间中有三个与训练集一致的假设，但他们对（色泽=青绿；根蒂=蜷缩；敲声=沉闷）的瓜会预测出不同的结果：




基本术语--归纳偏好


学习过程中对某种类型假设的偏好称作归纳偏好。



存在多条曲线与有限样本训练集一致



(a) A 优于 B



(b) B 优于 A

没有免费的午餐。(黑点: 训练样本; 白点: 测试样本)







模式识别

模式识别概述

模式识别应用案例

Steven Jobs



50

模式识别概述

什么是模式识别？

Pattern recognition is a branch of machine learning that focuses on the **recognition of patterns and regularities** in data.

--Wiki, Bishop, Christopher M. [1]

模式识别是机器学习的一个分支，主要关注于数据中的模式和规律的识别。

--Wiki, Bishop, Christopher M. [1]

[1] Christopher M. Bishop, Pattern recognition and machine learning. springer, 2006.

51

模式识别概述

什么是模式？

模式是主体行为的一般方式，包括科学实验模式、经济发展模式、企业盈利模式等...

-- 百度百科




跟模式识别中的“模式”完全不同

模式识别概述

什么是模式？

1. 模式是物体吗？如果是，为什么不称物体识别而是模式识别呢？




我们识别的是他的步态，而并不是腿本身。



53

模式识别概述


什么是模式？



在人脸识别中，只要是属于乔布斯的照片我们都认为是拥有相同的模式，而不关心他的年龄、着装等。

模式识别概述

什么是模式？





在性别识别中，只要是属于同一性别的我们都认为是拥有相同的模式，而不关心对方是谁。

模式识别概述

什么是模式？

模式是指在具体识别问题中具有相同类别属性的事物或行为的统称。



模式识别概述



模式识别概述

数据预处理

保留和恢复与识别相关的，去除不相关的部分



58

模式识别概述

特征提取

feature extraction starts from an initial set of measured data and builds derived values (**features**) intended to be informative and non-redundant, facilitating the subsequent learning and generalization steps, and in some cases leading to better human interpretations.


--Wiki

特征提取从一个可测量的初始集开始构建派生值，使其信息量大、无冗余，并有益于之后的学习和推广步骤，以及在一些情况下使得数据的可解释性更好。

--Wiki

模式识别概述

特征提取：为什么要特征提取？




[2] I. Goodfellow, Y. Bengio, A. Courville, Deep Learning. Cambridge, MIT Press, 2016.


60

模式识别概述

特征提取：为什么要特征提取？



轿车



非轿车




?

[3] Andrew Ng, Neural Networks: Representation, 2016.


61

特征提取：为什么要特征提取？





62

特征提取：为什么要特征提取？



63


特征提取：为什么要特征提取？



64

模式识别概述

特征提取：为什么要特征提取？




特征提取将原始观测数据变换到新的数据空间，使得学习和识别更容易，效果更好。

模式识别系统

分类

➤ K近邻分类器




➤ 感知器与神经网络

➤ 支持向量机


➤ 决策树

➤ ...




模式识别系统

后处理



利用先验知识进一步提升识别结果




实例


实例

使用SVM分类器来识别尿沉渣图像中的红细胞和白细胞


实验流程图如下：



训练目标图片库



白细胞图像库




红细胞图像库


实例

图像分割

- 采用局部自适应阈值分割，同时结合形态学处理来去除噪声和散焦成分。




原始图像



分割图像

去除散焦成分




原理：散焦成分的灰度分布比较均匀，形态学处理对其影响不大，而红细胞或白细胞的边界灰度和内部灰度有明显的区别，所以形态学处理前后二值化图像是不同的。

特征提取

- 主要提取形状特征和纹理特征

形状特征：面积、周长和圆形度

纹理特征：灰度直方图的标准差和均值、灰度共生矩阵的相关性、对比度和二阶矩。




特征提取流程图

特征提取结果

- 形状特征:


红色表示红细胞的特征
蓝色表示白细胞的特征




×

• 纹理特征

灰度直方图的均值




灰度直方图的标准差




×

灰度共生矩阵的二阶矩




×

灰度共生矩阵的相关性



灰度共生矩阵的对比度






×

特征值的选取


- 面积
- 周长
- 圆形度
- 均值
- 标准差
- ▶ 灰度共生矩阵的对比度
- ▶ 灰度共生矩阵的相关性
- ▶ 灰度共生矩阵的能量
- ▶ 灰度共生矩阵的一致性

一般图像特征


扩展图像特征



三种算法结果比较




2个特征正确率比较



7个特征正确率比较

测试结果图像



谢 谢!