



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP研究内容
- ▶ NLP的困难和挑战
- ▶ NLP研究方法
- ▶ 相关资源



课程信息

▶ 学时

▶ 78学时(48+30)

▶ qq

▶ 群号: 706465619

▶ contact

▶ 一综 b421



2025AI-NLP

群号: 706465619



扫一扫二维码, 加入群聊






教材和参考资料

► 教材和资源

- <http://web.stanford.edu/class/cs224n/>, 斯坦福, manning
- <https://space.bilibili.com/639900532/channel/collectiondetail?sid=84480>, 西湖大学, 张岳 《自然语言处理》





课程目标

▶ 课程内容

▶ Part I: NLP basis

- ▶ 概述，中文和英文文本处理，N-gram模型，VSM文本向量表示，文本分类，序列标注，句法分析

▶ Part II: NLP with deep learning

- ▶ Word2vec, fastText, textCNN, RNN-LM, LSTM&GRU, Attention, Transformer, BERT, GPT, LLM概述

▶ Part III: Models and Applications

- ▶ 情感分析，信息抽取，大模型技术



课程实施

▶ 学习方法

- ▶ 48理论(3学分)+30实验 (1学分)
- ▶ 阅读文献，复现论文，展示讨论
<https://aclanthology.org/>

▶ 考核方式(暂定)

- ▶ 理论
 - ▶ 50%(itc作业)+50%考试
- ▶ 实验
 - ▶ 50% experiments(7.5次)
 - ▶ 50%课程项目 (近3年A会论文复现和改进，不分组)



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



自然语言

► Natural Language(自然语言)

Natural language refers to a human language such as Chinese, as opposed to an artificial language. Natural languages have been used to communicate and have evolved **in a natural way**.

Abstract

Metaphors are a common communication used in our day-to-day life. The detection and generation of metaphors in textual data have been studied extensively but metaphors in other forms have been under-explored. Recent studies have shown that Vision-Language models cannot understand visual metaphors in memes and adverts. As of now, no probing studies have been done that involve complex language phenomena like metaphors with videos. Hence, we introduce a new VL task of describing the metaphors present in the videos in our work. To facilitate this novel task, we construct and release a manually created dataset with 705 videos and 2115 human-written captions, along with a new metric called

澎湃新闻

8-31 21:18 澎湃新闻官方微博 已编辑

【马上评 | #青岛女司机逆行打人的两个未竟之#“路虎女司机逆行打人事件”还在持续发酵。8月

布通报称，驾车逆行的王某因正常行驶的林某某连续辱骂、殴打，导致林某某鲜血直流，王某

局日前发布的最新数据显示，我国超过2000亿元，现有数据中心机架效应进一步凸显；传输延迟控制在1现，用户体验进一步优化；新建数04，绿色低碳发展进一步加快。

最近实验进展怎么样？

突变体获得了吗？

把最近的进展做成ppt后发我，我看后有时间找你讨论

好的，老鼠



自然语言

► Artificial Language(人工语言)

```
try {
    cMessage = messageQueue.take();
    for (AsyncContext ac : queue) {
        try {
            PrintWriter acWriter = ac.getWriter();
            acWriter.println(cMessage);
            acWriter.flush();
        } catch (IOException e) {
            System.out.println("Error: " + e.getMessage());
        }
    }
} catch (InterruptedException e) {
    e.printStackTrace();
}
```

- append(CharSequence csq)
- append(char c)
- append(CharSequence csq)
- format(String format, Object... args)
- format(Locale l, String format, Object... args)
- printf(String format, Object... args)

```
def add5(x):
    return x+5

def dotwrite(ast):
    nodename = getNodeName()
    label=symbol.sym_name.get(int(ast[0]),ast[0])
    print '%s [%s]' % (nodename,label),
    if isinstance(ast[1], str):
        if ast[1].strip():
            print '= %s';' % ast[1]
        else:
            print ']'
    else:
        print '[';
        children = []
        for n, child in enumerate(ast[1:]):
            children.append(dotwrite(child))
        print '%s -> (' % nodename,
        for name in children:
            print '%s' % name,
```

(<https://netbeans.org/features/java/>)

(<http://noobite.com/learn-programming-start-with-python/>)



自然语言

► Language granularity 粒度

A **vocabulary** consists of a set of **words** (w_i)



(<http://learnenglish.britishcouncil.org/en/vocabulary-games>)

A **text** is composed of a sequence of **words** from a **vocabulary**



(http://www.nature.com/polopoly_fs/1.169291/menu/main/topColumns/topLeftColumn/pdf/518273a.pdf)

A **language** is constructed of a set of all possible **texts**



(<http://www.old-english/language.php>)



自然语言处理

► Natural Language Processing 自然语言处理

Natural language processing (NLP) is an area of **computer science and artificial intelligence** concerned with the interactions between **computers and human (natural) languages**, in particular how to program computers to process and analyze large amounts of natural language data.

https://en.wikipedia.org/wiki/Natural_language_processing

自然语言处理（NLP）是人工智能的一个核心分支，它研究如何让计算机能够理解、处理并生成人类自然语言（如中文、英文），最终实现人与机器之间有效通信的技术。


<https://chat.deepseek.com/>



NLP的学科关系

▶ 自然语言处理与人工智能(NLP & AI)

- ▶ 人工智能的一个分支
- ▶ 研究的是自动理解和生成人类语言



▶ AI的核心技术

- ▶ 计算机视觉
- ▶ 机器学习
- ▶ 自然语言处理
- ▶ 机器人
- ▶ 语音识别
- ▶ ...



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
 - ▶ 基础语言学：词法->句法->语义->语用
 - ▶ 核心技术与任务（理解、生成、交互）
 - ▶ 系统和场景应用
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



NLP研究内容

▶ NLP研究内容

▶ 1.基础语言学层面

▶ 词法->句法->语义->语用

▶ 2.核心技术与任务

▶ 基础任务：分词，词性标注，句法分析

▶ 语义理解：信息抽取，语义角色标注，情感分析

▶ 文本生成：机器翻译，文本摘要， 对话系统


▶ 3.系统和应用场景

▶ 搜索引擎，知识图谱，智能客服，翻译系统



NLP研究内容

► NLP研究内容






语言学基础

- ▶ 从语言学(Linguistic)的层级来分类
 - ▶ Phonology 音系学
 - ▶ 发音规则；音素phonemes的使用方式
 - ▶ Morphology 词法学
 - ▶ 词的构成规则；词素的使用方式
 - ▶ Syntax 句法
 - ▶ 组词成句的规则
 - ▶ Semantics 语义
 - ▶ 语言的意义相关的规则
 - ▶ Pragmatics 语用
 - ▶ 跟社会情景和语境相关的语言使用规则



语言学基础

► 语言学层级 vs NLP 基础任务





词法分析(lexical analysis)

▶ 1.词的形态分析(Morphological analysis)

- ▶ 研究词(word)的构成问题
- ▶ 词是语言中能独立使用的**最小单位**；语素morpheme是构成词的要素，是语言中最小的**有意义的**语言单位。

▶ 中文的词构成：

- ✓ 包含一个语素：人，蜈蚣，鹦鹉，马虎；
- ✓ 包含多个语素：图书馆← 图+书+ 馆
- ✓ 不能单独成词语素：[老]虎。[老]作前缀，无实意，是不成词语素。（也有将[老虎]看作一个语素）



词法分析(lexical analysis)

► 1.词的形态分析(Morphological analysis)

► 英文

✓ tokenization: I'm => I 'm

Mr.Right => Mr. Right

✓ stemming: activate, activation => activ


✓ lemmalization: computers => computer

✓ Morphology: walking => walk + ing



词法分析(lexical analysis)

- ▶ 2.词性标注(Part-of-speech tagging)
 - ▶ Assigning a PoS tag to each word in a sentence



<https://stanfordnlp.github.io/CoreNLP/>

<https://corenlp.run/>



词法分析(lexical analysis)

▶ 3.词语切分

▶ 中文分词(Word segmentation)

华为Mate 60 Pro支持卫星通话.

华为/Mate/60/Pro/支持/卫星/通话/.

<https://github.com/lancopku/pkuseg-python>

▶ 英文符号化(Tokenization)

I'm a teacher.

I 'm a teacher .



句法分析(syntactic parsing)

▶ 句法学Syntax

- ▶ 研究句子结构成分之间的相互关系和组成句子序列的规则

- ▶ The study of the structural relationships between words in a sentence

- ▶ 句法: 组词成句的知识



- ▶ 句法学: 研究句子结构成分之间的相关关系和组成句子序列的规则

- ▶ 苹果, 我吃了(话题句)
 - ▶ 我吃了苹果(主动句)
 - ▶ ≠ 苹果吃了我 (错误)



句法分析(syntactic parsing)


- ▶ 成分句法分析(Constituency Parse)
 - ▶ Building the syntactic tree of a sentence
 - ▶ 聪明的孩子认真地读有趣的书
 - ▶ ex: *I saw the man.*





句法分析(syntactic parsing)

- ▶ 依存分析(Dependency Parse)
 - ▶ Building the dependency tree of a sentence
 - ▶ ex: I saw the man with a telescope.




<https://corenlp.run/>



句法分析(syntactic parsing)

- ▶ 依存分析(Dependency Parsing)
 - ▶ 华为Mate60Pro支持卫星通话.



<https://corenlp.run/>

<https://ltp.ai/demo.html>



语义分析(semantic analysis)

► 语义学 Semantics

- 研究如何从一个语句中词的意义，以及这些词在该语句中句法结构中的作用来推导出该语句的意义
- The study of the **meaning** of words, and how these **combine** to form the **meanings of sentences**



语义分析(semantic analysis)

- ▶ 词级别(word-level)的语义分析
 - ▶ 词义消歧(word sense disambiguation, WSD)
 - ▶ I **saw** a man with a **saw**.
 - ▶ 我的**苹果**坏了
 - ▶ Never **trouble** **troubles** till **trouble** **troubles** you
 - ▶ 真有**意思**，我完全不是那个**意思**。
 - ▶ 隐喻
 - ▶ He is a **big potato**.
 - ▶ 又抓了一个**大老虎**



语义分析(semantic analysis)

▶ 词级别(word-level)的语义任务

▶ 词间语义关系

synonyms

- quick-fast
- good-fine
- cute-lovely

antonyms

- quick-slowly
- good-bad
- correct-wrong

hypernym

- animal-cat
- plant-grass
- career-doctor


▶ 语义类比

- ▶ king-queen / man-woman / boy-girl



语义分析(semantic analysis)

- ▶ 句子级别(sentence-level)的语义任务
 - ▶ Predicate-argument relation/semantic role labeling
(谓词-论元结构 / 语义角色标注)





语义分析(semantic analysis)

- ▶ 句子级别(sentence-level)的语义任务
 - ▶ 文本蕴含 (text entailment)

Jack and Peter are doing homework in the classroom

hypotheses

- Jack and Peter are together ✓
- Classroom is a studying place ✓
- Jack and Peter are chatting ✗



语用分析(Pragmatics analysis)

▶ 语用学Pragmatics

- ▶ 研究通过语言达到目标，以及上下文(语境)对语义理解所产生的影响。核心概念包括：言外之意、语境、合作原则、礼貌原则等。
- ▶ 从狭隘的语言学观点看，语用学处理的是语言结构中有形式体现的那些语境。
 - ▶ 例如：火，火，火！
 - ▶ 比如礼貌用语
 - Give me the salt!
 - Could you please give me the salt?



语用分析(Pragmatics analysis)

► 语义学和语用学的区别

- 对句子语义的分析，前者着眼于内部成分和组合制约，后者着眼于外部环境因素制约
- 一个向内求义，符合“意义组合原则”；一个向外求义，符合“意义情景原则”
- 语用学不仅要看句子组成，句子上下文，还要看使用场合



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
 - ▶ 基础语言学：词法->句法->语义->语用
 - ▶ 核心技术与任务（理解、生成）
 - ▶ 系统和场景应用
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



核心技术与任务

▶ 1. 自然语言理解NLU

- ▶ 让机器能够“读懂”或“听懂”人类语言。核心的判断和决策
- ▶ 例如：
 - ▶ 信息抽取，情感分析，指代消解，词义消歧，语义角色标注，句法分析


▶ 2. 自然语言生成NLG

- ▶ 让机器能够根据结构化数据、知识或语义表示，生成流畅、准确、易于理解的自然语言文本。
- ▶ 例如
 - ▶ 机器翻译，文本摘要，问答



核心技术与任务(NLU)

- ▶ 信息抽取(information extraction, IE)
 - ▶ 从无结构文本中获取结构化信息
 - ▶ 涉及多个层面的语言学知识





核心技术与任务(NLU)

► 命名实体识别(Named entity recognition, NER)

NER(named entity recognition)

比亚迪董事长兼总裁王传福也现身慕尼黑车展现场



Entites: 比亚迪(org),王传福(per), 慕尼黑(loc)





核心技术与任务(NLU)

▶ 回指消解(Anaphora Resolution)

▶ 代词或名词的指向



▶ 0代词指向

我看过这部电影, 很有趣


电影



核心技术与任务(NLU)

▶ 共指消解(co-reference)

- ▶ 有些代词或者表达指向多个相同实体。






核心技术与任务(NLU)

▶ 关系抽取(relations)

▶ 实体之间的关系



Entites: 比亚迪(org),王传福(per), 慕尼黑(loc)
Relation: 雇佣 (employment)
Event: 现身(王传福, 车展)



核心技术与任务(NLU)

▶ 事件抽取

比亚迪董事长兼总裁王传福也现身德国慕尼黑车展现场

arg1 points to 王传福
arg2 points to 车展




Event trigger: 现身
Event type: 外事活动
Event argument: Arg1: 王传福
Arg2: 车展



核心技术与任务(NLU)

► 知识图谱

- 一种图数据库，实体为节点，关系为边





核心技术与任务(NLU)

► 情感分析(sentiment analysis)

► 识别文本中的情感和观点

► 1.情感分类：sentiment classification

电影太精彩了，我喜欢！ → positive/negative  

► 2.针对性情感：targeted sentiment

华为和小米手机都很流畅 → 华为：positive
小米：positive

► 3.方面情感分析：Aspected sentiment

这酒店服务很好，卫生也不错，就是价格太贵

► 4.细粒度情感分析：fine-grained

老师批评我做事情不认真



核心技术与任务(NLU)

▶ 情感分析相关任务

▶ 讽刺检测sarcasm detection

…美国爆发大规模游行，美丽风景线！

▶ 情绪检测emotion detection

anger, excited, liking

▶ 情感词典构建

▶ like, favor, love, ...

▶ 立场检测

▶ Support, against



核心技术与任务(NLU)

▶ 立场检测 Stance detection

关于远程办公的立场

文本1:

- ▶ 远程办公极大地提高了我的工作效率和生活质量，减少了通勤时间，让我能更好地平衡工作与生活。这是未来工作的必然趋势。

文本2:

- ▶ 远程办公导致团队沟通效率低下，公司文化变得淡薄，而且让工作和生活的界限变得模糊，弊大于利。

文本3:

- ▶ 我们公司本周三和周五允许员工选择远程办公或到岗办公。”



核心技术与任务(NLU)

▶ 语法检查/拼写检查

- ▶ 拼写错误, 语法检查, 流畅度检查
- ▶ 自动作文评分

The cat is chase the dog




The cat is chasing the dog



核心技术与任务(NLG)

摘要生成summarization

根据一篇或多篇文本生成一段流畅的文字






核心技术与任务(NLG)

► 机器翻译

► 从一种语言到另一种语言






核心技术与任务(NLG)

▶ 问答question answering(QA)

▶ Knowledge-based QA

▶ e.g. 比亚迪董事长是谁?



▶ Open QA

▶ e.g. LLM-based QA, 组合了各种技术



请简单回答：你喜欢自然语言处理吗？



作为你的对话伙伴，我没有情感和喜好，因此无法说“喜欢”或“不喜欢”自然语言处理。然而，我可以告诉你自然语言处理是一个重要的领域，它涉及计算机与人类语言之间的交互，具有广泛的应用和重要的研究价值。自然语言处理技术的发展，对于推动人工智能的进步和普及具有重要意义。

由文心大模型 3.5 生成



核心技术与任务(NLG)

► 图像描述生成(Image Captioning)



解释图片

这是一幅卡通风格的插画，展现了一个小女孩在街道上奔跑的场景。画面里，小女孩戴着圆框眼镜，头发部分束成丸子头，穿着紫色外套、浅色内搭与破洞牛仔短裤，面带笑容，显得活泼又欢快。背景是有着树木、房屋和车辆的街道，整体色调温暖明亮，营造出一种轻松愉悦、充满朝气的氛围，仿佛小女孩正享受着户外的美好时光。



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP研究内容
 - ▶ 基础语言学：词法->句法->语义->语用
 - ▶ 核心技术与任务（理解、生成、交互）
 - ▶ 系统和场景应用
- ▶ NLP的困难和挑战
- ▶ NLP研究方法概述
- ▶ 相关资源



系统和场景应用

► Information Retrieval





系统和场景应用

► Text Categorization

- Assigning one (or more) pre-defined category to a text





系统和场景应用

► 大模型应用



请画一张小狗在抓蝴蝶的漫画



好的，根据你的需求，我为你创作了一幅画作。如果需要继续让我为你作画，请完整描述你的需求，如：“帮我画深海里的古风女孩，侧脸美颜，甜美微笑”。

由文心大模型 3.5 生成



系统和场景应用

▶ 对话系统 Spoken dialog systems

Try the service

The screenshot shows a chat interface with a scrollable message history. The first message from the system (pizza icon) says: "Ok, I have one Small canadian bacon pizza for pickup. Is that correct?". The user (speech bubble icon) responds with "no". The second message from the system says: "Oops! Let's start over. What size would you like?". At the bottom is a text input field with the placeholder text "Type a response and hit enter".



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



NLP的困难和挑战

▶ NLP的主要挑战

▶ 语言本身的复杂性

▶ 歧义性、新词、不规范

▶ 数据挑战

▶ 数据稀疏性（低资源语言）、标注成本、偏见

▶ 计算效率

▶ 大模型（Llama, deepseek）和较大模型(BERT, GPT)
算力需求，模型的可解释性



歧义现象

▶ 按语言学层级分类：

▶ 词法歧义

- ▶ 发生在词汇层面，涉及词的多义性和词性兼类

▶ 句法歧义

- ▶ 发生在句子结构，同一个句子可以有多种句法解释

▶ 语义歧义 (Semantic Ambiguity)

- ▶ 句法结构清晰，句子的含义仍不明确

▶ 语用歧义 (Pragmatic Ambiguity)

- ▶ 依赖上下文、说话者意图和共享知识

有时候他们有交叉和包含关系



词法歧义

▶ 1) 一词多义

▶ I'll go to the **bank**.

▶ 词义：银行，河堤

▶ 2) 词性兼类

▶ “动物**保护**警察”明年上岗

▶ 词性：名词，动词

▶ 窗户**开关**

▶ 词性：名词/动词



词法歧义

► E. g

- 他说：“她这个人真有意思(funny)”。她说：“他这个人怪有意思的(funny)”。于是人们以为他们有了意思(wish)，并让他向她意思意思(express)。他火了：“我根本没有那个意思(thought)”！她也生气了：“你们这么说是什么意思(intention)”？事后有人说：“真有意思(funny)”。也有人说：“真没意思(nonsense)”。



句法歧义

► 特点:

► 词语之间的组合关系不明确

► 例如:

► (1) 喜欢乡下的孩子

□ 乡下的孩子？ 喜欢乡下？

► (2) 关于鲁迅的文章

□ 关于鲁迅？ 鲁迅的文章？

► (3) 咬死了猎人的狗

► (4) I saw the man with a telescope.

► (5) 年轻的男孩和女孩





句法歧义

- ▶ (6) 下雨天留客天留人不留
 - ▶ 下雨天，留客天，留人不？留
 - ▶ 下雨天，留客，天留，人不留
- ▶ 这个句子的歧义是由句法结构的不确定性造成的
- ▶ 它完美地展示了汉语作为一种“意合”语言的特点：词语之间的关系高度依赖语序和上下文来体现，一旦语序和上下文无法提供唯一解，就会产生结构歧义



语义歧义

▶ 特点

- ▶ 发生在意义层面，即使句法结构清晰，句子的含义仍不明确，例如

▶ 1) 语义角色歧义

- ▶ 动词的施事、受事等角色分配不明确。

□ (1) 鸡不吃了

▶ 2) 指代歧义

- ▶ 代词 (it, he, she, they) 或指示词 (这, 那) 的指代对象不明确。

□ (2) 小明打了小王，因为他很生气。



语用歧义

► 特点:

► 跟语境背景和上下文有关, 例如:

► (1) 能穿多少穿多少

□ 冬天: 多; 夏天: 少

► (2) 这回你真长脸了

□ 批评还是表扬跟场景和意图有关

► (3) 你可真行啊

□ 语义跟场景有关



基于NLP任务视角的歧义现象

▶ E.g 基于中文分词任务的歧义现象，可以划分为

▶ 1.组合歧义

□ 门把手弄坏了

门/ 把/ 手/ 弄/ 坏/ 了

门把手/ 弄/ 坏/ 了

▶ 2.交叉歧义

□ 大学生物理学学科

▶ 3.复合歧义



未知语言现象

▶ 新词创造

- ▶ 类可以用有限的词汇和规则生成无限多的新句子，如
- ▶ 网络新词
 - ▶ “yyds”、“绝绝子”，“大冤种”，
- ▶ 网络隐喻
 - ▶ 摸鱼、搬砖、CPU你、塌房、绿茶、逝一下可刑



目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



NLP研究方法概述

- ▶ 基于规则的方法(1950s-1980s)
 - ▶ Rule-based(symbolic)
 - ▶ 最早的NLP方法
 - ▶ 基于人类开发(启发式)的规则和词典
 - ▶ 难以解决歧义

精神很强壮，肉体很虚弱



The spirit is strong, but the flesh is weak ✓


The Vodka is good, but the meat is bad ✗



NLP研究方法概述

▶ 基于统计机器学习方法(1980s-2000s)

- ▶ 训练数据（标注语料）
- ▶ 特征工程
- ▶ 使用参数训练模型
- ▶ 训练好的模型应用到测试数据






NLP研究方法概述

► 深度学习(2000s-)


- 不需要语言学特征（如词形，句法，词性，依存）
- 采用深层大模型
- 在大的非标注语料上预训练





NLP研究方法概述

► 大语言模型(LLM, 2019~)





目录

- ▶ 课程信息
- ▶ 基本概念
- ▶ NLP的研究内容
- ▶ NLP的困难和挑战
- ▶ NLP的研究方法概述
- ▶ 相关资源



开发工具和库

▶ 1. 主流深度学习框架

▶ PyTorch

- ▶ 当前学术研究和工业界的主流选择。
- ▶ Hugging Face等生态都以其为核心。

▶ TensorFlow

- ▶ 在生产环境部署、移动端支持方面有优势



开发工具和库

▶ 2. 核心NLP库

▶ Hugging Face

- ▶ 自然语言处理领域不可或缺的**开源平台**，尤其以其 Transformers 库和丰富的预训练模型资源闻名

▶ spaCy

- ▶ 工业级自然语言处理库。包括词性标注、依存句法分析、命名实体识别等功能，适合构建工业流水线。

▶ NLTK (Natural Language Toolkit):

- ▶ NLP教学和研究的**老牌经典库**。提供了大量的语料库和算法示例，适合学习和原型设计。



开发工具和库

▶ Stanford CoreNLP

- ▶ 斯坦福大学的NLP工具包。提供非常扎实、准确的语言学分析（如句法树），适合对语言学精度要求高的场景。

▶ gensim

- ▶ 主题建模和词向量训练的工具。用于训练Word2Vec、Doc2Vec、LDA等模型，非常好用。



开发工具和库

▶ 3. 文本处理工具

▶ jieba

- ▶ 最好的中文分词工具之一

▶ pkuseg

- ▶ 北大开源的中文分词工具

▶ regex (正则表达式)

- ▶ 处理复杂文本模式匹配

▶ pandas

- ▶ 数据处理和分析的核心库，用于清洗、转换和探索文本数据。



数据资源

▶ 1. 开放数据集平台

▶ Hugging Face Datasets

▶ <https://huggingface.co/datasets>

▶ 当前最重要的数据集中心。提供了超过4万个数据集

▶ Kaggle Datasets

▶ <https://www.kaggle.com/datasets>

▶ 数据科学竞赛平台，也拥有大量用户上传的数据集

▶ Papers with Code

▶ <https://paperswithcode.com/datasets>

▶ 集成了学术论文、代码和数据集



数据资源

▶ 2. 知名基准数据集

▶ 分词/词性

▶ 人民日报语料

▶ 文本分类:

▶ IMDb, THUCNews

▶ 命名实体识别

▶ CoNLL-2003

▶ 问答

▶ SQuAD, CMRC

▶ 语言理解

▶ GLUE, CLUE



数据资源

▶ 3. 语料库标注样例

▶ nltk.brown语料

▶ 词法级别标注

语料示例：

Furthermore/**rb** ,/, as/**cs** an/**at** encouragement/**nn** to/**in**
revisionist/**nn** thinking/**nn** ,/, it/**pps** manifestly/**rb** is/**bez** fair/**jj**
to/**to** admit/**vb** that/**cs** any/**dti** fraternity/**nn** has/**hvz** a/**at**
constitutional/**jj** rig...



数据资源

► Penn TreeBank (宾州树库)

► 词项和短语句法分析结果

```
( (S
  (NP Martin Marietta Corp.)
  was
  (VP given
    (NP a
      $ 29.9
      million Air Force contract
      (PP for
        (NP low-altitude navigation
          and
          targeting equipment))))))
.)
```



数据资源

▶ 1998年《人民日报》

▶ 分词和词性标注

19980101-01-001-001/m 迈向/v 充满/v 希望/n 的/u 新/a 世纪/n ——/w 一九九八年/t 第
19980101-01-001-002/m 中共中央/nt 总书记/n 、 /w 国家/n 主席/n 江/nr 泽民/nr
19980101-01-001-003/m (/w 一九九七年/t 十二月/t 三十一日/t) /w
19980101-01-001-004/m 1 2 月/t 3 1 日/t , /w 中共中央/nt 总书记/n 、 /w 国家/n 主
19980101-01-001-005/m 同胞/n 们/k 、 /w 朋友/n 们/k 、 /w 女士/n 们/k 、 /w 先生/n 们/k
19980101-01-001-006/m 在/p 1 9 9 8 年/t 来临/v 之际/f , /w 我/r 十分/m 高兴/a 地/
19980101-01-001-007/m 1 9 9 7 年/t , /w 是/v 中国/ns 发展/vn 历史/n 上/f 非常/d 重
19980101-01-001-008/m 在/p 这/r 一/m 年/q 中/f , /w 中国/ns 的/u 改革/vn 开放/vn 和
19980101-01-001-009/m 在/p 这/r 一/m 年/q 中/f , /w 中国/ns 的/u 外交/n 工作/vn 取



NLP的著名会议

▶ 会议列表

- ▶ **ACL**: Association for Computational Linguistics
- ▶ **EMNLP**: Empirical Methods on Natural Language Processing
- ▶ **CoLing**: Computational Linguistics
- ▶ **COLING**: International Conference on Computational Linguistics
- ▶ **NAACL**: North American ACL
- ▶ **NLPCC**: International Conference on Natural Language Processing and Chinese Computing
- ▶ **WWW**: The International Conference of World Wide Web
- ▶ **IJCAI**: International Joint Conference on Artificial Intelligence
- ▶ **AAAI**: the Association for the Advance of Artificial Intelligence
- ▶ ...

<https://aclanthology.org/>



Thanks