




强化学习导论

何新卫

华中农业大学信息学院
xwhe@mail.hzau.edu.cn

几个小案例



一只刚出生的羚羊
正在学习站立行走


- **新生小羚羊生存：**刚出生的羚羊面临生存挑战，需要不断试错，学会站立和奔跑。通过尝试不同的策略，以达到生存的目的。



□ **大学新生表现：**大学每年录取新生，尽管资质相近，但最终学习成绩差异很大。如何更好地理解自己的行为与结果之间的关系，从而有针对性地调整学习策略。



□ 机器人：一个机器人被安置在一个未知的环境中，需要通过学习来完成特定的任务，比如捡起一个物体并将其放置在另一个位置。机器人可以通过观察环境反馈并尝试不同的动作，逐步改进策略，使得完成任务的效率最大化。



□ **机器下围棋：**下围棋时，机器算法感知棋盘上棋子分布构成的状态，依据策略从众多可落子的动作中做出选择，落子后根据环境给予的奖励反馈更新策略以提升后续对弈表现。



- 股票交易：通过观察市场变化和历史数据，并根据不同的交易策略进行投资，该算法可根据交易结果对策略进行调整和优化，以实现最大化收益。
- 等等

如何找到一个好策略 $\pi(a|s)$ ？

如何评估策略好坏？

如何优化策略？

是本课程探讨的重点内容。



考核要求及推荐参考书

□先修课程

- 微积分A, 线性代数A, 概率论与数理统计A, 机器学习

□考核要求

- 课程平时作业: **20%**
- 四次实验: **40%**
- 期末报告: **40%**

□推荐参考书

- Richard Sutton, Andrew Barto 著, 俞凯等译, 《强化学习》(第二版), 电子工业出版社
- 王琦, 杨毅远, 江季, Easy RL: 强化学习教程, 人民邮电出版社
<https://github.com/datawhalechina/easy-rl>, 2022.
- 在线资源: 1) <https://hrl.boyuai.com/chapter> 2)
<https://spinningup.readthedocs.io/zh-cn/latest/>

□Office Hour

- 每周五5,6节课, 一综B417

第一章：基础知识 (Basics)


目标

- 准确说出强化学习和有监督学习，无监督学习的差别
- 说出强化学习定义中涉及的主体要素以及目标
- 以马里奥游戏为例，解析涉及到的强化学习核心术语和概念。

什么是强化学习

□ 机器学习三大主流**范式**:


- 有监督学习 (supervised learning)
- 无监督学习 (unsupervised learning)
- **强化学习 (reinforcement learning)**



有监督学习

□有监督学习: 基于标注数据 (如图片+ 标签) 训练模型


- **监督信息反馈无延迟**: 每个训练样本都将正确的标签**即时**传递给神经网络计算损失
- **数据分布假设**: 数据尽量满足独立同分布假设, 如果数据相关性强, 模型过拟合严重, 泛化性能较差。
- 如图像分类、目标检测、图像语义分割等任务。



无监督学习

□ **无监督学习**: 基于无标注数据（如图片），挖掘数据中的模式(pattern)。

- 例如K-means聚类、降维、异常检测等。



强化学习：玩两个游戏



1. 超级马里奥：<https://supermario-game.com/>
2. Atari Breakout: <https://www.coolmathgames.com/zh-hans/0-atari-breakout>

强化学习 (Reinforcement Learning, RL) 定义

智能体(agent) 在复杂、不确定环境(environment), 通过不断交互, 最大化它能获得的累计奖励的期望。



□智能体 (agent) : 强化学习的主体。由谁做动作或决策, 谁就是智能体。

□环境 (environment) : 智能体交互的对象。



- 过程描述: 智能体在环境里获取某状态, 基于此智能体做出一个动作 (action)。然后这个动作会在环境中被执行, 智能体获得新的状态及当前动作带来的奖励。智能体的目的就是尽可能多地从环境中获取累计奖励的期望。

强化学习研究问题举例：超级马里奥





□**智能体**：超级玛丽游戏中，控制玛丽奥运动的算法就是智能体

□**环境**：游戏程序环境, 会给出给出的一帧帧环境画面

□**目标**：马里奥（智能体）在游戏环境中进行序列动作决策，从而最大化累计奖励，赢得游戏。



启动
游戏

智能体





初始观测 O_0

向右移动 a_0





下一帧观测 O_1

向右移动 a_1



下一帧观测 O_2

向上跳跃 a_2



下一帧观测 O_3

...

奖励 r_1

奖励 r_2


奖励 r_3

环境

序列决策 (SEQUENTIAL DECISION MAKING)

□智能体与环境交互的过程就是**序列决策**的过程。

- 与环境交互过程中，智能体会获得很多观测。针对每一个观测，智能体会采取一个动作，也会得到一个奖励。所以历史是**观测、动作、奖励的时间序列**。



$$o_0, a_0, r_1, o_1, a_1, r_2, \dots, o_t, a_t, r_{t+1}, \dots$$

□**状态**：智能体采取动作会依赖它之前的历史，所以可把当前整个游戏的状态看成关于这个历史的函数

$$H_t = o_0, a_0, r_1, \dots, o_t, a_t, r_{t+1}$$

$$s_t = f(H_t)$$

强化学习核心概念和重要术语

重要术语：状态与观测

□ 状态 (STATES) 和观测 (OBSERVATIONS)

- 状态 s 是对环境的完整描述, 不会隐藏环境的信息
- 观测 o 是对状态的部分描述, 可能会遗漏信息

当环境是完全观测的, 可以在符号上将状态和观测交替使用

□ 状态和观测的表示: 我们使用实值向量、矩阵或高阶张量来表示

- 如视觉观测可以通过其像素值的RGB 矩阵来表示; 机器人的状态可能通过其关节角度和速度来表示。
- 当智能体可观测到环境的状态, 则称**环境是完全观测的**。当只看到部分时, 则称**环境是部分观测的**。



完全观测环境观测：围棋棋盘布局



部分观测环境观测：游戏中一帧RGB图像

这里为了方便描述, 后续我们在符号表示上, 不区分观测和状态 (即 s 和 o 可交换使用)

重要术语：奖励

□ **奖励 (Reward)**：由环境给的一种反馈信号（标量），反映智能体在某一步采取某个动作的表现如何。

□ **奖励类型和环境相关：**

- 比如一个象棋选手在最后棋局结束的时候，他就会得到一个正奖励（赢）或者负奖励（输）。
- 在股票管理里面，奖励由股票获取的奖励与损失决定。
- 在玩打砖块游戏的时候，奖励就是增加或减少的游戏的分数，奖励本身的稀疏程度决定了游戏的难度。



重要术语：状态空间

- **状态空间 (state space)** 是指所有智能体可能存在状态的集合，记作花体字母 $\mathcal{S}$ 。
- 状态空间可以是离散的，也可以是连续的。状态空间可以是有限集合，也可以是无限可数集合。
 - 在超级玛丽、星际争霸、无人驾驶这些例子中，状态空间是无限集合，存在无穷多种可能的状态。
 - 围棋、五子棋、中国象棋这些游戏中，状态空间是离散有限集合，可枚举出所有可能的状态（即棋盘上的格局）。

					
					
					
					
				End	

题目1：状态空间大小？请对每个状态进行编码，列举出来。


-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
	-100 	-100 	-100 	-100 	-100 	-100 	-100 	-100 	-100 	-100 	+10 

题目2：状态空间大小？请对每个状态进行编码，列举出来。

重要术语：动作空间

□ **动作空间 (ACTION SPACE)**：在给定环境中，所有有效动作的集合被称为动作空间。


- **离散动作空间 (discrete action space)**：智能体只能选择有限数量的动作，例如，像雅达利游戏和围棋 (Go) 等环境中，是离散动作空间。走迷宫机器人如果只有往东、往南、往西、往北这4种移动方式。
- **连续动作空间 (continuous action space)**：动作是实值向量。



离散动作空间

动作空间是？

$$\mathcal{A} = \{\text{"up"}, \text{"left"}, \text{"right"}\}$$



连续动作空间

动作空间是？

$$\mathcal{A} = [0^\circ, 360^\circ] \times [0^\circ, 180^\circ]$$

重要术语：策略

□ **策略 (POLICY)**：智能体采取动作的规则。其实是一个函数，把输入状态映射为动作。


- **确定性策略 (deterministic policy)**：是确定性的，通常用 μ 进行表示： $a = \mu(s)$

- **随机策略 (stochastic policy)**，这种情况下通常以 π 表示： $\pi(a|s) = p(A = a|S = s)$ ； $\pi : \mathcal{S} \times \mathcal{A} \mapsto [0, 1]$

□ 策略实质上是智能体的思维过程，所以常把“策略”一词替换为“智能体”

□ 策略可以使用**神经网络参数化** (θ 作为下标表示)，并优化以改变行为

□ 一般来说，智能体选择随机策略，可**利用随机性更好地探索环境**，动作更具有多样性，这在多个智能体博弈时非常重要，对手难以预测



观测视为状态的描述，代替状态输入网络

$$\pi_\theta(\text{左}|s) = 0.2$$

$$\pi_\theta(\text{右}|s) = 0.7$$


$$\pi_\theta(\text{下}|s) = 0.1$$

$$a^* = \operatorname{argmax}_a \pi_\theta(a|s)$$

智能体可选择最有可能得动作

离散状态空间大小为4，离散动作空间大小是4，则确定性策略的总数有？

- ☐ A 4×4
- ☐ B $4 + 4$
- ☒ C 4^4
- ☐ D 4



提交


策略总数

- 一般来说，假设动作空间是离散的 $\mathcal{A}$ ，状态空间也是离散的 $\mathcal{S}$ ，且每个状态的valid actions 是动作空间任意一个。则确定性策略 $\mu(s)$ 的总数是多少？

$$|\mathcal{A}|^{|\mathcal{S}|}$$

例题1


- 2x1 的grid world, 每个cell 可执行up、down、left、right 四个动作, 则确定性策略的总数为? 请列举所有可能的策略。




例题2: MARIO

- 在马里奥游戏中，使用大小为 $224 \times 224 \times 3$ (RGB channels) 的图像表示，以及三种可能的动作，可以定义多少种独特的策略和状态？
- 在马里奥游戏场景中有三种可能的动作，策略数量可以根据每个状态的可能动作总数来计算。由于在每个状态下有三种可用的动作，因此策略的总数将是 (3^N) ，其中 $(N = 256^{224 \times 224 \times 3})$ 是状态空间大小。

这是一个 [填空1] 。




这是一个 [填空1] 。




作答

这是一个 [填空1] 。



作答

这是一个 [填空1] 。



作答

重要术语：轨迹

□ **轨迹 (TRAJECTORIES)**：一个轨迹 τ 是智能体在环境中交互生成的一个状态-动作序列, $\tau = (s_0, a_0, s_1, a_1, \dots)$. 第一个状态是 s_0 , 是从一个初始状态分布中随机采样得到


- 轨迹常被称为回合 (episodes) 或者预演 (rollouts) .
- 一个episode 可以代表一场游戏的结束、迷宫旅行的结束, 或者任何重复性交互的结束
- episode 之间可以视为独立的

□ 两类任务：

- **回合制任务(episodic task)**, 即有终止状态
- **连续性任务(continuing task)**, 即没有结束 (如机器人的一生) 。





回合制任务



连续性任务

训练数据




- **观测数据非独立同分布**: 智能体与环境交互获取的观测数据是时间序列数据, 帧间其实有非常强的关联。
- **延迟反馈**: 游戏没有立即告诉我们哪个动作是正确动作。比如想定左/右边移动, 并没有立刻的反馈奖励。
- **延迟奖励 (delayed reward)** 使得网络缺乏即时反馈, 优化困难。

有监督学习和强化学习区别

学习范式	数据来源	数据特点	监督信号	学习过程	模型上限
有监督学习	收集，人工标注	独立同分布	正确标签，即时修正模型预测	通过优化目标函数学习模型参数	理论性能上限是人类表现
强化学习	智能体与环境交互获取数据	时间序列，不满足独立同分布	环境的奖励信号，奖励延迟	探索利用的平衡，不断试错探索	探索环境，有超越人类潜力

强化学习历史

- **标准强化学习**：早期对状态（如图像）手动设计特征，利用特征训练策略网络或价值评估网络
- **深度强化学习 (deep reinforcement learning)**：深度学习+ 强化学习，端到端训练，直接输入状态，输出动作概率或者拟合价值函数等。



(a) 标准强化学习




(b) 深度强化学习

强化学习应用举例

□ 近年来强化学习成功应用的关键有如下：

- **算力（computation power）**，可以更快地做更多的试错尝试;
- 通过不同尝试，**智能体在环境里获得很多信息**，在环境里面取得很大的奖励
- **端到端**把特征提取和价值估计或决策一起优化，可得到一个更强的决策网络。



机器人、游戏领域领域

[Submitted on 22 Jan 2025]

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, Xiaokang Zhang, Xingkai Yu, Yu Wu, Z.F. Wu, Zhibin Gou, Zhihong Shao, Zhuoshu Li, Ziyi Gao, Aixin Liu, Bing Xue, Bingxuan Wang, Bochao Wu, Bei Feng, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, Fuli Luo, Guangbo Hao, Guanting Chen, Guowei Li, H. Zhang, Han Bao, Hanwei Xu, Haocheng Wang, Honghui Ding, Huajian Xin, Huazuo Gao, Hui Qu, Hui Li, Jianzhong Guo, Jiashi Li, Jiawei Wang, Jingchang Chen, Jingyang Yuan, Junjie Qiu, Junlong Li, J.L. Cai, Jiaqi Ni, Jian Liang, Jin Chen, Kai Dong, Kai Hu, Kaige Gao, Kang Guan, Kexin Huang, Kuai Yu, Lean Wang, Lecong Zhang, Llang Zhao, Litong Wang, Liyue Zhang, Lei Xu, Leyi Xia, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Meng Li, Miaojun Wang, Mingming Li, Ning Tian, Panpan Huang, Peng Zhang, Qiancheng Wang, Qinyu Chen, Qilishi Du, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, R.J. Chen, R.L. Jin, Ruyi Chen, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shengfeng Ye, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, S.S. Li et al. (100 additional authors not shown)

We introduce our first-generation reasoning models, DeepSeek-R1-Zero and DeepSeek-R1. DeepSeek-R1-Zero, a model trained via large-scale reinforcement learning (RL) without supervised fine-tuning (SFT) as a preliminary step, demonstrates remarkable reasoning capabilities. Through RL, DeepSeek-R1-Zero naturally emerges with numerous powerful and intriguing reasoning behaviors. However, it encounters challenges such as poor readability, and language mixing. To address these issues and further enhance reasoning performance, we introduce DeepSeek-R1, which incorporates multi-stage training and cold-start data before RL. DeepSeek-R1 achieves performance comparable to OpenAI-o1-1217 on reasoning tasks. To support the research community, we open-source DeepSeek-R1-Zero, DeepSeek-R1, and six dense models (1.5B, 7B, 8B, 14B, 32B, 70B) distilled from DeepSeek-R1 based on Qwen and Llama.

构建大预言模型的重要理论基础

总结

□ 机器学习三大主流范式及区别

□ 强化学习定义和特点

1 在复杂、不确定 2，通过不断交互，最大化它能获得的 3。

□ 以马里奥游戏为例，解释重要术语：

- 1) 环境, 2) 智能体, 3) 动作空间, 4) 状态空间
- 5) 策略, 6) 奖励, 7) 轨迹, 8) 状态和观测,
- 9) 任务类型

