


第三章: 背景知识-有限马尔可夫过程 (Finite Markov Processes)

背景介绍



贫富差距财富转移背后的哲学
图片来源：电影1942

随机变量 S




□ 概率论的研究对象是静态的随机现象

随机过程 $S(t)$

□随机过程 (stochastic process)

✓随机过程的研究对象是随**时间**演变的随机现象（例如天气随时间变化、城市交通随时间变化）。

□随机过程研究状态的变化过程。某时刻 t 的状态 S_t 通常取决于 t 时刻前历史状态。我们将已知历史信息 $(S_1, S_2, \dots, S_t)$ 时下一时刻状态 S_{t+1} 的概率表示成 $P(S_{t+1} | S_1, S_2, \dots, S_t)$



经典的一种随机过程：马尔可夫性质

□ 性质：马尔可夫性质（（Markov property））：某时刻状态只取决于上一时刻的状态：

$$P(S_{t+1}|S_t) = P(S_{t+1}|S_1, \dots, S_t)$$

- 即下一个状态只取决于当前状态，而不会受到过去状态的影响
- **并不代表这个随机过程就和历史完全没有关系。**因为虽然时刻 $t+1$ 的状态只与时刻 t 的状态有关，但是时刻 t 的状态其实包含了 $t-1$ 时刻的状态的信息。通过这种**链式的关系，历史的信息被传递到了现在。**



- 可以大大简化运算，因为只要当前状态可知，所有历史信息都不再需要了。

马尔可夫过程

- 马尔可夫过程 (Markov process) 又称马尔可夫链 (Markov chain)
- 我们通常用**元组** $\langle \mathcal{S}, P \rangle$ 描述一个马尔可夫过程, 其中 $\mathcal{S}$ 是状态空间, P 是状态转移矩阵 (state transition matrix) 。
- 假设共有 n 个状态, 此时 $\mathcal{S} = \{s_1, s_2, \dots, s_n\}$ (注: 小写的非随机变量), 则状态转移矩阵 P 定义了所有状态之间的转移概率, 即


$$P = \begin{bmatrix} p(s_1|s_1) & p(s_2|s_1) & p(s_3|s_1) & \cdots & p(s_n|s_1) \\ p(s_1|s_2) & p(s_2|s_2) & p(s_3|s_2) & \cdots & p(s_n|s_2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ p(s_1|s_n) & p(s_2|s_n) & p(s_3|s_n) & \cdots & p(s_n|s_n) \end{bmatrix} \quad \Rightarrow \quad \text{行和为1}$$

- $p(s_j|s_i) = P(S_{t+1} = s_j | S_t = s_i)$ 表示从状态 s_i 转移到状态 s_j 的概率 (注: S_{t+1}, S_t 为随机变量, s_j 和 s_i 具体状态)
- 从某个状态出发, 到达其他状态的概率和必为1。

马尔可夫过程

□ 下图展示了一个6状态的马尔科夫过程，表面状态之间转移情况。比如若某时刻当智能体位于 s_1 ，则它以0.9的概率基于待在原状态 s_1 ，而以0.1的概率转移到 s_2 上面。 回答如下问题：


- 若用元组 $\langle s, P \rangle$ 表示，则 s 和 P 是什么？
- 终止状态是那个状态？
- 右图里面每个圆圈代表状态，是否为随机变量？



基于马尔可夫链的采样

- 右下图马尔可夫链唯一定义了这个环境的所有动态信息。
- 当智能体位于 s_3 时，我们可以基于该链完成采样，采样出**很多轨迹**，比如：

- s_3, s_6
- s_3, s_4, s_6
- s_3, s_4, s_6
- s_3, s_6
- s_3, s_4, s_6
- $s_3, s_4, s_5, s_3, s_4, s_6$
- ...



案例

- 一个封闭的村子完全和外面世隔绝。村里住着三户人家。最开始每人手上有村子里1/3的财富。他们每人每年财富的转移概率如下图。则经过若干年后财富分布情况。

$$P = \begin{bmatrix} 0.6 & 0.2 & 0.2 \\ 0.5 & 0.2 & 0.3 \\ 0.5 & 0.35 & 0.15 \end{bmatrix}$$


```
[0.55555533 0.23188383 0.21256084]
[0.55555553 0.23188413 0.21256034]
[0.55555555 0.23188405 0.2125604 ]
[0.55555556 0.23188406 0.21256039]
[0.55555556 0.23188406 0.21256039]
```

```
import numpy as np
P = np.array([[0.6, 0.2, 0.2],
              [0.5, 0.2, 0.3],
              [0.5, 0.35, 0.15]])
x = np.array([1/3, 1/3, 1/3])
print(x)
for i in range(10):
    x = np.dot(x, P)
    print(x)
```

最后财富的分布收敛到一个稳态分布，不再改变了。这是马尔可夫过程的一个重要性质

总结

- 马尔可夫性质
- 马尔可夫过程



第三章：有限马尔可夫决策过程

何新卫

华中农业大学信息学院

回顾



折扣回报 (Return) : 回顾

□智能体在 t 时刻，其目标是最大化期望回报

$$G_t \triangleq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{H-1} \gamma^k R_{t+k+1}$$

□折扣系数 (discount rate) : $0 \leq \gamma \leq 1$ 超参数，对未来的奖励打折扣

✓ $\gamma=0$: 只关注即时奖励

✓ $\gamma=1$: 关注长期的累计奖励

✓ $0 < \gamma < 1$: γ 越大，越关注长期奖励，接近0，关注短期奖励

G_t 和 G_{t+1} 计算回报的关系

$$\begin{aligned} G_t &\triangleq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} + \cdots \\ &= R_{t+1} + \gamma (R_{t+2} + \gamma R_{t+3} + \gamma^2 R_{t+4} + \cdots) \\ &= R_{t+1} + \gamma G_{t+1} \end{aligned}$$

□ 上述公式对于 $t < H$ 均成立。

□ 对于 $t = H$ ，我们定义 $G_H = 0$ ，上述公式也满足。

例题

□题目：智能体与环境进行一个回合，获得如下奖励序列($H = 5$),

$$R_1 = -1, R_2 = 2, R_3 = 6, R_4 = 3, R_5 = 2$$


□问题： $\gamma = 0.5$, 计算 $G_0, G_1, G_2, \dots, G_5$ (提示：从后往前计算)

方法一： $G_t \triangleq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{H-1} \gamma^k R_{t+k+1}$

[推荐]方法二： $G_t \triangleq R_{t+1} + \gamma G_{t+1}$ 😊

马尔可夫奖励过程 (MRP)

□ 在马尔可夫过程 ($\langle p, \mathcal{S} \rangle$) 的基础上引入了奖励函数 $\langle p, \mathcal{S}, \mathcal{R} \rangle$



状态转
移矩阵

$$P = \begin{matrix} & \begin{matrix} s_1 & s_2 & s_3 & s_4 & s_5 & s_6 \end{matrix} \\ \begin{matrix} s_1 \\ s_2 \\ s_3 \\ s_4 \\ s_5 \\ s_6 \end{matrix} & \begin{bmatrix} 0.9 & 0.1 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.6 & 0 & 0.4 \\ 0 & 0 & 0 & 0 & 0.3 & 0.7 \\ 0 & 0.2 & 0.3 & 0.5 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \end{matrix}$$

奖励函数 $R = \begin{matrix} & \begin{matrix} s_1 & s_2 & s_3 & s_4 & s_5 & s_6 \end{matrix} \\ \begin{bmatrix} -1, -2, -2, 10, 1, 0 \end{bmatrix} \end{matrix}$

- 马尔可夫奖励过程的一个简单例子: $\mathcal{S} = \{s_1, s_2, s_3, s_4, s_5, s_6\}$ (注意: 注意元素为确定量, 非随机变量)


□ 问题1: 如何估算每个节点的期望回报 (或者价值) ?

$$G_t \triangleq R_{t+1} + \gamma G_{t+1} \quad (\text{注意: } G_{t+1}, G_t, R_t \text{ 随机变量})$$


方法一：贝尔曼方程

□ **状态价值**：一个状态的期望回报, 即从这个状态出发的未来累积奖励的期望

□ **价值函数**：所有状态的价值就组成了价值函数(value function), 写成



$$\begin{aligned} v(s) &\triangleq \mathbb{E}[G_t | S_t = s] \\ &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \mathbb{E}[R_{t+1} + \gamma v(S_{t+1}) | S_t = s] \\ &= \underbrace{\mathbb{E}[R_{t+1} | S_t = s]}_{\text{即时奖励期望正好是}} + \gamma \underbrace{\mathbb{E}[v(S_{t+1}) | S_t = s]}_{\text{可以根据状态 } s \text{ 出发的}} \end{aligned}$$



$$v(s) = r(s) + \gamma \sum_{s'} p(s' | s) v(s')$$


即时奖励期望正好是
奖励函数的输出 $r(s)$

可以根据状态 s 出发
的转移概率得到

□ 上述公式即为MRP的**贝尔曼方程 (Bellman equation)**

贝尔曼方程 (Bellman equation) 矩阵形式及求解

$$\mathcal{S} = \{s_1, s_2, \dots, s_n\}$$
$$\mathbf{v} = [v(s_1), v(s_2), \dots, v(s_n)]^T$$
$$\mathbf{R} = [r(s_1), r(s_2), \dots, r(s_n)]^T$$



(a) 马尔可夫链

(b) 状态转移示例

$$\begin{bmatrix} v(s_1) \\ v(s_2) \\ \dots \\ v(s_n) \end{bmatrix} = \begin{bmatrix} r(s_1) \\ r(s_2) \\ \dots \\ r(s_n) \end{bmatrix} + \gamma \begin{bmatrix} P(s_1|s_1) & P(s_2|s_1) & \dots & P(s_n|s_1) \\ P(s_1|s_2) & P(s_2|s_2) & \dots & P(s_n|s_2) \\ \dots & \dots & \dots & \dots \\ P(s_1|s_n) & P(s_2|s_n) & \dots & P(s_n|s_n) \end{bmatrix} \begin{bmatrix} v(s_1) \\ v(s_2) \\ \dots \\ v(s_n) \end{bmatrix}$$



$$\mathbf{v} = \mathbf{R} + \gamma \mathbf{P} \mathbf{v}$$
$$(\mathbf{I} - \gamma \mathbf{P}) \mathbf{v} = \mathbf{R}$$
$$\mathbf{v} = (\mathbf{I} - \gamma \mathbf{P})^{-1} \mathbf{R}$$

- 可以通过矩阵求逆把 $\mathbf{v}$ 的价值直接求出来。该矩阵求逆的过程的复杂度是 $O(n^3)$ 。
 - 所以当状态空间较大，比如100 万个状态时，状态转移矩阵就会是一个100 万乘100 万的矩阵，对这样一个大矩阵求逆是非常困难的。
- 通过解析解去求解状态价值只适用于小规模马尔可夫奖励过程。

方法二：蒙特卡洛（MonteCarlo, MC）采样求解

- 1) 从上述状态概率转移矩阵中采样若干条轨迹，2) 对每条轨迹上的每个状态，基于回报公式计算回报；3) 每个状态**回报的平均值**作为该状态的回报期望值的估计。
- 例如要计算 s_3 的价值估值，1) 可从 s_3 开始基于概率 P 采样很多条轨迹： $s_3 \rightarrow s_6$; $s_3 \rightarrow s_4 \rightarrow s_6$; $s_3 \rightarrow s_6$; ... 2) 采样完后，估算每条轨迹 s_3 的回报，3) 最后取平均值作为 s_3 的回报期望估计。（注：需要提前确定 γ 数值）

- 1: $i \leftarrow 0, G_t \leftarrow 0$
- 2: 当 $i \neq N$ 时，执行：
- 3: 生成一个回合的轨迹，从状态 s 和时刻 t 开始
- 4: 使用生成的轨迹计算回报 $g = \sum_{i=t}^{H-1} \gamma^{i-t} r_i$
- 5: $G_t \leftarrow G_t + g, i \leftarrow i + 1$
- 6: 结束循环
- 7: $V_t(s) \leftarrow G_t / N$

图 2.6 计算马尔可夫奖励过程价值的蒙特卡洛方法

方法三：动态规划求解

□一直迭代贝尔曼方程，直到价值函数收敛，我们就可以得到某个状态的价值。

-
- 1: 对于所有状态 $s \in S$, $V'(s) \leftarrow 0, V(s) \leftarrow \infty$
 - 2: 当 $\|V - V'\| > \epsilon$ 执行
 - 3: $V \leftarrow V'$
 - 4: 对于所有状态 $s \in S$, $V'(s) = R(s) + \gamma \sum_{s' \in S} P(s'|s) V(s')$
 - 5: 结束循环
 - 6: 返回 $V'(s)$, 对于所有状态 $s \in S$
-

图 2.7 计算马尔可夫奖励过程价值的动态规划算法


总结：

- MP, MRP的异同点

马尔可夫决策过程



MDP



□ 智能体和MDP环境交互产生序列（轨迹（trajectory））

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots$$

- **注1:** A_t, R_t, S_t 均为离散随机变量
- **注2:** R_t, S_t 具有明确显式定义离散概率分布，并取决于上一个状态和动作

□ **马尔可夫性质:** 给定 $t-1$ 时刻的**状态和动作**，则随机变量 S_t 在 t 时刻取某个特定状态 $s' \in \mathcal{S}$, $r \in \mathcal{R}$ 的概率为：

$$p(s', r | s, a) \triangleq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\},$$

for all $s', s \in \mathcal{S}$, $r \in \mathcal{R}$, $a \in \mathcal{A}(s)$

□ **p 完整定义了MDP环境的全部动态信息**，是一个四参数的确定性函数

$$p: \mathcal{S} \times \mathcal{R} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$$

有限MDP

□有限MDP (finite MDP) 特点:

- ✓ 状态空间 $\mathcal{S}$ 包含有限个状态
- ✓ 动作空间 $\mathcal{A}$ 包含有限个动作
- ✓ 奖励函数 R 包含有限种奖励数值

有限MDP

□ p 满足如下约束

$$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) = 1, \text{ for all } s \in \mathcal{S}, a \in \mathcal{A}(s)$$

□ 给定 p , 可直接计算状态转移概率, 即三参数函数 $p: \mathcal{S} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$

$$p(s' | s, a) \triangleq \Pr\{S_t = s' | S_{t-1} = s, A_{t-1} = a\} = \sum_{r \in \mathcal{R}} p(s', r | s, a)$$

□ 直接计算状态-动作对的期望奖励 $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$

$$r(s, a) \triangleq \mathbb{E}[R_t | S_{t-1} = s, A_{t-1} = a] = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r | s, a)$$

MDP环境特点

□MDP环境是抽象且灵活的

- ✓ **时间步(time-step)**不一定指固定的实际时间间隔，例如，可以是决策制定和行动执行的**任意连续**阶段；
- ✓ **动作**可以是**低级控制**（例如施加在机器人手臂电机上的**电压**）或**高级决策选择**（例如是否吃午饭）；
- ✓ **状态**可以采用各种形式，例如低级感知，如直接传感器读数，图像和点云；
- ✓ **给定一个强化学习任务，借助MDP对任务进行形式化描述是理解简化问题的第一步。**

总结

- 马尔可夫奖励过程
- 状态价值三种计算方式
- MDP和MRP的异同点
- 四参数 p 如何刻画MDP