

第一章 (续)

回顾：强化学习

智能体(agent) 在**复杂、不确定环境(environment)**，通过不断交互，**最大化它能获得的累计奖励的期望。**

- 机器学习三大主流范式及区别
- 强化学习定义和特点
- 强化学习重要术语：
 - 1) 环境, 2) 智能体, 3) 动作空间, 4) 状态空间
 - 5) 策略, 6) 奖励, 7) 轨迹, 8) 状态和观测,
 - 9) 任务类型

智能体与环境交互一轮结束，产生一段时间序列数据

复盘：给状态/动作进行打分

$s_0, a_0, r_1, s_1, a_1, r_2, s_2, a_2, r_3, s_3, \dots, \dots, s_T, r_T$

➡ 又被称为轨迹


如何评估这个动作（状态）的好坏？

A 后面时刻的奖励（ r_3 ）？

B 前面时刻的奖励（ r_2 ）？

C 前面奖励总和（ $r_1 + r_2$ ）？

D 后面奖励总和（ $r_3 + \dots + r_T$ ）？



智能体的目标：最大化累计奖励和的期望

重要术语：回报

□ **回报 (Return)**：智能体在 t 时刻后收到奖励序列为： $R_{t+1}, R_{t+2}, R_{t+3}, \dots$,

则可定义回报 (Return) 为奖励的累加和： $G_t \triangleq R_{t+1} + R_{t+2} + R_{t+3} + \dots +$

R_T , 其中 T 为最终时间步。对于continuing tasks, $T = \infty$

□ **折扣回报 (discounted return)**，引入折扣系数 γ ，对来自未来的奖励打折扣

$$G_t \triangleq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

- $\gamma=0$: 只关注即时奖励
- $\gamma=1$: 关注长期的累计奖励
- $0 < \gamma < 1$: γ 越大，越关注长期奖励，接近0，关注短期奖励

“今天的一块钱比明天的一块钱更有价值”


回报的随机性

- 假设一回合游戏共有 T 步，我们观测到所有 T 个奖励： $r_1, r_2, \dots, r_T$ 。此时这些奖励不是随机变量，而是实际观测到的数值。此时我们可以实际计算出折扣回报

$$g_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-t-1} r_T, t = 0, 1, \dots, T-1$$

此时的折扣回报 g_t 是实际观测到的数值，不具有随机性。

- 若只观测到了 t 时刻前的历史，那么对于 t 时刻往后，则存在随机性



G_t 的随机性来源：1) 动作的随机性来自于策略；2) 状态的随机性来自于状态转移概率函数。

- 智能体的目标是最大化期望回报(expected return)

价值函数没有随机性

□ 价值函数定义在回报上，通过对回报取期望消除随机性

□ 状态价值函数（V函数）：评估状态好坏

$$v_{\pi}(s) \triangleq \mathbb{E}_{\pi} [G_t | S_t = s] = \mathbb{E}_{\pi} [\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s]$$


□ 状态-动作价值函数（Q函数）：评估动作好坏

$$Q_{\pi}(s, a) \triangleq \mathbb{E}_{\pi} [G_t | S_t = s, A_t = a] = \mathbb{E}_{\pi} [\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a]$$

□ 当得到Q 函数后，在某状态要采取最优动作可以通过Q 函数直接得到。

强化学习智能体的类型

- 基于价值的智能体 (value-based agent) 学习价值函数，基于此需要外推出策略。
- 基于策略的智能体 (policy-based agent) 直接学习策略。给定状态，输出对应动作概率。



- 演员-评论员智能体 (actor-critic agent)：既学习策略，又学习价值，通过交互达到最佳动作。

- 智能体基于策略给出动作，价值对动作给出评估，具有加速训练的效果

模型

□ **环境模型**：表示智能体对环境的理解，它决定了环境中世界的运行方式。

□ **环境模型决定下一步的状态**。下一步状态取决于当前状态以及当前采取的动作。它由状态转移概率和奖励函数两个部分组成。

- **状态转移概率**即：

$$p(s'|s, a) = p(S_t = s' | S_{t-1} = s, A_{t-1} = a)$$

- **奖励函数**是指我们在当前状态采取了某个动作，可以得到多大的奖励

$$r(s, a) = \mathbb{E}[R_t | S_{t-1} = s, A_{t-1} = a]$$

强化学习智能体的类型：有模型和免模型


□ **有模型(model-based) 智能体**: 有模型（model-based）智能体通过学习状态转移来采取动作

- 对真实环境建模
- 可以在虚拟环境中预测要发生的事情，并采取对自己有利的策略
- 马尔可夫模型等，属于此类智能体

□ **免模型（model-free）智能体**: 没有去直接估计状态的转移，也没有得到环境的具体转移变量。

- 不对环境建模，直接通过与真实环境交互来学习最有策略
- 属于数据驱动型，需要大量采样来估计状态、动作和奖励函数，从而优化动作策略
- **大部分主流方法都是免模型**

强化学习智能体的类型



重要话题：探索（Exploration）与利用(Exploitation)

□ **探索**：即探索环境，通过尝试不同的动作来得到最佳的策略（带来最大奖励的策略）。

□ **利用**：即不去尝试新的动作，而是采取已知的可以带来很大奖励的动作。


□ 探索-利用的平衡问题

- **过度探索**导致智能体无法充分利用已有的知识和经验，浪费时间。
- **过度利用**导致智能体陷入局部最优，可能会忽略更好地策略



总结

- 说一下免模型和有模型的区别
- 基于策略和基于价值的强化学习的区别
- 举一个生活的例子，说明探索与利用的均衡问题



第二章：多臂老虎机

何新卫

华中农业大学信息学院

一个案例



抓娃娃机

喜欢哪个娃娃，投个币就有机会得到它。



两台娃娃机

- 设想一下，有两台娃娃机，投入1个币，娃娃机即可以一定概率输出娃娃。
- 你有100枚游戏币，设下如下两种情形的玩法：
 - 假如提前告诉你左边机器以概率为0.3 的概率输出娃娃，右边以0.5 的概率输出娃娃，你会怎么玩呢？
 - 假如不提前告诉你奖励概率，你会怎么玩呢？
 - A 完全随机的，还是逮着其中一台机器玩100次？
 - B 每个娃娃机玩50次
 - C 更好的策略？（思考一下利用和探索）

目标

- 多臂老虎机类问题强化学习形式化解读
- 多臂老虎机问题求解

多臂老虎机问题 (multi-armed bandit, MAB)

□ **通用问题**: K 个不同选项或动作之间的选择, 每个选择对应固定概率分布中数值奖励, 目标是在某个时间段内最大化期望总奖励, 如1000 次动作选择。

□ **MAB问题**: 每次拉动 K 个手杆之一, 以相应概率获取奖励。通过重复选择, 最大化赢利。


□ **动作价值**: 将时间步 t 上选择的行动表示为 A_t , 其奖励表示为 R_t , 则对任意动作 a 的**价值** (期望奖励) 记为 $q_*(a)$:

$$q_*(a) \triangleq \mathbb{E}[R_t | A_t = a]$$

• 如果知道每个动作的 $q_*(\cdot)$, 那么最优策略: 总是选择价值最高的动作即可

□ MAB是一个特别经典的问题, 理解它能够帮助理解强化学习的核心研究话题: **探索与利用 (exploration vs. exploitation)** 。

多臂老虎机 (multi-armed bandit, MAB) 问题定义



MAB问题。各根拉杆的奖励概率分布未知

- ❑ 各根拉杆的奖励概率分布未知，从头开始尝试，目标是在操作 T 次拉杆后获得尽可能高的累积奖励。
- ❑ 需要在“探索拉杆的获奖概率”和“根据经验选择获奖最多的拉杆”中进行权衡。

MAB强化学习形式化描述

要素	指代对象
智能体	我们的算法
环境	K 臂老虎机
动作	选择哪一个老虎机臂。
状态	只有一个状态，老虎机不会随时间发生改变
动作空间	$\mathcal{A} = \{1,2, \dots, K\}$
状态空间	老虎机的奖励分布不会随时间发生改变
奖励	老虎机奖励的，注意，没有延迟问题
学习目标	在操作 T 次拉杆后获得尽可能高的累积奖励

$$\max \sum_{t=1}^T r_t, r_t \sim R(\cdot | a_t)$$

其中 a_t 表示在第 t 时间步拉动某一拉杆的动作， r_t 表示动作获得的奖励

评估动作价值

□ 动作价值估计：估计每个臂的价值。


- 对于动作 $a \in \mathcal{A}$, 记其真实价值为 $q_*(\cdot)$, 第 t 次动作时, 估计价值为 $Q_t(a)$
- 通过对实际收到的奖励序列平均值估计。假设 t 次动作前, 动作 a 被选择了 k_a 次, 获得奖励为 $r_1, r_2, \dots, r_{k_a}$, 则 $Q_t(a)$ 的估计价值为:

$$Q_t(a) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=a}}$$

其中, 如果 $k_a = 0$, 则我们定义 $Q_t(a)$ 为 0;

□ 理论基础: 随着 $k_a \rightarrow \infty$, 根据大数定理, $Q_t(a)$ 将收敛到 $q_*(\cdot)$ 。

假设5个臂



盛放对应收益



臂1

$$Q_t(1) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=1}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=1}}$$



臂2

$$Q_t(2) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=2}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=2}}$$

...



臂5

$$Q_t(5) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=5}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=5}}$$

基于动作价值，制定策略

□ **贪心策略**：选择具有最大估计价值的动作：

$$A_t = \underset{a}{\operatorname{argmax}} Q_t(a)$$

- 贪婪策略总是利用当前知识来最大化即时奖励的动作，完全不采样当前估值较差的动作，以查看它们是否可能真的更好。

□ **ϵ - greedy 策略**：大部分时间都贪婪地选择动作，但偶尔以较小的概率 ϵ 随机从动作空间中**等概率随机**选择一个动作。

ϵ - greedy 策略更好平衡探索和利用

题目1: ϵ - greedy 算法, $\mathcal{A}$ 为动作空间, 则当前具有最大估计价值的动作被选择的概率有多大?

$(1 - \epsilon + \epsilon/|\mathcal{A}|)$, 其中 $\mathcal{A}$ 为动作空间。

假设动作空间有两个动作{1, 2}, 使用 $\epsilon = 0.5$ 的贪心策略。若某个时刻, 动作1 具有当前最大的估计Q 值, 则下一时刻动作1被选中的概率有多大?

- ☒ A 0.75
- ☐ B 0.25
- ☐ C 0.5
- ☐ D 不确定

提交

假设动作空间有两个动作{1, 2}, 使用 $\epsilon = 0.5$ 的贪心策略。若某个时刻, 动作1 具有当前最大的估计Q 值, 则下一时刻动作2被选中的概率有多大?

- ☐ A 0.75
- ☒ B 0.25
- ☐ C 0.5
- ☐ D 不确定

提交

累加实现奖励平均

$A_1, R_1, A_2, R_2, A_1, R_3, \dots, A_{t-1}, R_{t-1}$



$$Q_t(1) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=1}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=1}}$$

$$Q_t(2) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=2}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=2}}$$

$$Q_t(5) \triangleq \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=5}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=5}}$$



$A_1, R_1, A_2, R_2, A_1, R_3, \dots, A_{t-1}, R_{t-1}, A_t, R_t$



$$Q_t(1) \triangleq \frac{\sum_{i=1}^t R_i \cdot \mathbb{I}_{A_i=1}}{\sum_{i=1}^t \mathbb{I}_{A_i=1}}$$

$$Q_t(2) \triangleq \frac{\sum_{i=1}^t R_i \cdot \mathbb{I}_{A_i=2}}{\sum_{i=1}^t \mathbb{I}_{A_i=2}}$$

$$Q_t(5) \triangleq \frac{\sum_{i=1}^t R_i \cdot \mathbb{I}_{A_i=5}}{\sum_{i=1}^t \mathbb{I}_{A_i=5}}$$

需要1) 保存奖励列表, 2) 每次都要累加, 取均值作为动作价值估计

❑ **缺点:** 随着更多奖励, 内存和计算需求将随时间增长。每次奖励都需要额外的内存来存储它, 并需要额外的计算来计算分子中的总和。

平均奖励计算公式改进

增量实现(Incremental Implementation)

□ 给定 Q_n 和第 n 次获得的奖励 R_n , 则所有 n 次奖励的平均奖励通过以下方式计算得到:

$$\begin{aligned}Q_{n+1} &= \frac{1}{n} \sum_{i=1}^n R_i \\&= \frac{n-1}{n} Q_n + \frac{1}{n} R_n \\&= Q_n + \frac{1}{n} (R_n - Q_n)\end{aligned}$$

这个公式适用于任意时刻, 即使对于 $n = 1$, 也可以得到 $Q_2 = R_1$ 。

这种实现只需要保存 Q_n 和 n 的内存, 并且对于每个新的奖励只需要进行简单的计算。

上述更新公式可以简化成如下形式:

$$NewEstimate \leftarrow OldEstimate + StepSize \cdot (Target - OldEstimate)$$

注意:

- 表达式 $[Target - OldEstimate]$ 是估计误差, 通过朝着“ $Target$ ”迈出一步来减少这个误差。假定目标指示了移动的理想方向, 尽管可能存在噪音。在上述情况下, 例如, 目标是第 n 个奖励。
- 需要注意的是, 增量方法中使用的步长参数 ($StepSize$) 会随着时间步长的变化而变化。在处理动作 a 的第 n 个奖励时, 该方法使用步长参数 $1/n$ 。在本书中, 我们用符号 α 或更一般地用 $\alpha_t(a)$ 来表示步长参数。

多臂老虎机增量实现伪代码

- 完整的使用增量计算样本平均值和 ϵ -贪心动作选择的强盗算法的伪代码如下所示。其中假设函数**bandit(a)** 接受一个动作并返回相应的奖励。

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \operatorname{argmax}_a Q(a) & \text{with probability } 1 - \epsilon \quad (\text{breaking ties randomly}) \\ \text{a random action} & \text{with probability } \epsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

$$N(A) \leftarrow N(A) + 1$$

$$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

多臂老虎机相关问题延伸举例



医生为多个重病患者选择治疗方法。每个行动对应一种治疗方法，奖励是患者的存活或健康状况



股票市场选股

总结

- 多臂老虎机问题强化学习形式化描述
- 如何设计策略，兼顾利用和探索
- 多臂老虎机动作价值增量计算方式