






第三章：有限马尔可夫决策过程（续）

何新卫

华中农业大学信息学院

RL关键任务：价值函数估计



回顾：价值函数

- **状态价值函数** (state value function)：评估智能体在环境中状态 $s \in \mathcal{S}$ 有多好？
- **动作（或状态-动作）价值函数**：智能体在状态 $s \in \mathcal{S}$ 下执行动作 $a \in \mathcal{A}(s)$ 有多好？
- 其实是要**评估回报期望**
 - 状态和动作的回报具有随机性






图 3.3: 状态空间是 $\mathcal{A} = \{\text{左}, \text{中}, \text{右}\}$ 。把当前状态 s 输入策略函数，策略函数输出三个概率值：0.2, 0.1, 0.7。所以，对于确定的状态 s ，智能体执行的动作是不确定的，三个动作都可能被执行。

- 回报和未来有关，未来和执行策略有关，具有**随机性**
- 价值**不具有随机性**，是一个**回报的期望值**，且和策略 $\pi(a|s)$ 绑定，有唯一值

例题

□ MDP环境，假设当前状态为 $S_t = s$ ，动作选择遵循随机策略 π ，则根据 π 和四参数 $p(s', r | s, a)$ ，计算奖励 R_{t+1} 的期望。

$$\mathbb{E}_{\pi} [R_{t+1} | S_t = s] = \sum_a \pi(a | S_t = s) \sum_{s'} \sum_r r p(s', r | s, a)$$



□ 备份图 (Backup diagram) :

- 节点：
 - 空心圈：状态
 - 实心圈：动作
- 边：相应转移概率作为权重
- 单向图

状态价值

□状态价值：智能体在策略 π 下状态 s 的价值，记 $v_\pi(s)$ ，定义如下：

$$v_\pi(s) \triangleq \mathbb{E}_\pi [G_t | S_t = s] = \mathbb{E}_\pi [\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s], \text{ for all } s \in \mathcal{S}$$

- $\mathbb{E}_\pi [\cdot]$ 代表智能体遵循某个策略 π 期望，时间步 t
- $v_\pi(\cdot)$ 表示智能体在策略 π 下状态价值函数


动作价值函数

□动作价值：智能体一直遵循策略 π ，位于状态 s 执行动作 a 的期望回报，记 $q_\pi(s, a)$

$$q_\pi(s, a) \triangleq \mathbb{E}_\pi [G_t | S_t = s, A_t = a] = \mathbb{E}_\pi [\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a]$$

□动作价值函数： $q_\pi(\cdot)$ 代表智能体在策略 π 下的动作（或状态-动作）价值函数

v_π 关于 q_π 和 π 的关系



$$v_\pi(s) = \sum_a \pi(a|s) q_\pi(s, a)$$


这个状态的平均价值

□ 空心圈：状态，实心圈：动作

□ 价值信息从一个状态（或状态-动作对）的后继状态（或状态-动作对）转移回该状态

例题


1) 给定折扣 γ , $p(s', r | s, a)$, 画出 $q_\pi(s, a)$ 和 $v_\pi(s')$ 的备份图, 并写出关系式



$$q_\pi(s, a) = \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) [r + \gamma v_\pi(s')]$$

优势函数 (Advantage Function)

□ **优势函数**：强化学习中，我们不需要从绝对意义上描述一个动作有多好，而只需要知道它相对其他动作平均来说有多好，即该动作的相对优势，即优势函数。



$$A_{\pi}(s, a) = q_{\pi}(s, a) - v_{\pi}(s)$$
$$= q_{\pi}(s, a) - \sum_{a \in \mathcal{A}} \pi(a|s) q_{\pi}(s, a)$$

状态 s 下采取动作 a
并随后按照策略 π 行
动所获得的预期回报

状态 s 下按照策略 π 行
动所获得的预期回报

v_π 的 贝尔曼方程 (Bellman equation)


□ 对于任意一个策略 π ，和任意一个状态 s ，则状态 s 和其后继状态的价值满足如下递归式：

$$\begin{aligned} v_\pi(s) &\triangleq \mathbb{E}_\pi [G_t | S_t = s] \\ &= \mathbb{E}_\pi [R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) [r + \gamma v_\pi(s')] \text{ for all } s \in \mathcal{S} \end{aligned}$$

注意：任意策略！！，其状态价值函数都满足该公式


• 这里隐含了动作 $a \in \mathcal{A}(s)$ ，下一个状态 $s' \in \mathcal{S}$ ，奖励 $r \in \mathcal{R}$

$v_\pi(s)$ 的备份图：



例题：一个简单有限MDP过程

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) [r + \gamma v_{\pi}(s')] \text{ for all } s \in \mathcal{S}$$




□ 状态空间： $\mathcal{S} = \{s_A, s_B, s_C, s_D\}$

□ $r=0.7$ ，奖励如图所示

□ 问题：求解状态价值函数（即计算每个状态对应的价值）

□ 解法：解决线性方程组即可(n个未知量，n个线性方程组)

$$\begin{cases} v_{\pi}(s_A) = 0.25[5 + 0.7v_{\pi}(s_B)] + 0.25[0 + 0.7v_{\pi}(s_C)] + 0.5[0 + 0.7v_{\pi}(s_A)] \\ v_{\pi}(s_B) = 0.5[5 + 0.7v_{\pi}(s_B)] + 0.25[0 + 0.7v_{\pi}(s_A)] + 0.25[0 + 0.7v_{\pi}(s_D)] \\ v_{\pi}(s_C) = 0.25[0 + 0.7v_{\pi}(s_A)] + 0.25[0 + 0.7v_{\pi}(s_D)] + 0.5[0 + 0.7v_{\pi}(s_C)] \\ v_{\pi}(s_D) = 0.25[5 + 0.7v_{\pi}(s_B)] + 0.25[0 + 0.7v_{\pi}(s_C)] + 0.5[0 + 0.7v_{\pi}(s_D)] \end{cases}$$




$$\begin{cases} v_{\pi}(s_A) = 4.2 \\ v_{\pi}(s_B) = 6.1 \\ v_{\pi}(s_C) = 2.2 \\ v_{\pi}(s_D) = 4.2 \end{cases}$$


$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) [r + \gamma v_{\pi}(s')]$$



练习题：基于备份图，写公式



$$V_\pi = \sum_a q_\pi(s, a) \pi(a|s)$$



$$q_\pi(s, a) = \sum_{s', r} [r + \gamma v_\pi(s')] p(s', r|s, a)$$

最优策略和最优价值函数

□ 策略 π 比策略 π' 不差，则对于所有状态 s 有如下

$$v_\pi(s)$$

□ 最优策略 (π_*)：至少存在一种策

□ 最优策略共享同一个最优状态价值


$$v_*(s) :$$

□ 若存在多个最优策略，则他们共享

$$q_*(s, a) \triangleq \max_{\pi} q_{\pi}(s, a), \text{ for all } s \in \mathcal{S}, a \in \mathcal{A}(s)$$

□ $q_*(s, a)$ 和 $v_*(s)$ 的关系：


$$q_*(s, a) = \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a]$$



$$\pi_1 \geq \pi_2$$

思考题


以下两个确定性策略，哪一个策略更好？



π



状态价值计算



π'



-1.1	-1.1
-0.5	-1.2

$v_{\pi}(\cdot)$

0.8	1.0
2.0	-8

$v_{\pi'}(\cdot)$



根据定义，并不能说策略 π' 比策略 π 好！

寻找最优策略

□ 对有限马尔可夫模型，确定性策略的个数是： $|\mathcal{A}|^{|\mathcal{S}|}$

- **穷举法：**我们通过状态价值函数评估每一个策略，则需要评估 $|\mathcal{A}|^{|\mathcal{S}|}$ ，记录为 $v_{\pi_1}(\cdot), v_{\pi_2}(\cdot), v_{\pi_3}(\cdot), \dots, v_{\pi_{|\mathcal{A}|^{|\mathcal{S}|}}}(\cdot)$
- 然后遍历比较一遍，即可搜索到最优策略。
- 穷举法效果不高，后面将通过策略迭代或价值迭代两种方法求解（第四章）。

贝尔曼最优方程 (Bellman optimality equation)

在**最优策略**下，**一个状态的价值**必须等于在**该状态下执行最优动作的价值**。

□ v_* 的贝尔曼最优方程

$$\begin{aligned} v_*(s) &= \max_{a \in \mathcal{A}(s)} q_{\pi_*}(s, a) \\ &= \max_a \mathbb{E}_{\pi_*}[G_t \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}_{\pi_*}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_*(s')]. \end{aligned}$$

贝尔曼最优方程的两种形式（注意：**不依赖于具体的策略**）

□ q_* 的贝尔曼最优方程

$$\begin{aligned} q_*(s, a) &= \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right] \\ &= \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right]. \end{aligned}$$

注意：任意的s,a,对应q值

贝尔曼最优方程的备份图




Figure 3.4: Backup diagrams for v_* and q_*

思考题：你能基于备份图，写出贝尔曼最优方程吗？

基于最优价值函数的最优策略

$$\pi_*(a|s) = \operatorname{argmax}_{a \in \mathcal{A}(s)} q_*(s, a), \text{ for all } s \in \mathcal{S}$$

$$\begin{bmatrix} q_*(s_1, a_1) & \cdots & q_*(s_1, a_1) \\ \vdots & \ddots & \vdots \\ q_*(s_{|\mathcal{S}|}, a_1) & \cdots & q_*(s_{|\mathcal{S}|}, a_{|\mathcal{A}|}) \end{bmatrix} \xrightarrow[\text{按行argmax}]{\text{最优策略提取}} \pi_*(a|s) = \begin{bmatrix} \pi_*(a|s_1) \\ \pi_*(a|s_2) \\ \cdots \\ \pi_*(a|s_{|\mathcal{S}|}) \end{bmatrix} = \begin{bmatrix} a_{j_1} \\ a_{j_2} \\ \cdots \\ a_{j_{|\mathcal{S}|}} \end{bmatrix}$$

最优动作价值函数 q_*

$$\pi_*(a|s) = \operatorname{argmax}_{a \in \mathcal{A}(s)} \sum_{s', r} p(s', r|s, a) [r + \gamma v_*(s')], \text{ for all } s \in \mathcal{S},$$

总结

- MP, MRP, MDP
- 奖励期望和回报期望有什么区别
- 状态价值、动作价值
- 贝尔曼方程
- 最优策略