



华中农业大学
HUAZHONG AGRICULTURAL UNIVERSITY

强化学习结课报告

姓名: 陈佳伸
所在班级: 人工智能 2302
所在院系: 信息学院
指导老师: 何新卫

2026 年 5 月 3 日

目录

1 本课程总结	3
1.1 强化学习导论与核心概念	3
1.2 多臂老虎机问题：探索与利用的博弈	3
1.3 马尔可夫决策过程：强化学习的数学基石	4
1.4 动态规划：基于模型的精确求解	4
1.5 蒙特卡洛方法：无模型经验采样	5
1.6 时序差分学习：自举与采样的完美结合	5
1.7 策略梯度与前沿进展	6
2 个人思考和展望	6
2.1 理论与实践的碰撞：从数学方程到代码实现	6
2.2 强化学习重塑大语言模型：以 DeepSeek-R1 为鉴	7
2.3 泛化与落地：物理世界中的强化学习展望	7
2.4 关于伦理、安全与可解释性的哲学思考	8
2.5 结语	8

1 本课程总结

强化学习 (Reinforcement Learning, RL) 作为机器学习的三大主流范式之一, 在近年来取得了突破性的进展。从击败人类顶尖棋手的 AlphaGo, 到如今具备强大逻辑推理能力的大语言模型 (如 DeepSeek-R1), 强化学习在其中都扮演了不可或缺的核心角色。本学期的课程内容结构严密、循序渐进, 从最基础的概念出发, 逐步深入到马尔可夫决策过程、经典表格型算法, 最终拓展至策略梯度等高阶内容。以下是对本学期所学核心知识点的系统性总结。

1.1 强化学习导论与核心概念

在第一讲中, 课程首先明确了强化学习在人工智能领域中的定位。与依赖大量人工标注数据的有监督学习, 以及旨在挖掘数据内在结构的无监督学习不同, 强化学习的核心在于“交互”与“试错”。智能体 (Agent) 在复杂、不确定的环境 (Environment) 中, 通过不断执行动作 (Action), 改变环境的状态 (State), 并从中获取延迟的奖励信号 (Reward), 其最终目标是最大化长期累积奖励的期望。

这种学习范式极具仿生学意义。正如课程中提到的“刚出生的羚羊学习站立”, 自然界中的生物必须在没有明确指令的情况下, 通过跌倒和重新站起 (试错) 来掌握生存技能。这种机制被严格形式化后, 便构成了强化学习的理论基础。强化学习系统有几个关键术语: 状态、动作、奖励、策略 (Policy) 和价值函数 (Value Function)。其中, 策略决定了智能体在特定状态下应该采取什么动作; 价值函数则用于评估在某个状态下, 或者在某个状态执行某个动作后, 长远来看能获得多大的期望回报。评估当前动作的好坏, 不能仅仅依靠即时奖励, 而必须考虑整个轨迹 (Trajectory) 的后续收益。

1.2 多臂老虎机问题: 探索与利用的博弈

第二讲通过多臂老虎机 (Multi-Armed Bandit, MAB) 问题, 深刻揭示了强化学习中最基础但也最核心的矛盾——探索与利用 (Exploration vs. Exploitation) 的困境。MAB 问题是一种简化版的强化学习环境, 它只有一个状态, 智能体面临 K 个动作 (摇动不同的拉杆), 每个动作背后的奖励服从未知概率分布。

为了最大化总收益, 智能体需要对每个动作的潜在价值进行估计。传统的做法是计算历史奖励的算术平均值, 但这种方法会随着数据量增加而导致内存与计算成本呈线性增长。课程引入了“增量实现 (Incremental Implementation)”公式:

$$Q_{n+1} = Q_n + \frac{1}{n}(R_n - Q_n) \quad (1)$$

这一公式极其优雅, 它揭示了“新估计值 = 老估计值 + 步长 $\times$ (目标值 - 老估计值)”的普遍更新规律, 这一思想贯穿了后续所有的时序差分学习算法。

在动作选择上, 如果完全依赖当前的估值 (贪心策略), 智能体很容易陷入局部最优, 错过潜在的高收益动作。为此, 引入了 ϵ -贪心 (ϵ -greedy) 算法, 即以 $1 - \epsilon$ 的概率

选择当前最优动作，以 ϵ 的概率随机探索未知动作。这种简单的机制在理论上保证了在无限时间下，所有动作都会被充分采样，从而得到准确的价值评估。

1.3 马尔可夫决策过程：强化学习的数学基石

第三讲和第四讲系统介绍了马尔可夫决策过程 (Markov Decision Process, MDP)，这是强化学习用于建立动力学模型的严密框架。MDP 建立在马尔可夫性质之上，即“未来状态仅取决于当前状态，而与历史状态条件独立”。这一假设极大地简化了复杂环境的建模难度。

课程从简单的马尔可夫过程 (MP) 讲起，引入奖励机制形成马尔可夫奖励过程 (MRP)，最后引入动作空间，构成了完整的 MDP 模型。有限 MDP 的环境动态由一个核心的四参数转移概率函数定义：

$$p(s', r|s, a) = \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\} \quad (2)$$

在 MDP 中，为了评估长远收益，引入了折扣回报 (Discounted Return) 的概念，使用折扣因子 $\gamma \in [0, 1]$ 来平衡近期奖励与远期奖励的权重，同时确保了无限序列中总回报的收敛性。基于回报，课程严谨地定义了状态价值函数 $v_\pi(s)$ 和动作价值函数 $q_\pi(s, a)$ 。

整个 MDP 理论的核心在于贝尔曼期望方程 (Bellman Expectation Equation) 与贝尔曼最优方程 (Bellman Optimality Equation)。贝尔曼方程揭示了当前状态价值与后继状态价值之间的递归关系：

$$v_*(s) = \max_a \sum_{s', r} p(s', r|s, a) [r + \gamma v_*(s')] \quad (3)$$

该方程表明，一旦找到了最优价值函数，我们只需在每个状态上执行能够最大化后续期望价值的动作，即可直接提取出最优策略 π_* 。这为后续算法设计提供了明确的优化目标。

1.4 动态规划：基于模型的精确求解

第五讲聚焦于动态规划 (Dynamic Programming, DP)。DP 方法要求环境动态（即转移概率矩阵）是完全已知的，它利用了贝尔曼方程的结构进行迭代计算。DP 的核心思想是“自举” (Bootstrapping)，即利用对后继状态的现有估值来更新当前状态的估值。

课程详细推导了策略迭代 (Policy Iteration) 算法。该算法包含两个交替进行的步骤：策略评估（通过反复迭代计算当前策略的真实价值）和策略改进（基于最新的价值函数，通过贪心算法生成更优的策略）。只要 MDP 是有限的，策略迭代最终必定收敛至最优策略。

为了克服策略评估步骤耗时过长的问题，课程进一步介绍了价值迭代 (Value Iteration)。价值迭代不再等待策略评估完全收敛，而是在进行一次全状态扫描后，直接利用

贝尔曼最优方程进行截断式更新：

$$v_{k+1}(s) = \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma v_k(s')] \quad (4)$$

价值迭代将策略评估的一步更新与贪心改进融为一体，极大地提升了计算效率，是模型已知情况下的强大求解工具。

1.5 蒙特卡洛方法：无模型经验采样

第六讲转向了现实中更常见的情况：环境动态未知 (Model-free)。此时动态规划失效，蒙特卡洛 (Monte Carlo, MC) 方法应运而生。MC 方法彻底摒弃了自举，转而让智能体在环境中实际交互，生成完整的状态-动作-奖励轨迹，然后利用大数定律，通过计算轨迹的实际平均回报来无偏地估计价值函数。

MC 方法分为首次访问 (First-visit) 和每次访问 (Every-visit) 两种变体，主要应用于具有明确终点的回合制 (Episodic) 任务中。为了在未知环境中寻找最优策略，课程详细讲解了基于 MC 的广义策略迭代 (GPI)，并在其中引入了探索机制。

在无模型控制中，为了彻底分离“用于探索数据的策略”和“需要优化的目标策略”，课程重点探讨了异策略 (Off-policy) MC 学习。异策略学习必须依赖重要性采样 (Importance Sampling) 技术，通过轨迹在两个策略下发生概率的比值 (重要性权重) 来修正期望回报。课程还对比了普通重要性采样 (方差大、无偏) 与加权重要性采样 (方差小、微小有偏) 的优劣，为后续更复杂的离线强化学习奠定了统计学基础。

1.6 时序差分学习：自举与采样的完美结合

第七讲介绍的时序差分 (Temporal-Difference, TD) 学习被认为是强化学习领域最伟大的突破。TD 学习巧妙地融合了动态规划的自举特性与蒙特卡洛的无模型采样特性。正如课程中生動的“北京到郑州高铁预估时间”案例所示，TD 不需要等待一个完整的回合结束，而是在每执行一步动作后，利用获得的即时奖励和对下一个状态的现有估值，立即对当前状态的价值进行更新。

TD(0) 的核心更新公式为：

$$V(S_t) \leftarrow V(S_t) + \alpha [R_{t+1} + \gamma V(S_{t+1}) - V(S_t)] \quad (5)$$

基于 TD 理论，课程详细剖析了两种统治级的表格型控制算法：Sarsa 与 Q-Learning。

- **Sarsa 算法**是一种同策略 (On-policy) 算法。它严格依赖一次实际交互产生的五元组 $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$ 进行更新，其目标构建使用了下一步实际采取的动作。这使得 Sarsa 在学习过程中相对保守，更注重探索过程中的安全性。
- **Q-Learning 算法**则是异策略 (Off-policy) 的典范。它在计算更新目标时，直接选取下一个状态的最大可能动作价值 $\max_a Q(S_{t+1}, a)$ 。这一突破性设计斩断了目

标策略与行为策略的耦合，使得智能体可以放肆探索，同时在后台稳定逼近最优策略，更为后来深度强化学习中经验回放机制的引入铺平了道路。

1.7 策略梯度与前沿进展

第八讲也是最后一讲，课程带领我们跨越了表格型强化学习的边界，进入了基于函数逼近（Function Approximation）的高阶领域。在连续动作空间或极高维度的状态空间（如倒立摆 CartPole 任务、围棋盘面）中，无法再用表格存储价值。策略梯度（Policy Gradient, PG）方法不通过价值反推策略，而是使用带参数的数学模型（如深度神经网络 θ ）直接拟合策略分布 $\pi_\theta(a|s)$ 。

策略梯度的核心在于最大化预期回报目标函数 $J(\theta)$ ，通过对数导数技巧推导出著名的策略梯度定理：

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s, a) \nabla_\theta \pi_\theta(a|s) \quad (6)$$

课程从最原始的高方差 REINFORCE 算法讲起，为了降低方差，引入了基线（Baseline），进而推出现代深度强化学习的基石——Actor-Critic（演员-评论家）架构。Actor 负责输出策略概率，Critic 负责利用 TD 误差评估策略的优劣，二者协同进化。

最后，课程提及了近端策略优化（Proximal Policy Optimization, PPO）算法。PPO 通过巧妙的裁剪机制（Clip）约束了策略更新的幅度，避免了学习过程中的策略崩溃。作为当今工业界应用最广泛的算法之一，PPO 为本学期的理论教学画上了圆满的句号。

2 个人思考和展望

经过一个学期的深入学习，我对强化学习这一领域不仅建立起了系统的理论认知，更对其在人工智能宏大图景中所处的地位有了深度的思考。强化学习远不止是一系列用于通关小游戏或走迷宫的数学公式，它本质上是一种关于“决策、优化与演进”的通用计算框架。以下是我在课后的几点深刻感悟与对该领域未来发展的展望。

2.1 理论与实践的碰撞：从数学方程到代码实现

在课程初期，面对密集的概率论公式和马尔可夫链证明，我曾感到相当大的认知阻力。尤其是贝尔曼期望方程展开后的重重求和符号，显得十分抽象。然而，当我开始在作业中亲手使用 Python 在网格世界（GridWorld）中编写代码时，理论与实践的壁垒瞬间被打通了。

我深刻体会到，代码中那个维护价值字典的数组，就是状态空间的具象化；而嵌套的 for 循环，正是在执行贝尔曼方程的期望求和。在实现蒙特卡洛方法与时序差分算法的对比时，我亲眼观察到：蒙特卡洛方法在回合早期犹如无头苍蝇，必须等到数万次回合后价值函数才慢慢成型；而 Q-Learning 算法在经历了几百步的试错后，价值矩阵就

像波纹一样迅速从终点向起点反向传递，迅速规划出一条最优路径。这种将抽象数学理论转化为可见的智能行为的过程，赋予了我极大的学术成就感。我也认识到，强化学习的学习不能仅停留在纸面公式推导，必须深入到“探索率衰减、学习率微调、奖励函数重塑”等工程细节中，才能真正掌握其精髓。

2.2 强化学习重塑大语言模型：以 DeepSeek-R1 为鉴

课程第一讲就极具前瞻性地提到了目前炙手可热的 DeepSeek-R1 大语言模型。在学习策略梯度和 PPO 算法后，我对强化学习如何重塑大模型有了茅塞顿开的理解。

过去，大语言模型的能力瓶颈在于有监督微调 (SFT)。无论向模型喂给多少高质量的人类代码或数学解答，模型本质上只是在进行“词元接龙”式的分布模仿，并未真正学会逻辑推理。而强化学习 (RLHF 机制) 彻底改变了这一困局。对于诸如 DeepSeek-R1 这类旨在突破数学与逻辑推理天花板的模型，研究者采用了甚至不依赖先验 SFT 的纯强化学习架构。系统给出一个数学题，模型自己生成答案（动作序列），环境通过判断答案是否正确以及推理过程是否符合逻辑来给予奖励。

在这一过程中，课程中讲授的 PPO 算法，以及基于相对奖励的群体相对策略优化 (GRPO)，发挥了决定性的作用。模型为了获取更高的奖励回报，开始在内部进行复杂的试错，自发地演化出了“顿悟” (Aha-moment)、“自我反思与修正”以及长程思维链 (CoT) 等高级认知行为。可以说，没有强化学习对长期延迟奖励的优化机制，大模型就永远停留在鹦鹉学舌的阶段；正是强化学习赋予了 AI 系统挣脱人类语料数据束缚、向上探索引擎逻辑极限的能力。这是我对强化学习最震撼的认知升级。

2.3 泛化与落地：物理世界中的强化学习展望

尽管强化学习在虚拟环境和虚拟语言空间取得了巨大成功，但我认为，该领域在未来五到十年最大的突破将发生在其向物理世界的大规模下沉与渗透，特别是与具身智能 (Embodied AI) 和运筹调度的深度融合。

首先，在自动驾驶与机器人控制领域。目前基于规则的方法面临着无数不可预见的长尾边缘场景 (Corner Cases)。基于策略梯度的深度强化学习，允许机器人在企业级高保真物理模拟器中进行亿万次的虚拟碰撞与试错。通过学习如何从视觉和激光雷达像素直达底盘控制的“端到端” (End-to-End) 映射，具身机器人将不再僵硬，而是能展现出如同人类跑酷运动员般的柔韧与适应性。

其次，在智慧能源与供应链调度中。传统的运筹学依赖于复杂的整数规划求解器，面对动态突发的物流中断或电网负荷激增，往往计算耗时过长。而经过离线强化学习 (Offline RL) 训练的决策系统，能够在几毫秒内基于当前路网或电网的观测状态，直接输出近似最优的调度动作，从而在个性化医疗资源分配、无人仓储自动分拣等场景释放巨大的商业与社会价值。

2.4 关于伦理、安全与可解释性的哲学思考

任何强大的技术都伴随着隐患，强化学习也不例外。在课程结尾的思考中，我愈发意识到“安全强化学习”（Safe RL）与“可解释性”的迫切性。

传统的强化学习是一个为了最大化奖励不择手段的黑盒。在虚拟游戏中，智能体为了拿高分可以无限次牺牲；但如果在医疗诊断系统中，智能体为了探索新的药物组合而拿患者的生命试错，则是绝对违反伦理的。这就要求我们在设计奖励函数（Reward Shaping）时必须极其谨慎，如何将人类的道德准则、法律红线转化为算法能理解的惩罚项？如何确保智能体在探索过程中始终被约束在一个安全的“护栏”之内？

此外，决策的不可解释性是阻碍其进入关键工业领域（如核电站控制、航空管制）的最大障碍。未来，我们需要研究如何将深度神经网络提取的高维策略，逆向转化为人类可读的决策树或逻辑规则。只有当人类审计员能够清晰追踪系统每一步决策的因果链条时，人机协作才具备真正的信任基础。

2.5 结语

回首整个学期的课程，《强化学习》为我打开了一扇理解智能本质的全新大门。从简单的多臂老虎机到深奥的策略梯度理论，从枯燥的马尔可夫转移矩阵到激动人心的大语言模型推理突破，这门课程不仅极大地拓宽了我的专业视野，更培养了我以“动态交互”和“长期回报”来剖析复杂系统的方法论。

随着算力的爆炸式增长和算法范式的不断重构，强化学习正处于从实验室走向物理现实的关键奇点。我相信，掌握这一核心计算范式，将在未来的人工智能浪潮中赋予我们解决实际复杂问题的关键能力。感谢老师一学期以来的悉心教导与硬核的理论推导，这将是我的学术生涯中一笔无比宝贵的财富。