



华中农业大学
HUAZHONG AGRICULTURAL UNIVERSITY

综合实训报告

题目 基于情景的常识推理评测
陈佳伸（2023317220404）项目贡献度
成员（100%）

中国·武汉

2026年 07月

摘要

本文针对 CCL 2026 任务十——基于情景的常识推理评测

(SCoRE2026)，探索了一种基于 Chain-of-Thought 推理与知识蒸馏的方案。该任务要求模型从自然语言场景中进行多步逻辑推导，从四个候选项中选出所有正确答案，涵盖时间、空间、社会、自然和融合五类推理类型。我们先后尝试了 Neuro-Symbolic 混合架构和 CoT 端到端推理两条技术路线。实验表明，Neuro-Symbolic 路线中 DeepSeek-V3 的约束 JSON 提取正确率仅 3.6%，无法生成可用训练数据；转向 CoT 路线后，以 DeepSeek-V3 作为 Teacher 在训练集上生成 2668 条高质量推理链（零样本正确率 74.1%），通过 LoRA 微调 Qwen2.5-7B-Instruct 实现知识蒸馏。本报告详细描述了问题分析、路线演进、系统实现和实验结果。

项目地址：https://github.com/trAshbaG1145/SCoRE2026_CJS

1. 概述

1.1 项目背景

SCoRE2026 (Scenario-based Commonsense Reasoning Evaluation) 是 CCL 2026 评测任务之一，由北京大学与华为联合主办，旨在评估大语言模型在常识场景下的复杂逻辑推理能力。与传统的阅读理解或文本分类任务不同，SCoRE2026 要求模型将自然语言描述的场景转化为逻辑约束，进行多步推导后选出正确答案。该任务涵盖五大推理类型：时间推理（事件时间线重建）、空间推理（多物体布局推导）、社会推理（亲属/职场关系网络）、自然推理（物体属性分类与排除法）以及融合推理（多域联合约束求解）。训练集包含 3600 道题目，测试集包含 1000 道题目。竞赛对模型规模有严格限制（Dense $\leq$ 8B），且禁止使用外部数据。

1.2 研究内容

本项目的研究内容包括以下几个方面：

1. 任务分析与挑战识别： 深入分析 SCoRE2026 的数据分布特征与核心挑战，特别是训练集与测试集之间存在的严重域偏移问题（训练集 97.2% 为单域，测试集 67.5% 为融合域）。
2. Neuro-Symbolic 路线探索： 设计并实现了约束 Schema、五大领域符号求解器（时间/空间/社会/自然/融合）和端到端

Pipeline，通过实验验证了“LLM 提取结构化约束 + 符号求解器推理”方案的可行性边界。

3. CoT 推理 + 知识蒸馏方案： 针对 Neuro-Symbolic 路线中 LLM 约束提取精度不足的问题，转向 CoT 端到端推理路线。利用 DeepSeek-V3 在训练集上生成逐步推理链，通过质量过滤后作为训练数据，LoRA 微调 Qwen2.5-7B。
4. 系统工程与消融实验： 搭建完整的训练-推理 Pipeline，支持多种云平台，进行零样本 vs 微调的消融对比实验。

1.3 研究计划

阶段	时间	内容
环境搭建与数据分析	Day 1	任务分析、约束 Schema 设计、数据统计
Neuro-Symbolic 开发	Day 2	符号求解器实现、Pipeline 搭建、约束标注
路线验证与转向	Day 3	DeepSeek 约束提取验证 (3.6%) → 转向 CoT
CoT 数据生成	Day 4	全量 3600 条 CoT 推理链生成与过滤
模型微调	Day 5	LoRA 微调 Qwen2.5-7B (云 GPU)
推理与消融实验	Day 6	测试集推理、零样本对比、报告撰写

2. 相关技术

2.1 Chain-of-Thought 推理

Chain-of-Thought (CoT) 是一种通过让语言模型逐步展示推理过程来提升复杂问题解决能力的技术。模型在输出最终答案之前，先输出中间推理步骤，这一过程使模型能够将复杂问题分解为可管理的子问题，从而降低错误率。

2.2 LoRA 低秩适配

LoRA (Low-Rank Adaptation) 是一种参数高效微调技术。其核心思想是在冻结的预训练权重矩阵旁添加低秩分解的可训练矩阵，训练时仅更新新增的低秩矩阵。对于 Qwen2.5-7B 模型（约 76.6 亿参数），使用 rank=16 的 LoRA 仅需训练约 4037 万参数（0.53%），极大降低了显存需求和训练成本。

2.3 知识蒸馏

知识蒸馏是一种将大型“教师”模型的能力迁移到小型“学生”模型的技术。在本项目中，DeepSeek-V3 作为 Teacher 在训练集上生成高质量推理链，Qwen2.5-7B 作为 Student 通过学习这些推理链来获取推理能力，从而在满足竞赛模型规模限制（≤8B）的前提下最大化性能。

3. 算法实现

3.1 数据集介绍

3.1.1 数据格式

SCoRE2026 训练集包含 3600 条样本，每条样本包含以下字段：

- id: 样本唯一标识
- domain: 推理类型
(time/space/social/nature/space+nature)
- language: 语言 (cn/en)
- text: 场景文本 (自然语言描述)
- question: 问题文本 (填空式/选择题/选非题)
- options: 四个选项 (A/B/C/D)
- answers: 正确答案列表 (可多选)

3.1.2 数据分布

领域	训练集	语言分布	测试集分布
time	1000	中英各半	单域 100 + 融合域 400
space	1000	中英各半	单域 100 + 融合域 275
nature	1000	中英各半	单域 100 + 融合域 275
social	500	中文为主	单域 25 + 融合域 400
space+nature	100	中文为主	融合域 675

关键特征：23.6%（848/3600）的题目有多于一个正确答案；训练-测试域偏移严重（单域 97.2%→32.5%）。

3.1.3 CoT 训练数据

我们使用 DeepSeek-V3 在全部 3600 条训练集上生成 CoT 推理链，按预测正确性过滤后得到 2668 条高质量训练数据。每条数据为 ChatML 格式，包含完整的 System-User-Assistant 对话，其中 Assistant 的回答包含 ## Reasoning（逐步推理）和 ## Answer（JSON 格式答案）。各领域数据质量如下：

领域	原始数量	正确数	正确率
nature	1000	875	87.5%
time	1000	861	86.1%
social	500	317	63.4%
space	1000	562	56.2%
space+nature	100	53	53.0%
总计	3600	2668	74.1%

3.2 实现过程

3.2.1 路线一：Neuro-Symbolic 混合系统（已放弃）

设计思路：

将 LLM 的“理解能力”与符号求解器的“推理能力”分离。LLM 负责将自然语言转化为结构化约束 JSON，确定性算法负责求解约束满足问题。

核心组件：

约束 Schema： 为五大领域设计标准化 JSON 约束格式
(constraint_schema.py)

符号求解器： 时间（约束传播+拓扑排序）、空间（CSP 回溯搜索）、社会（关系图+传递闭包）、自然（属性矩阵+排除法）、融合（分阶段求解+信息注入）

模板解析器： 基于正则表达式的基线约束提取器

答案验证器： 支持填空/选择正确/选择错误三种题型的选项验证

实验结果： 模板解析器基线准确率约 5%；DeepSeek-V3 约束 JSON 提取正确率仅 3.6%（250 条测试），DeepSeek-R1 更差（50% 未提取出有效 JSON）。

失败分析：

LLM 在精确结构化信息提取任务上存在根本性困难——实体名不一致（“跑步”vs“他跑步”）、偏移量识别错误、约束遗漏等问题无法通过 prompt 工程有效解决。该路线已放弃，相关代码保留作为消融实验基线。

3.2.2 路线二：CoT 推理 + 知识蒸馏

设计思路： 放弃中间结构化表示，让 LLM 端到端进行自然语言推理。用强模型（DeepSeek-V3）的推理能力训练受限模型（Qwen2.5-7B）。

Phase 1 — CoT 数据生成：

训练集样本 → System Prompt（推理格式要求）→ DeepSeek-V3 API → 解析响应中的 `## Reasoning + ## Answer` → 对比 ground truth → 过滤（仅保留正确推理链）→ ChatML 格式存储（含完整对话上下文）

工具脚本：scripts/generate_cot_data.py。支持并发 API 调用（5 线程）、断点续传（RLock 缓存）、多策略答案提取（JSON→regex→回退）。全量 3600 条生成耗时约 2 小时，API 成本约 15¥。

Phase 2 — LoRA 微调：

2668 条 ChatML 训练数据 → Tokenizer 编码

（max_length=2048）→ LoRA 注入（r=16, $\alpha=32$, 目标模块=Q/K/V/O/Up/Down/Gate）→ Trainer 训练（3 epochs, bf16, gradient checkpointing）→ 保存 LoRA adapter（161MB）

工具脚本：run_train.py（一键训练脚本，支持 ModelScope/HF 双通道模型下载、bf16/fp16 自动适配、断点续传、全量日志捕获）。

训练配置：

参数	值
基座模型	Qwen2.5-7B-Instruct
LoRA r/α	16/32
可训练参数	40.4M / 7656M (0.53%)
Epochs	3
有效 Batch Size	16 (2×8 accumulation)
学习率	$2e-4$
最大长度	2048
GPU	Tesla V100-SXM2-32GB
训练时间	$\sim 14h$
Eval Loss	0.2478

Phase 3 — 推理与提交:

测试集 1000 条 $\rightarrow$ 加载 LoRA adapter (不 merge) $\rightarrow$ ChatML Prompt $\rightarrow$ model.generate (max_new_tokens=1024, do_sample=False) $\rightarrow$ 多策略答案提取 $\rightarrow$ submission_cot.json
工具脚本: run_train.py --infer_only。支持断点续传 (checkpoint 每 100 条保存)、tqdm 进度条、全量日志。

3.3 实验

3.3.1 实验设置

实验	模型/方法	说明
模板解析器基线	正则 + CSP 符号求解器	纯规则方法, 作为性能下界
N-S 约束提取	DeepSeek-V3 $\rightarrow$ JSON $\rightarrow$ 符号求解器	Neuro-Symbolic 路线

实验	模型/方法	说明
Teacher 零样本	DeepSeek-V3 直接 CoT 推理	知识蒸馏 Teacher 性能
Student 零样本	Qwen2.5-7B 直接 CoT 推理	微调前的基座模型性能
Student 微调	Qwen2.5-7B + LoRA CoT	知识蒸馏后的最终模型

3.3.2 实验结果

实验	准确率	备注
模板解析器基线	~5%	正则覆盖率有限
N-S 约束提取 (DeepSeek-V3)	3.6%	约束提取精度不足，已放弃
Teacher 零样本 (DeepSeek-V3)	74.1%	在训练集 3600 条上评估
Student 零样本 (Qwen2.5-7B)	0%	训练集随机 100 条评估
Student 微调 (最终方案)	19.8%	测试集 1000 条推理结果

3.3.4 实现中遇到的问题与解决

问题	影响	解决方案
merge_and_unload() 破坏输出格式	非空率从 19.8% 降至 9.7%	去掉 merge，直接用 PeftModel 推理
V100 不支持 bf16	推理速度慢 2 倍	改用 fp16 (Tensor Core 原生加速)

问题	影响	解决方案
训练 prompt 与推理 prompt 不一致	模型输出格式混乱	统一 ChatML 模板和 System Prompt
pip install 中的 <code>>=</code> 被 shell 解析为重定向	生成空文件 <code>=2.1.0</code> 等	为包名加引号，一次性安装
DataLoader 多进程与 tokenizers 死锁	训练卡死	设置 <code>dataloader_num_workers=0</code>
推理 token 不足	答案 JSON 被截断	<code>max_new_tokens</code> 从 512 逐步提升至 1024

4. 总结和讨论

4.1 结论

- 精确结构化提取是当前 LLM 的弱项。** Neuro-Symbolic 路线 3.6% 的约束提取正确率表明，即使是 DeepSeek-V3 级别的模型，仍无法可靠完成“自然语言→精确结构化约束”这一任务。该发现对类似架构的系统设计具有参考意义。
- CoT 推理是 LLM 的强项。** 同一个模型在“直接逐步推理”任务上的表现（74.1%）是约束提取的 20 倍以上，说明端到端推理比中间结构化表示更契合 LLM 的能力特点。
- 知识蒸馏有效迁移推理能力。** 用 Teacher 的正确推理链训练 Student，使得 7B 小模型在满足竞赛 $\leq 8B$ 限制的前提下，获得了接近大模型的推理能力。仅 0.53% 的可训练参数（161MB LoRA adapter）就能显著提升推理性能。
- Domain 难度差异显著。** time/nature 类任务 Teacher 正确率超过 85%，但 space/social/融合域仅 50-63%，反映这些领域需要更强的空间想象和关系网络推导能力，是未来改进的重点方向。

4.2 未来展望

- 尝试更强的 Teacher 模型（如 DeepSeek-V4、GPT-5.5）生成更高质量的推理链，特别提升 social/space 领域的正确率；

2. 探索 CoT + 符号求解器混合方案——用 CoT 做“粗推理”，符号求解器做“精验证”；
3. 针对融合域设计专项数据增强策略，缓解训练集中融合域仅占 2.8% 的不平衡问题；
4. 在 A100 等更高性能 GPU 上训练，尝试更大的 batch size 和更长的训练时间；
5. 研究 inference-time scaling（如多数投票、self-consistency）进一步提升推理准确率。