

# 第六章 农业大数据应用技术

|      |             |
|------|-------------|
| 尹江津  | 信息学院        |
| Q Q: | 1961015633  |
| 微 信: | 15674996078 |

---

## 6.1 农业大数据概述

## 6.2 农业大数据存储和管理

## 6.3 农业大数据分析与计算

## 6.4 农业大数据可视化

## 6.5 农业大数据应用案例

---

## 6.1 农业大数据概述

---

- **定义：** **农业大数据**指在现代农业生产、经营、管理、投资等各种活动中形成的，具有**高附加值的、多时空特征**的海量数据，包括生物信息数据、资源环境数据、气象数据、作物生长监测数据、市场营销数据、农业管理数据等，是**多维度、全样本、多类型**的数据集合。
  - **农业大数据研究**是利用大数据的理念、技术和方法，解决农业或涉农领域数据的采集、存储、分析与应用等一系列问题，是大数据的理论和技术在农业领域的应用与实践。
  - 农业大数据由**结构化数据、半结构化数据和非结构化数据**构成。
-

# 6.1 农业大数据概述

**结构化数据**，是指可由**二维表结构**来逻辑表达和实现的数据，严格地遵循数据格式与长度规范，主要通过关系型数据库进行存储和管理，也称作**行数据**。**特点是：**数据以行为单位，一行数据表示一个实体的信息，每一行数据的属性是相同的。

| 表 6-1 部分国家某年粮食产量与耕地情况（Agriculture） |       |       |
|------------------------------------|-------|-------|
| 国家                                 | 粮食总产量 | 耕地面积  |
| 中国                                 | 6.17  | 150.4 |
| 美国                                 | 4.4   | 166.9 |
| 印度                                 | 3.13  | 153.5 |
| 巴西                                 | 1.17  | 66.1  |
| 加拿大                                | 0.56  | 47.4  |
| （注：粮食总产量单位-亿吨，耕地面积单位-万平方公里）        |       |       |

# 6.1 农业大数据概述


- **半结构化数据**，是**结构化数据的一种形式**。属于同一类实体可以有**不同的属性**，而且**这些属性的顺序也不重要**。
- 半结构化数据包含相关标记，用来分隔语义元素以及对记录 and 字段进行分层。因此，也被称为**自描述的结构**。常见的半结构化数据格式有**XML和JSON**。

表 6-2 XML 和 JSON 数据格式

| XML 格式数据                                                                                                                                                                                                                                                                                                                                                                                     | JSON 格式数据                                                                                                                                                                                                                |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre>&lt;部分地区主要作物产量（万吨）&gt;   &lt;地区 名称="北京"&gt;     &lt;小麦&gt;18.7&lt;/小麦&gt;     &lt;玉米&gt;75.2&lt;/玉米&gt;   &lt;/地区&gt;   &lt;地区 名称="河北"&gt;     &lt;稻谷&gt;58.8&lt;/稻谷&gt;     &lt;玉米&gt;1703.9&lt;/玉米&gt;     &lt;小麦&gt;1387.2&lt;/小麦&gt;   &lt;/地区&gt;   &lt;地区 名称="广西"&gt;     &lt;稻谷&gt;1156.2&lt;/稻谷&gt;     &lt;甘蔗&gt;8104.3&lt;/甘蔗&gt;   &lt;/地区&gt; &lt;/部分地区主要作物产量（万吨）&gt;</pre> | <pre>{   "部分地区主要作物产量（万吨）":{     "北京":{       "小麦":18.7,       "玉米":75.2     },     "河北":{       "稻谷":58.8,       "玉米":1703.9,       "小麦":1387.2     },     "广西":{       "稻谷":1156.2,       "甘蔗":8104.3     }   } }</pre> |

# 6.1 农业大数据概述

**非结构化数据**，是数据结构不规则或不完整，没有预定义的数据模型，不方便用**数据库二维逻辑表**来表现的数据。包括所有格式的办公文档、文本、图片、HTML、各类报表、图像和音频/视频信息等等，一般存储为**二进制的**数据格式。




# 6.1 农业大数据概述

## 6.1.1 农业大数据的地位

大数据、物联网、云计算和人工智能作为信息化浪潮的代表技术，在农业领域应用越来越广泛。**大数据技术在整个技术体系中处于核心基础地位。**

- ① 农业大数据技术为**农业物联网**数据分析提供技术支撑
- ② 农业大数据为**云计算**提供了“用武之地”
- ③ 农业大数据为**人工智能**农业应用奠定了坚实基础



### 6.1.1 农业大数据的地位

**农业物联网感知设备源源不断产生着大量数据。物联网数据具有非结构化、碎片化、时空域等特性，需要新型的数据存储和处理技术，而大数据技术可支持物联网海量数据的更深层次的挖掘和应用。**

- The diagram illustrates the technological support for agriculture, showing the flow of data and processing. At the bottom left is the **农业物联网** (Agriculture IoT) section, featuring a globe with various agricultural icons (carrot, cow, tractor, house, etc.) connected by lines. A purple arrow points from the IoT section to the central **农业大数据** (Agriculture Big Data) section. This central section contains a word cloud with terms like **BIG DATA**, **ANALYTICS**, **STORAGE**, **COMPLEX DATABASES**, **RESEARCH**, **EXAMPLES**, **ABILITY**, **SETS**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**, **INCLUDE**, **SYSTEMS**, **NETWORKS**, **INFORMATION**, **RECORDS**, **SOFTWARE**, **SIZE**, **NEEDED**, **PARALLEL**, **PETABYTES**, **INTERNET**, **TECHNOLOGIES**, **SOCIAL**, **LARGE**, **CAPTION**, **MANAGEMENT**, **EVERY**, **DATA**, **SHARED**,

# 6.1 农业大数据概述

## 6.1.1 农业大数据的地位

### ② 农业大数据为云计算提供了“用武之地”

在农业领域，云计算与大数据二者已经彼此渗透、相互融合。云计算“用武之地”体现如下：

**基于云服务的海量农作物数据的存储：**农业信息数据量呈井喷式增长，传统服务器存储方式已不能满足需求。云服务可将海量数据进行PB级的存储、处理、分析，且云存储具有价格低廉、安全可靠、易于扩容的优点，为用户提供了数据挖掘的基础环境和能力

**基于云计算的农业生产数据处理：**在农业生产中会产生大量的信息数据，农业专家只有在定量分析的基础上才能做出准确判断和决策。因此，引入云计算智能分析技术，来满足农业生产管理所需的大规模计算资源至关重要。




## 6.1 农业大数据概述

### 6.1.1 农业大数据的地位

- ## ● 农业大数据为人工智能农业应用奠定了坚实基础

**农业大数据是人工智能技术在农业领域应用的基础，这是因为人工智能需要大量的数据来训练。人工智能应用的数据越多，其获得的结果就越准确。**

- 随着人工智能算法思想的不断发展及实际问题规模的逐步扩大，面对支撑人工智能算法的海量基础性数据，数据处理能力成为关键要素。农业大数据技术的不断发展，很大程度上满足了海量农业数据的检索及统计要求，从而使人工智能技术在农业领域能够更深入而广泛地应用。
- 农业大数据技术与人工智能的整合，可促进发挥各自的技术优势。而在具体整合中，农业大数据技术发挥了自身的基础性作用。农业大数据与人工智能的集成技术，正在不断提升各种农业应用的“智慧化”程度。




## 6.1 农业大数据概述

### 6.1.1 农业大数据的特征

在大数据理论中，大数据的特征通常被称为**5V特征**，农业大数据同样具备这些特征。


- **数据体量大 (Volume)**
- **数据类型多 (Variety)**
- **处理速度快 (Velocity)**
- **价值密度低 (Value)**
- **真实性 (Veracity)**



## 6.1 农业大数据概述

### 6.1.1 农业大数据的特征

- **数据体量大（Volume）**
  - 随着农业物联网技术的大范围应用，农业传感器开始广泛应用的农业各个环节，这些设备会源源不断的产生新数据，而且这种数据的产生方式是自动的，由此带来的是农业监测数据的**指数级增长**。
  - 例如，利用温室高通量表型平台监测玉米动态生长发育，1000盆植株每天产生的各类图像数据可达TB级；利用MicroCT获取籽粒显微图像，500份籽粒的图像信息可达到20TB。
  - 根据国际数据公司IDC的估测，数据一直都在以每年50%的速度增长，也就是说每两年就增长一倍，称之为**大数据摩尔定律**。



# 6.1 农业大数据概述

## 6.1.1 农业大数据的特征

- 数据体量大（Volume）

数据量单位与  
换算关系


| 单位  | 英文标识      | 单位标识 | 大小                   | 含意与例子                                                       |
|-----|-----------|------|----------------------|-------------------------------------------------------------|
| 位   | bit       | b    | 0或1                  | 计算机处理数据的二进制数                                                |
| 字节  | byte      | B    | 8位                   | 计算机存储数据的基本物理单元，存储一个英文字母用1个字节表示，一个汉字用2个字节表示                  |
| 千字节 | KiloByte  | KB   | 1024字节或 $2^{10}$ 个字节 | 一张纸上的文字约为5KB个字节                                             |
| 兆字节 | MegaByte  | MB   | $2^{20}$ 个字节         | 一个普通的MP3格式的歌曲约为4MB                                          |
| 吉字节 | GigaByte  | GB   | $2^{30}$ 个字节         | 一部电影大约是1GB                                                  |
| 太字节 | TeraByte  | TB   | $2^{40}$ 个字节         | 美国国会图书馆所有书籍的信息量约为15TB，截至2011年底其网络备份数据量为280TB，今后每个月以5TB的速度增长 |
| 拍字节 | PetaByte  | PB   | $2^{50}$ 个字节         | NASA EOS对地观测系统3年观测的数据量约为1PB                                 |
| 艾字节 | ExaByte   | EB   | $2^{60}$ 个字节         | 相当于中国13亿人每人一本500页书的数据量的总和                                   |
| 皆字节 | ZetaByte  | ZB   | $2^{70}$ 个字节         | 截至2010年人类拥有的信息量的总和约为1.2ZB                                   |
| 佑字节 | YottaByte | YB   | $2^{80}$ 个字节         | 超出想象<br>1YB=1024ZB=1 208 925 819 614 629 174 706 176 B      |
| 诺字节 | NonaByte  | NB   | $2^{90}$ 个字节         | 超出想象                                                        |
| 刀字节 | DoggaByte | DB   | $2^{100}$ 个字节        | 超出想象                                                        |

# 6.1 农业大数据概述

## 6.1.1 农业大数据的特征

### ● 数据类型多 (Variety)

- 农业大数据**采集方式**包括传感器、移动端、主流媒体等，
- 数据涉及农业生产、加工，农产品流通、消费等**全产业链**，
- **数据格式**有文本、图像、视频、音频、文档等结构化、半结构化和非结构化的数据，
- **空间上**从作物个体监测、个体农场管理、区域农业规划到国家农业产业，
- **时间上**涵盖历史数据、现状数据以及未来预测数据。



## 6.1 农业大数据概述

### 6.1.1 农业大数据的特征

- 处理速度快 (Velocity)

- 农业大数据的数量和类型都在不断增加，直接影响到的就是数据的处理速度。大数据时代的基本要求就是**速度要快**。
- 由于数据自身具有**时效性**，其所能挖掘的价值可能稍纵即逝，如果大量的数据来不及处理，就会变成**数据垃圾**。

**时效性 (Velocity) :** 数据需要在一定的时间限度下得到及时处理

**时效性 (Velocity) :** 数据需要在一定的时间限度下得到及时处理



## 6.1 农业大数据概述

### 6.1.1 农业大数据的特征

- 价值密度低 (Value)

价值密度可以理解成**有用数据在总数据中所占的比例**。价值密度低的原因如下：

- **数据本身冗余**：因为庞大的数据量和复杂的数据类型；
- **数据处理不及时**：因为处理速度过慢，无法迅速准确的获取有价值的数据。比如智能农业大棚中的各种农业传感器，往往是7×24小时工作的，数据源源不断的采集过来；



## 6.1 农业大数据概述

### 6.1.1 农业大数据的特征

- 真实性 (Veracity)

- 真实性指数据的准确性和可信赖度，即数据的质量；
- **面临挑战**：农业大数据相较于传统数据，数据真实性（准确性与可信赖度）问题更突出，严重影响后续存储、分析性能及数据质量保障。
- **关键原因**：数据源（尤其是传感器、网站、应用等）的**稳定性、连续性、安全性**直接影响数据质量。因此，数据质量保障必须贯穿大数据处理的**每个环节**



---

## 问：农业大数据的定义是什么？

农业大数据是指在**现代农业生产、经营、管理、投资**等各种活动中形成的，**具有高附加值的、多时空特征的海量数据**，包括生物信息数据、资源环境数据、气象数据、作物生长监测数据、市场经营数据、农业管理数据等，**是多维度、全样本、多类型的数据集合**。

---

---

**问：农业大数据是由结构化数据、半结构化数据和非结构化数据组成，它们的特点分别是什么？**

- **结构化数据**，是指可由二维表结构来逻辑表达和实现的数据，严格地遵循数据格式与长度规范，主要通过关系型数据库进行存储和管理，也称作行数据。一般特点是，数据以行为单位，一行数据表示一个实体的信息，每一行数据的属性是相同的。
  - **半结构化数据**，属于同一类实体可以有不同的属性，而且这些属性的顺序也不重要。半结构化数据虽不符合关系型数据库或其他数据表的形式关联起来的数据模型结构，但包含相关标记，用来分隔语义元素以及对记录和字段进行分层。因此，也被称为自描述的结构。
  - **非结构化数据**是数据结构不规则或不完整，没有预定义的数据模型，不方便使用数据库二维逻辑表来表现的数据，一般存储为二进制的文件格式。
-

---

## □ 简述农业大数据技术与农业物联网、云计算、人工智能技术的关系。

大数据、物联网、云计算和人工智能作为当前信息化浪潮的代表技术，在农业领域都已经开始得到越来越广泛的应用，对农业产业的各个环节带来了深远的影响。大数据技术在整个技术体系中处于核心基础地位。农业大数据技术为农业物联网数据分析提供技术支撑；农业大数据为云计算提供了“用武之地”；农业大数据为人工智能农业应用奠定了坚实基础。

## 6.1 农业大数据概述

### 6.1.2 农业大数据的独有特征

农业大数据除了具有大数据的一般特征，也有**自身独特的特性**，表现为一下5个方面。

- **涉及领域广**。农业大数据涉及**跨行业、跨学科、跨业务的多粒度、多结构交叉的融合和关联**；也广泛应用于农资投入、农机服务、农技服务、金融投资、农业保险等涉农服务领域。
- **跨越周期长**。农业大数据是农业中客观实体或事物的表达，动植物的生长遵循一定的规律，受自然因素的影响，随季节而变化，具有周期性。**农业生产周期一般以年为单位**。
- **地域性强**。**动植物等农业生产对象需要不同的自然条件**。不同地域的地理位置、地形地貌、水分、热量等自然条件和生态环境以及社会经济、技术条件等各不相同，因此农业大数据表现出明显的地域特征。
- **服务对象众**。农业产业链各个环节的**政府、科研机构、高校、企业**共同服务于农业大数据建设，通过农业大数据平台达成合作与共享，发挥数据协同服务效应。
- **数据维度高**。农业大数据**融合了政府、企业、农民等各阶层参与者的理念、思维**，在数据分析阶段要从不同用户的多维度出发，例如要综合耕地数量、农田质量、气候变化、作物品种、栽培技术、产业结构、农资配置等多种因素分析粮食安全问题。

## 6.1 农业大数据概述

---

选择题：

以下不是农业大数据特征的是（ **B** ）

- A. 数据体量大
- B. 以结构化数据为主
- C. 价值密度低
- D. 跨越周期长

## 6.1 农业大数据概述

### 数据思维

#### (1) 科学研究的三种方法及思维

科学界一般认为，科学方法分为实验、理论和计算三大类，与三大科学方法相对的是三大科学思维。

- **实验科学--实证思维**：以实验为基础，以物理学科为代表。
- **理论科学--理论思维**：以推理和演绎为特征，以数学学科为代表。
- **计算科学--计算思维**：以设计和构造为特征，以计算机学科为代表。

#### (2) 科学发现的**第四范式**

**计算机科学家，1998年图灵奖得主吉姆·格雷**认为，鉴于数据的爆炸性增长，数据密集范式理应并且已经从第三范式即计算范式中分离出来，成为一个独特的科学研究范式，即“第四范式”。


数据密集型：**数据科学——数据思维**

小插曲：吉姆·格雷于2007年1月在其个人爱好航海活动中失踪，当时他驾驶帆船出海，从此下落不明。


# 6.1 农业大数据概述

## 1. 数据思维的由来

图灵奖获得者、著名数据库专家**吉姆·格雷**(Jim Gray)观察并总结人类自古以来，在科学研究上，先后历经了实验、理论、计算和数据四种范式



实验



理论



计算



数据

# 6.1 农业大数据概述

## 2. 大数据时代下的数据思维

- **全样本而非抽样。**

在传统的统计学和数据分析中，由于数据收集和处理能力的限制，常采用**抽样调查**的方式来估计总体特征。而在大数据时代，随着数据采集技术的进步和存储能力的提升，越来越多的情境下可以获取并处理几乎全部数据，也就是所谓的“**全样本**”。这样做的好处在于，可以**减少抽样误差，提供更为全面和精确的结论。**

### 案例：乔布斯与癌症治疗

在2004年，乔布斯花费几十万美元做了基因检测，成为世界上第一个对自身所有DNA和肿瘤DNA进行排序的人，通过这些基因数据，医生们可以根据乔布斯特定的DNA为他设计药物，并观察药效，如果由于癌症的病变导致药物失效，医生可以及时的更换药物，以免延误治疗期。



## 6.1 农业大数据概述

### 2. 大数据时代下的数据思维

- **重视数据的复杂性，弱化精确性。**

在大数据环境下，海量数据往往呈现出复杂、多维的特性，且数据质量可能存在参差不齐的现象。因此，相较于追求数据的绝对精确性，大数据思维更侧重于在一定程度上的模糊性和不确定性中寻找规律。这意味着即便数据中有噪音和误差，也可以通过大量数据的汇聚和复杂算法的运用，挖掘出有用的信息。

**举例：**社交媒体情绪分析中，虽然无法做到对每一个用户情感状态的精确识别，但通过分析千万条微博、评论和帖子，可以捕捉到整体的社会情绪趋势和热点话题。



## 6.1 农业大数据概述

### 3. 大数据时代下的数据思维

- **关注数据的相关性，而非因果关系。**

大数据分析很多时候并不寻求严格的因果关系证明，而是注重发现**数据之间的相关性**，通过观察现象之间的关联性来辅助决策。这是因为大数据往往可以从海量数据中快速发现隐含的关系，但**确定因果链条需要严谨的实验设计和验证**，而这在很多现实场景中难以实施。利用相关性分析，可以快速响应并作出初步的预测或行动方案。



啤酒与尿布




谷歌与流感

## 6.1 农业大数据概述

### 6.1.3 农业大数据技术


**农业大数据处理流程：**包括数据预处理，数据存储与管理，数据分析与计算，以及数据可视化。

- **数据预处理：**预处理包括数据清洗，数据转换，数据规约，数据集成等，来提高大数据的一致性，准确性，真实性和可用性。
- **数据存储与管理：**数据存储是大数据计算的基础，上层分析挖掘算法等都依赖于数据存储系统的表现。
- **数据分析与计算：**通过统计分析和数据挖掘来获取隐含的、潜在有用的信息
- **数据可视化：**将数据分析和挖掘结果以图形图像等直观方式展现给用户，便于用户理解。



# 6.1 农业大数据概述

农业大数据技术体系



---

6.1 农业大数据概述

6.2 农业大数据存储和管理

6.3 农业大数据分析与计算


6.4 农业大数据可视化

6.5 农业大数据应用案例

---

## 6.2.1 农业大数据预处理

- 对于大数据，并不是全部有价值，有些数据并不是人们关心的内容，而有一些数据可能是完全错误的干扰性，需要对数据进行去噪。**在数据挖掘工作中，数据预处理所占的工作量达到整个工作量的60%-80%。**
- **数据预处理**就是在数据挖掘之前，对原始数据进行必要的**清洗、集成、转换、规约**等一系列的处理工作，使之达到挖掘算法进行知识获取所要求的**最低规范标准**。



## 6.2.1 农业大数据预处理

---

### 1.数据清洗

未经过处理的原始数据中包含大量的无效数据，这些数据在到达存储过程之前就应该被过滤掉。在原始数据中，常见的数据质量问题包括**噪声和数据缺失**，通过**数据清洗**方法来处理。

- **噪声数据清洗**：噪声数据是一组数据中存在由随机错误或偏差引起的孤立数据，如传感器故障或外界噪声干扰导致数据错误。一般使用**分箱法（箱线图）**来判断异常值。
  - **缺失数据清洗**：实际数据中存在大量不完整数据，如人工录入时疏忽，调查问卷时被调查人没有填写等。这些不完整数据会影响数据分析结果的准确性。
  - **解决办法是**：删除不完整的数据或者使用填充算法对缺失值进行填充。
-

## 6.2.1 农业大数据预处理

---

### 2. 数据转换

各种各样的农业感知设备获取**数据的格式可能不一样**，需要**转换为相同的格式以便存储、分析和处理**。数据转换就是解决数据不一致的问题：


- 其过程主要包括数据的转化、数据的重新格式化、关键数据的重新构建以及数据的汇总、定位。
- 数据转换一般包括两类：
  - 数据名称和格式的统一
  - 数据字段的组合、分割或计算

## 6.2.1 农业大数据预处理

### 3. 数据规约

**数据规约**目的是在保证数据原有特征和重要信息尽可能得以保留的基础上，**减少数据的规模，降低数据的复杂性和存储需求**，提高后续数据分析和挖掘的效率。数据规约主要研究内容如下：

- **高纬度数据的降维处理**：主要方法包括主成分分析（PCA）、线性判别分析（LDA）等，通过投影将高维数据映射到低维空间。
- **减少数据量**：主要方法包括直方图、聚类等，进而从数据集中选择较小规模的数据
- **数据离散化技术**：将连续属性值转化为离散属性值，涉及采样，量化和编码等。



## 6.2.1 农业大数据预处理

---

### 4. 数据集成

**数据集成**就是将不同数据源的数据统一融合在一个数据集中，并提供统一的数据视图的数据整合方式。

- 农业大数据通常来自多个数据源，它们具有高度异构的特点：不同的数据模型、不同的数据类型、不同的命名方法、不同的数据单元等，需要有效的数据集成方法对这些数据进行整合。
  - 现有的数据集成方法可以分为四种类型：基于物化或ETL方法的引擎，基于联邦数据库或中间件方法的引擎，基于数据流方法的引擎，以及基于搜索引擎的方法。
-

## 6.2.2 数据的组织形式

---

农业数据需要按照一定的组织形式和规则进行存储和处理，以实现有效的数据管理。常用的数据组织形式有两种：**文件和数据库**。

### 文件

一种高度灵活的数据存储形式，它允许使用者非常自由地进行数据处理而不受过多的约束。

### 数据库

数据组织的高级形式是数据库，即存储在计算机内有组织的、共享的、统一管理的数据集合。

# 6.2.2 数据的组织形式

## 1. 文件


- 最简单的数据管理形式是文件。在数据库管理系统出现以前，人们通常使用文件作为数据存储形式。
- **优点：**简单，高度灵活，使用者可以自由的进行数据处理。
- **缺点：**数据可能会冗余、不一致，数据访问繁琐，难以添加条件约束，安全性不高。
- 常用数据文件格式：EXCEL文件，CSV文件，XML格式文件，JSON文件等

| 表 6-2 XML 和 JSON 数据格式                                                                                                                                                                                                                                                                                                                                                                        |                                                                                                                                                                                                                          |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| XML 格式数据                                                                                                                                                                                                                                                                                                                                                                                     | JSON 格式数据                                                                                                                                                                                                                |
| <pre>&lt;部分地区主要作物产量（万吨）&gt;   &lt;地区 名称="北京"&gt;     &lt;小麦&gt;18.7&lt;/小麦&gt;     &lt;玉米&gt;75.2&lt;/玉米&gt;   &lt;/地区&gt;   &lt;地区 名称="河北"&gt;     &lt;稻谷&gt;58.8&lt;/稻谷&gt;     &lt;玉米&gt;1703.9&lt;/玉米&gt;     &lt;小麦&gt;1387.2&lt;/小麦&gt;   &lt;/地区&gt;   &lt;地区 名称="广西"&gt;     &lt;稻谷&gt;1156.2&lt;/稻谷&gt;     &lt;甘蔗&gt;8104.3&lt;/甘蔗&gt;   &lt;/地区&gt; &lt;/部分地区主要作物产量（万吨）&gt;</pre> | <pre>{   "部分地区主要作物产量（万吨）":{     "北京":{       "小麦":18.7,       "玉米":75.2     },     "河北":{       "稻谷":58.8,       "玉米":1703.9,       "小麦":1387.2     },     "广西":{       "稻谷":1156.2,       "甘蔗":8104.3     }   } }</pre> |

## 6.2.2 数据的组织形式

### 2. 数据库

□ 数据组织的高级形式是数据库。数据库中保存的数据结构既描述了数据之间的内在联系，便于数据增加、更新和删除，也保证了数据的独立性、可靠性、安全性和完整性，提高了数据管理效率。



## 6.2.3 数据库系统

### 关系型数据库

- **关系型数据库** (Relational Database)，是建立在关系模型基础上的数据库，借助于集合代数等概念和方法来处理数据库中的数据。
- **关系数据库**模型是当前数据库系统最为常用的数据模型，但随着大数据应用需求的不断增长，**NoSQL数据库**、**NewSQL数据库**也越来越占据了重要的地位。



# 6.2 农业大数据预处理

## 关系型数据库

- **关系型数据库**使用的存储结构是**多个二维表格**，即反映事物及其联系的数据描述是以平面表格形式体现的，关系数据库表可以看作多个结构相同的数据对象的集合。
- 二维表中的每一行称为一条记录或元组，用来描述一个对象的信息。每一列称为一个字段或者属性，用来表述对象的一个属性。

| 结果 |     | 消息    |        |
|----|-----|-------|--------|
|    | 国家  | 粮食总产量 | 耕地面积   |
| 1  | 中国  | 6.17  | 150.40 |
| 2  | 美国  | 4.40  | 166.90 |
| 3  | 印度  | 3.13  | 153.50 |
| 4  | 巴西  | 1.17  | 66.10  |
| 5  | 加拿大 | 0.56  | 47.40  |

| 结果 |     | 消息   |        |       |
|----|-----|------|--------|-------|
|    | 国家  | 所属大洲 | 国土面积   | 人口数量  |
| 1  | 中国  | 亚洲   | 959.70 | 14.24 |
| 2  | 美国  | 北美洲  | 982.66 | 3.29  |
| 3  | 印度  | 亚洲   | 328.76 | 13.44 |
| 4  | 巴西  | 南美洲  | 851.20 | 2.09  |
| 5  | 加拿大 | 北美洲  | 997.60 | 0.37  |

## 6.2.3 数据库系统

### 结构化查询语言SQL

- **结构化查询语言**(Structured Query Language)简称**SQL**, 是一种特殊目的的**编程语言**, 是一种数据库查询和程序设计语言, 用于**存取数据以及查询、更新和管理关系数据库系统**。



## 问：数据预处理有哪几个环节？各个环节的主要任务是什么？

数据预处理主要包括**数据清洗**、**数据转换**、**数据归约**、**数据集成**等环节。

- **数据清洗**主要任务是将未经处理的原始数据中包含大量的无效数据过滤掉，包括噪声数据清洗、缺失数据清洗等；
- **数据转换**主要是解决数据的不一致性问题，其过程包括数据的转化、数据的重新格式化和关键数据的重新构建以及数据的汇总、定位等；
- **数据归约**主要任务包括高维度数据的降维处理、减少数据量、数据离散化等；
- **数据集成**主要任务是将不同数据源的数据统一融合在一个数据集中，并提供统一数据视图。

## 6.2.3 数据库系统

### 结构化查询语言SQL

结构化查询语言的主要功能：

1. **数据定义**：其语句包括动词CREATE, ALTER和DROP。在数据库中创建新表或修改、删除表（CREAT TABLE, ALTER TABLE 或 DROP TABLE）等。
2. **数据查询**：用以从表中获得数据，确定数据怎样在应用程序给出。保留字**SELECT**用得最多的动词，其他常用的保留字有WHERE, ORDER BY, GROUP BY和HAVING。这些保留字常与其它类型的SQL语句一起使用。
3. **数据操作**：其语句包括动词**INSERT**、**UPDATE**和**DELETE**。它们分别用于添加、修改和删除。

# 6.2.3 数据库系统

## 结构化查询语言SQL

**例** 查询粮食总产量超过2亿吨的世界主要农业国的粮食总产量和耕地面积，并按耕地面积从大到小排序。

结果消息

|   | 国家 | 粮食总产量 | 耕地面积   |
|---|----|-------|--------|
| 1 | 美国 | 4.40  | 166.90 |
| 2 | 印度 | 3.13  | 153.50 |
| 3 | 中国 | 6.17  | 150.40 |

SQLQuery1.sql - 2...888.test (sa (84))\*

SELECT 国家, 粮食总产量, 耕地面积  
FROM Agriculture  
WHERE 粮食总产量>2  
ORDER BY 耕地面积 DESC

## 6.2.3 数据库系统

---

### 关系数据库的优缺点

- **优点：**数据一致性好、事务机制完善、查询语言标准化、查询效率高、技术成熟
- **局限性：**在面对超大规模数据量、大量非结构化或半结构化数据的大数据计算问题时，关系型数据库面临诸多挑战。

近年随着大数据处理而兴起的基于分布式文件系统的非关系型数据库（Not Only SQL, NoSQL）则以其**扩展性好、能有效处理非结构化或半结构化数据、支持高并发计算模型**的特点，在农业大数据领域得到了比较广泛地应用。

---

## 6.2.3 数据库系统

---

### 非关系数据库NoSQL


**NoSQL**是一种不同于关系型数据库的数据库管理系统设计方式，**是对非关系型数据库的统称**，与传统关系数据库的关系模型不同，NoSQL通常采用类似**键值、列族、文档**等非关系模型。NoSQL数据库具有以下特点：

- **灵活的可扩展性**：考虑到**水平扩展**的需求，能够通过添加更多的硬件资源（通常是普通的服务器集群）来分散数据存储和处理压力，降低了单点故障风险。
  - **灵活的数据模型**：摒弃了传统关系型数据库固定的表格结构和关系约束，提供了多种数据模型以适应不同应用需求
  - **与云计算紧密融合**：NoSQL数据库天然适合云环境部署，因为它们通常设计为分布式系统，能够充分利用云计算提供的弹性计算和存储资源
-

# 6.2.3 数据库系统

## 非关系数据库NoSQL

NoSQL数据库的类型可以分为四类: 键值数据库、列存储数据库、文档数据库、以及图数据库。

| 文档数据库                                                                                                                                                                                                                                                                                                                                                   | 图数据库                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div></div> | <div></div>                                                                                                                                                                                                                                                                |
| 列族数据库                                                                                                                                                                                                                                                                                                                                                   | 键值数据库                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| <div></div>                                                                                  | <div></div> |

# 6.2.3 数据库系统

## 非关系数据库NoSQL

- 键值数据库

键值数据库 (Key-Value) 有一个特定的Key和一个指针指向特定的Value。Key可以用来定位和查询具体的Value。Value对数据库而言透明不可见，不能对 Value进行索引和查询。

JSON 数据格式

| JSON 格式数据                                                                                                                                                                                                                |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre>{   "部分地区主要作物产量（万吨）":{     "北京":{       "小麦":18.7,       "玉米":75.2     },     "河北":{       "稻谷":58.8,       "玉米":1703.9,       "小麦":1387.2     },     "广西":{       "稻谷":1156.2,       "甘蔗":8104.3     }   } }</pre> |

# 6.2.3 数据库系统

## 非关系数据库NoSQL

键  
值  
数  
据  
库

|       |                                                                                                                                                 |
|-------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| 数据模型  | <ul style="list-style-type: none"><li>• 键/值对</li><li>• 键是一个字符串对象</li><li>• 值可以是任意类型的数据，比如整型、字符型、数组、列表、集合等</li></ul>                             |
| 典型应用  | <ul style="list-style-type: none"><li>• 涉及频繁读写、拥有简单数据模型的应用</li><li>• 内容缓存，比如会话、配置文件、参数、购物车等</li><li>• 存储配置和用户数据信息的移动应用</li></ul>                |
| 优点    | 扩展性好，灵活性好，大量写操作时性能高                                                                                                                             |
| 缺点    | 无法存储结构化信息，条件查询效率较低                                                                                                                              |
| 不适用情形 | <p>不是通过键而是通过值来查：键值数据库根本没有通过值查询的途径</p> <p>需要存储数据之间的关系：在键值数据库中，不能通过两个或两个以上的键来关联数据</p> <p>需要事务的支持：在一些键值数据库中，产生故障时，不可以回滚</p>                        |
| 使用者   | 百度云数据库（Redis）、GitHub（Riak）、BestBuy（Riak）、Twitter（Redis和Memcached）、StackOverFlow（Redis）、Instagram（Redis）、Youtube（Memcached）、Wikipedia（Memcached） |

# 6.2.3 数据库系统

## 非关系数据库NoSQL

### ● 列族数据库

专为处理大量结构化数据而设计，适用于大数据场景，特别是在需要高性能读写、大规模扩展以及灵活数据模型的应用中表现出色。

列族数据库由多个行构成，**每行数据包含多个列族**，不同的行可以具有不同数量的列族，**属于同一列族的数据会被存放在一起**。每行数据通过行键进行定位，与这个行键对应的是多个列族。



## 6.2.3 数据库系统

列族数据库

|       |                                                                                                                 |
|-------|-----------------------------------------------------------------------------------------------------------------|
| 相关产品  | BigTable、HBase、Cassandra、HadoopDB、GreenPlum、PNUTS                                                               |
| 数据模型  | 列族                                                                                                              |
| 典型应用  | 分布式数据存储与管理<br>数据在地理上分布于多个数据中心的应用程序<br>可以容忍副本中存在短期不一致情况的应用程序<br>拥有动态字段的应用程序<br>拥有潜在大量数据的应用程序，大到几百TB的数据           |
| 优点    | 查找速度快，可扩展性强，容易进行分布式扩展，复杂性低                                                                                      |
| 缺点    | 功能较少，大都不支持强事务一致性                                                                                                |
| 不适用情形 | 需要ACID事务支持的情形，Cassandra等产品就不适用                                                                                  |
| 使用者   | Ebay（Cassandra）、Instagram（Cassandra）、NASA（Cassandra）、Twitter（Cassandra and HBase）、Facebook（HBase）、Yahoo!（HBase） |

## 6.2.3 数据库系统

□ 文档数据库就是一系列文档的集合。采用类似于XML、BSON等半结构化格式表示，每个文档都可以携带任意数量和结构的字段（key-value对或嵌套文档）。

文档数据库

|       |                                                                                          |
|-------|------------------------------------------------------------------------------------------|
| 相关产品  | MongoDB、CouchDB、Terrastore、ThruDB、RavenDB、SisoDB、RaptorDB、CloudKit、Perservere、Jackrabbit |
| 数据模型  | 键/值<br>值（value）是版本化的文档                                                                   |
| 典型应用  | 存储、索引并管理面向文档的数据或者类似的半结构化数据<br>比如，用于后台具有大量读写操作的网站、使用JSON数据结构的应用、使用嵌套结构等非规范化数据的应用程序        |
| 优点    | 性能好（高并发），灵活性高，复杂性低，数据结构灵活<br>提供嵌入式文档功能，将经常查询的数据存储在同一个文档中<br>既可以根据键来构建索引，也可以根据内容构建索引      |
| 缺点    | 缺乏统一的查询语法                                                                                |
| 不适用情形 | 在不同的文档上添加事务。文档数据库并不支持文档间的事务，如果对这方面有需求则不应该选用这个解决方案                                        |
| 使用者   | 百度云数据库（MongoDB）、SAP（MongoDB）、Codecademy（MongoDB）、Foursquare（MongoDB）、NBC News（RavenDB）   |


## 6.2.3 数据库系统

### 非关系数据库NoSQL

- 图数据库

图数据库使用图作为数据模型来存储数据，可以高效地存储不同顶点之间的关系。

例如图数据库可以将社交关系等数据描述为**点 (Vertex)** 和**边 (Edge)** 及它们的属性  
(Property)，每一张图都可以看作是一个结构化数据。



# 6.2.3 数据库系统

## 非关系数据库NoSQL

图  
数  
据  
库

|      |                                                       |
|------|-------------------------------------------------------|
| 相关产品 | Neo4J、OrientDB、InfoGrid、Infinite Graph、GraphDB        |
| 数据模型 | 图结构                                                   |
| 典型应用 | 专门用于处理具有高度相互关联关系的数据，比较适合于社交网络、模式识别、依赖分析、推荐系统以及路径寻找等问题 |
| 优点   | 灵活性高，支持复杂的图形算法，可用于构建复杂的关系图谱                           |
| 缺点   | 复杂性高，只能支持一定的数据规模                                      |
| 使用者  | Adobe（Neo4J）、Cisco（Neo4J）、T-Mobile（Neo4J）             |

## 6.2.3 数据库系统

### 关系型数据库与NoSQL数据库的对比

| 比较标准  | RDBMS | NoSQL                                   | 备注                                                                                                 |
|-------|-------|-----------------------------------------|----------------------------------------------------------------------------------------------------|
| 数据库原理 | 完全支持  | 部分支持                                    | RDBMS有关系 <b>代数理论</b> 作为基础<br>NoSQL没有统一的理论基础                                                        |
| 数据规模  | 大     | 超大                                      | RDBMS很难实现 <b>横向扩展</b> ，纵向扩展的空间也比较有限，性能会随着数据规模的增大而降低<br>NoSQL可以很容易通过 <b>添加更多设备（横向扩展）</b> 来支持更大规模的数据 |
| 数据库模式 | 固定    | 灵活                                      | RDBMS需要 <b>定义数据库模式</b> ，严格遵守数据定义和相关约束条件<br>NoSQL不存在数据库模式，可以自由灵活定义并存储各种不同类型的数据                      |
| 查询效率  | 快     | 可以实现高效的简单查询，但是不具备高度结构化查询等特性，复杂查询的性能不尽人意 | RDBMS借助于索引机制可以实现 <b>快速查询</b> （包括记录查询和范围查询）<br>很多NoSQL数据库没有面向复杂查询的索引，在复杂查询方面的性能仍然不如RDBMS            |

## 6.2.3 数据库系统

### 关系型数据库与NoSQL数据库各有优劣

NoSQL数据库可以提供良好的可扩展性和灵活性，很好地弥补了传统关系数据库的缺点。但是NoSQL也有不足之处。由于采用非关系数据模型，因此它**不具备高度结构化查询等特性，复杂查询方面不如关系数据库。**



最初表示“反SQL”运动  
用新型的非关系数据库取代关系数据库

概念演变



**Not only SQL**

现在表示关系和非关系型数据库各有优缺点  
彼此都无法互相取代

## 6.2.3 数据库系统

---


### NewSQL数据库

- **NewSQL是对各种新的可扩展、高性能数据库的简称**，这类数据库不仅具有 NoSQL对海量数据的存储管理能力、还保持了传统数据库支持ACID和SQL等特性。不同的 NewSQL数据库的内部结构差异很大，但是它们有**两个显著的共同特点：都支持关系数据模型；都使用SQL作为其主要的接口。**
- 目前，具有代表性的 **NewSQL**数据库主要包括 Spanner、Clustrix、GenieDB、ScalArc、Schooner、VoltDB、RethinkDB、ScaleDB、Akiban、CodeFutures、ScaleBase、Translattice、NimbusDB、Drizzle、Tokutek、Justone DB等。此外，还有一些在云端提供的 NewSQL数据库，包括AmazonRDS、Microsoft SQL Azure、Database.com、Xeround和FathomDB等

## 6.2.3 数据库系统

### 大数据时代的多元化数据架构

- 大数据时代的到来引发了数据处理架构的变革。以前希望**一种架构支持多类应用**，包括事务型应用，分析型应用和互联网应用。实践证明，不同应用场景的数据管理需求截然不同、一种数据库架构无法满足所有场景。
- 大数据时代，**数据架构开始向多元化方向发展**，形成**传统关系型数据(OldSQL)**，**NoSQL数据库**和**NewSQL数据库**三大阵营共存共荣。



---

选择题：

以下数据组织方式支持**SQL**语句查询的是（**C**）

**A. JSON文件**

**B. 列族数据库**

**C. 关系型数据库**

**D. 键值数据库**

---

## 6.2 农业大数据存储和管理

### 6.2.4 云计算技术

□ **云计算的定义：**云计算是由分布式计算、并行处理、网格计算发展而来的，是网格计算、分布式计算，并行计算、效用计算，网络存储、虚拟化、负载均衡等传统计算机技术和网络技术发展融合的产物，是一种新兴的商业计算模型。



图片来源：视觉中国 [www.vcg.com](http://www.vcg.com)

## 6.2 农业大数据存储和管理

---

### 6.2.4 云计算技术

云计算这一概念具有以下特征：

- 在**技术体制**方面，云计算不是全新的技术，而是现有技术的综合利用。
  - 在**经济性**方面，云计算强调系统构建的低成本。通常采用数量较多的高性能PC机或小型服务器等较为便宜的硬件构建分布式服务器集群
  - 在**应用程序**特征方面，云计算强调基于互联网的应用。云计算的典型应用模式是客户端根据自身需要通过浏览器等标准程序访问发布在互联网之上、以服务形式提供的计算能力、软件、存储服务、中间件平台等。
  - 在**应用模式**方面，云计算提倡效用计算（Utility Computing），并采用多重租赁的方式提供计算服务。
-

## 6.2 农业大数据存储和管理

云计算  
数据  
中心



## 6.2 农业大数据存储和管理

---

### 6.2.4 云计算技术

从**云计算部署模式**上可以分为私有云、公有云和混合云。


- **私有云：核心属性是资源的专有性。**私有云是专门为单个组织或企业构建的，可以是内部部署在企业数据中心。由该组织拥有和管理，提供了更高层次的数据安全和隐私保护，因为它仅供内部使用。
  - **公有云：核心属性是资源为云服务提供商所有。**公有云是由第三方服务提供商（如百度云、阿里云、Google Cloud等）拥有和管理的，通过互联网向公众或企业提供服务。公有云采用按需付费模式，企业只需为其实际使用的计算资源、存储空间和网络带宽付费，可轻松进行快速扩展或缩减资源，且无需大量前期投资。
  - **混合云：核心属性是灵活的部署方式。**混合云结合了私有云和公有云的优势，允许企业在私有云和公有云之间灵活调配工作负载，既可以保护敏感数据在私有云上运行，又可以利用公有云的弹性扩展能力。
-

# 6.2 农业大数据存储和管理

## 6.2.4 云计算技术


按照提供的**服务类型**可以分为三种

- IaaS—基础设施即服务，只涉及到租用**硬件**，是一种最基础的服务
- PaaS—平台即服务，已经从硬件的基础上，租用一个特定的**操作系统与应用程序**，来自己进行应用软件开发
- SaaS—软件即服务，在云平台提供的定制软件上，直接部署自己的应用系统



## 6.2 农业大数据存储和管理

### 云计算关键技术



## 6.2 农业大数据存储和管理

---

### 云计算关键技术

- **虚拟化**：虚拟化技术是云计算的基础，它**允许在单一物理硬件资源上创建多个隔离的、互相独立的虚拟环境**（如虚拟机）。通过虚拟化，云计算平台可以更高效地利用服务器资源，实现资源池化，灵活地按需分配给不同用户，从而提高硬件利用率并降低总体成本。每个虚拟环境都能运行自己的操作系统和应用程序，仿佛是在独立物理设备上运行一样。现有典型的虚拟化技术有：Hyper-V、Vnware、KVM、Docker、Virtualbox等。
- **分布式存储**：分布式存储技术是云服务能够提供海量、可靠和可扩展的数据存储的关键。这种技术将**数据分散存储在网络中多台独立的物理存储设备上**，通过网络协同工作，对外呈现为一个统一的、高可用性的存储资源。比如Google的GFS、Amazon S3、Hadoop HDFS等都是典型的分布式存储系统，它们保证了数据的冗余备份、负载均衡和故障恢复能力。

## 6.2 农业大数据存储和管理

---

### 云计算关键技术

- **分布式计算**：分布式计算技术让**云计算能够处理大量的并行计算任务**，将复杂的计算作业分解成许多小部分，分发到集群中的各个节点上同时进行处理，然后汇总结果。这种方式极大地提高了计算效率和处理能力，使得云计算能轻松应对大数据分析、机器学习以及其他大规模计算场景的需求。MapReduce和Spark是两种广泛应用于云计算环境下的分布式计算框架。
- **多租户**：多租户架构是云计算服务模式中的一个重要概念，特别是在软件即服务（SaaS）领域。在一个多租户系统中，单个实例的应用程序可以支持多个组织（称为租户）共享使用，每个租户都有自己的定制视图和数据集，同时保持彼此的隔离性和安全性。这种架构确保了资源的有效利用，同时也简化了管理和维护，因为所有的租户都运行在同一个应用程序版本上，由云服务提供商集中管理更新和升级。

---

6.1 农业大数据概述

6.2 农业大数据存储和管理

6.3 农业大数据分析与计算


6.4 农业大数据可视化

6.5 农业大数据应用案例

---

### 农业大数据计算模式

- 农业大数据被采集和存储后，虽然已经以某种特定的形式存在于计算机的存储系统中，但此时的数据还是数据，并不能体现它的价值和规律。因此需要进行**农业大数据分析 with 计算**。
- 针对农业大数据的不同数据类型、不同处理方式（如数据切割、数据迁移或复制等），需要不同的计算模式。目前，**大数据计算分析主要用到的计算模式如下**。




### 批处理计算

- 批处理主要操作**大容量静态数据集**，并在计算过程完成后返回结果
- 批处理非常**适合需要访问全部记录**才能完成的计算工作（如计算总数，平均数等）批处理在应对**大量持久数据**方面的表现极为出色，因此经常被用于对历史数据进行分析。
- 大量数据的处理**需要付出大量时间**，因此批处理不适合对处理时间要求较高的场合。

### 批处理计算-MapReduce的核心思想


- **分而治之**。一个大的MapReduce作业被拆分成很多个Map任务，在多台机器上并行执行每个Map任务。
- **计算向数据靠拢**：Map任务通常运行在数据存储的节点上。这样计算和数据就可以放在一起运行，不需要额外的数据传输开销



### 批处理计算


#### MapReduce工作流程

- 一个大的MapReduce作业被拆分成很多个Map任务，在多台机器上并行执行每个Map任务。Map任务结束后，会生成以<key,value>形式表示的许多中间结果，然后这些中间结果会被分发到多个 Reduce 任务，在多台机器上并行执行。相同key的<key,value>会被发送到同一个 Reduce 任务处，Reduce 任务会对中间结果进行汇总计算得到最后结果并输出到分布式文件系统中。




MapReduce工作流程

### 批处理计算



WordCount执行Map过程

批处理计算



### 其他大数据计算模式

- **流计算**：流数据是指在时间分布和数量上无限的一系列动态数据集合体，数据的价值随着时间的流逝而降低。**流计算可以实时处理来自不同数据源的连续到达数据，给出有价值的分析结果。**业内涌现的流计算框架有IBM InfoSphere Streams, Yahoo S4, Spark Streaming.
- **图计算**：许多大数据都是以大规模图和网络的形式呈现，如农产品物流网络，交通道路网等，需要图计算进行高效分析和提取。业内著名的图计算框架为Pregel并行图处理系统。
- **内存计算**：指采用各种内存技术，在计算过程中**让CPU从主存读取数据而不是从硬盘读取数据。**Apache Spark 是专为大规模数据处理而设计的快速通用的内存计算引擎。



### 农业预测预警

- **农业预测**农业预测是农业大数据的重要应用之一。是以土壤、环境、气象资料、作物或动物生长、农业生产条件、航拍或卫星影像等实际农业资料为依据，对研究对象未来发展的可能性进行推测和估计：是精确施肥、灌溉、播种、除草、灭虫等农事操作及农业生产计划编制、监督执行情况的科学决策的重要依据。
- **农业预警是农业预测发展的高级阶段，更加侧重于对可能发生的自然灾害、病虫害、市场波动等不利事件的及时预报**，并给出应对措施最大程度上避免或减少农业生产活动中所受到的损失，从而在提升农业活动收益的同时降低农业活动的否风险。农业预警就是要研究警情的排除，消除已经出现的警情，预防未来可能出现的警情。

#### 农业预测

- 回归预测法
- 时间序列分解法与趋势外推法
- 时间序列平滑预测法
- 灰色预测法。
- 模糊预测法

#### 农业预警

- 定性分析：德尔菲法、主观概率法
- 定量分析：统计法、模型法

## 农业智能决策


□ 农业智能决策是智能决策技术在农业领域的具体应用，是农业大数据分析技术的一个重要分支。农业智能决策基于农业大数据平台更充分地应用人类知识，进行多维的知识和数据挖掘和分析，既能处理定量问题，又能处理定性问题，是农业信息系统的最高层次，是农业信息化的重要特征。它的应用使农业大数据资源的价值越来越大，农业大数据资源真正成为涉农企业的核心资源。

表 6-6 智慧农业决策需求与相应智能计算方法

| 智慧农业决策需求   | 结合点 | 智能计算方法              |
|------------|-----|---------------------|
| 地力分级       | 分类  | 决策树、贝叶斯网、神经网络、支持向量机 |
| 管理区划分      | 聚类  | 神经网络、模糊聚类、灰色聚类等     |
| 产量预测、病虫害预测 | 预测  | 贝叶斯网、神经网络、灰色预测、粗糙集  |
| 智慧施肥       | 回归  | 神经网络                |
| 肥力评价、品种评价  | 评判  | 模糊综合评判              |
| 产量因素影响分析   | 关联  | 灰色关联、关联规则、粗糙集、贝叶斯网  |


### 6.3.5 常用数据分析工具

- ❑ **Excel**可以进行各种数据的处理、统计分析和辅助决策操作，已经广泛地应用于管理、统计、金融等领域。
- ❑ Excel是日常数据分析工作中最常用的工具，满足了绝大部分办公制表的需求，同时也拥有相当优秀的数据处理能力。
- ❑ 其自带的**ToolPak（分析工具库）**和**Solver（规划求解加载项）**可以完成基本描述统计、方差分析、统计检验、傅立叶分析、线性回归分析和线性规划求解工作。这些功能在Excel中没有默认打开，需要在Excel选项中手动开启。



### 6.3.5 常用数据分析工具


- ❑ **MATLAB**是矩阵实验室 (Matrix laboratory) 的简称, 是美国MathWorks公司出品的商业数学软件。
- ❑ MATLAB将数值分析、矩阵计算、科学数据可视化以及非线性动态系统的建模和仿真等诸多强大功能集成在一个易于使用的视窗环境中, 为科学研究、工程设计以及必须进行有效数值计算的众多科学领域提供了一种全面的解决方案, 可以进行矩阵运算、绘制函数和数据、实现算法、创建用户界面、连接其他编程语言的程序等, 并在很大程度上摆脱了传统非交互式程序设计语言 (如C、Java) 的编辑模式, 主要应用于工程计算、控制设计、信号处理与通讯、图像处理、信号检测、金融建模设计与分析等领域。




### 6.3.5 常用数据分析工具

#### MATLAB具有以下特点:

- ❑ 高效的数值计算功能，使用户从发杂的数学运算分析中解脱出来
- ❑ 具有完备的图像处理功能，实现计算结果和编程的可视化
- ❑ 友好的用户界面及接近数学表达式的自然化语言，易于学习和掌握
- ❑ 功能丰富的工具箱（如信号处理工具箱、通信工具箱等），为用户提供大量方便实用的处理工具。




# Matlab信息隐藏案例




## 图像加密

噪声图像容易引起攻击者的注意。




Secret image: Lena



(a)





Target image: Lake



(d)


J Yin, B Ou, X Liu, F Peng, [Mosaic secret-fragment-visible data hiding for secure image transmission based on two-step energy matching](#), Digital Signal Processing 81, 173-185

# 以图藏图



## 6.3.5 常用数据分析工具

**SAS** (Statistic Analysis System) 系统是世界领先的信息系统，它由最初的用于统计分析，经不断发展和完善而成为大型集成应用软件系统，具有完备的数据存取、管理、分析和显示功能。



### 6.3.5 常用数据分析工具





数据处理和统计分析领域，SAS系统被誉为国际上的标准软件系统。

**SAS具有以下特点：**

- **语言编程能力强。**SAS语言具有一般高级语言的一切功能，有100多个函数，有完成各种操作的算符，能读各种类型的数据，可以使用赋值语句、条件语句、数组和循环语句等对变量进行操作。SAS程序书写自由简洁。
- **分析方法丰富。**SAS汇集了大量的统计方法，从简单描述统计量的计算到多因素分析，从时间序列分析到质量控制等。仅SAS/STAT就包括了8类方法28个分析过程。
- **对数据的连续处理。**SAS能同时处理多个输入文件，能从几个数据集中组合变量值、观测值，建立子集，连接、合并和修改数据。SAS可存储一个合法的结果或中间结果，以便以后使用。
- **模块化。SAS系统是一个模块化的集成软件系统。**SAS系统提供的二十多个模块（产品）可完成各方面的实际问题，功能非常齐全，用户可按自己的要求，在SAS/BASE的基础上选择合适的模块，以组成自己需要的系统。

6.3.5 常用数据分析工具

- SPSS是“社会科学统计软件包”（Statistical Package for the Social Science）的简称，是一种集成化的计算机数据处理应用软件。
- SPSS是为广大的非专业人士设计的，操作方便，简单实用，因而很受非专业人士的青睐。



### 6.3.5 常用数据分析工具

**SPSS主要特点如下：**

- **操作简单：**除了数据录入及部分命令程序等少数输入工作需要键盘键入外，大多数操作可通过“菜单”、“按钮”和“对话框”来完成。
- **无须编程：**具有第四代语言的特点，告诉系统要做什么，无需告诉怎样做。只要了解统计分析的原理，无需通晓统计方法的各种算法，即可得到需要的统计分析结果。
- **功能强大：**具有完整的数据输入、编辑、统计分析、报表、图形制作等功能。自带11种类型136个函数。
- **方便的数据接口：**能够读取及输出多种格式的文件。比如文本编辑器文件，Excel文件等均可转换成可供分析的SPSS数据文件。能够把SPSS的图形转换为7种图形文件。结果可保存为txt及html格式的文件。
- **灵活的功能模块组合：**SPSS for Windows软件分为若干功能模块。用户可以根据自己的分析需要和计算机的实际配置情况灵活选择。

### 6.3.5 常用数据分析工具

- **Python**是一种通用的编程语言，开源、灵活、功能强大且易于使用。Python最重要的特性之一是其用于数据处理和分析任务的丰富实用程序和库集。
- Python由于其简单的用法和广泛的数据处理集，是大数据处理的一个非常好的选择。
- Python生态系统已经非常完备，具有诸如Numpy、SciPy、Matplotlib和Pandas等数据加工、数据处理、和可视化的著名程序包。如果能够将这些工具结合起来，其功效足以与MATLAB相媲美。



### 6.3.5 常用数据分析工具

- **NumPy**是 Python 语言的一个扩展程序库，支持大量的维度数组与矩阵运算，此外也针对数组运算提供大量的数学函数库。
- **SciPy** 是一个开源的 Python 算法库和数学工具包。SciPy是**构建在Numpy**的基础之上的，是一款方便、易于使用、专为科学和工程设计的Python工具包，包含的模块有最优化、线性代数、积分、插值、特殊函数、快速傅里叶变换、信号处理和图像处理、常微分方程求解和其他科学与工程中常用的计算。
- **Pandas** 是**基于NumPy**的一种工具，该工具是为了解决数据分析任务而创建的。Pandas 纳入了大量库和一些标准的数据模型，提供了高效地操作大型数据集所需的工具。Pandas提供了大量能快速便捷地处理数据的函数和方法。
- **Scikit-Learn**（简记Sklearn），是用Python实现的机器学习算法库，**基于NumPy和SciPy**。Sklearn可以实现数据预处理、分类、回归、降维、模型选择等常用的机器学习算法。

### 6.3.5 常用数据分析工具

- ❑ **Mahout**数据挖掘算法库，Mahout现在已经包含了聚类、分类、推荐引擎（协同过滤）和频繁集挖掘等广泛使用的数据挖掘方法。除了算法，Mahout还包含数据的输入/输出工具、与其他存储系统（如HDFS、关系数据库、MongoDB 或 Cassandra）集成数据挖掘支持架构。
- ❑ **Spark MLlib**是Spark的机器学习（Machine Learning）库，MLlib由一些通用的学习算法和工具组成，包括分类、回归、聚类、协同过滤、降维等，同时还包括底层的优化原语和高层的管道API。

---

6.1 农业大数据概述

6.2 农业大数据存储和管理

6.3 农业大数据分析与计算

6.4 农业大数据可视化

6.5 农业大数据应用案例

---

- **数据可视化**是指将大型数据集中的数据以图形图像形式表示，并利用数据分析和开发工具发现其中未知信息的处理过程。
- **基本思想**：是将数据库中每一个数据项作为单个图元素表示，大量的数据集构成数据图像。
- **大数据可视化的目标**：1.观测、跟踪数据；2.分析数据；3.辅助理解数据；4.增强数据吸引力。

### 可视化目标1：观测、跟踪数据


- 对于时序数据而言，利用变化的数据生成实时变化的可视化图表；人们一眼看出各种参数的动态变化过程，有效跟踪各种参数值。



智慧农机系统基于地图跟踪农机作业

可视化目标2：分析数据


利用可视化技术，实时呈现当前分析结果；并根据用户反馈信息执行后续分析操作，完成用户与分析算法的全程交互，实现数据分析算法与用户领域知识的完美结合。



作物种植结构和农机化程度的可视化分析

#### 可视化目标3：辅助理解数据

- 数据可视化可以帮助普通用户更快、更准确地理解数据背后的含义；如用不同的颜色区分不同对象、用动画显示变化过程等。



农产品生产成本分析图：色块面积越大费用所占比例越高

可视化目标4：增强数据吸引力

```
1 [
2   {
3     "name": "内蒙古",
4     "value": 1200
5   },
6   {
7     "name": "吉林省",
8     "value": 1000
9   },
10  {
11    "name": "四川省",
12    "value": 1300
13  },
14  {
15    "name": "新疆",
16    "value": 5000
17  },
18  {
19    "name": "江苏省",
20    "value": 3500
21  },
22 ]
```



### 文本数据可视化


- **文本数据可视化**：将文本中蕴含的语义特征（例如词频与重要度、逻辑结构、主题聚类、动态演化规律等）直观地展示出来。
- 文本可视化技术是**标签云（Word Clouds 或 Tag Clouds）**，将关键词根据词频或其他规则进行排序，按照一定规律进行布局排列，用大小、颜色、字体等图形属性对关键词进行可视化。




字体大小代表该关键词的重要性

### 时序数据可视化

时序数据可视化帮助人类通过数据的视角观察过去，预测未来。



(a) 面积图




(b) 气泡图




(c) 蜡烛图

- **面积图**可显示某时间段内量化数值的变化和发展，最常用来**显示趋势**，而非表示数值。
- **气泡图**把数据变量随时间的变化**制成动画**来显示。
- **蜡烛图**通常用作**交易工具**，用来显示和分析证券、衍生工具、外汇货币、股票、债券等商品随着时间的价格变动。


### 时序数据可视化



(d) 甘特图




(e) 热图





(f) 直方图

- **甘特图**通常用作项目管理的组织工具，显示活动（或任务）列表和持续时间，也显示每项活动何时开始和结束。
- **热图**通过色彩变化来显示数据。
- **直方图**适合用来显示在连续间隔或特定时间段内的数据分布，其中每个条形表示每个间隔/时间段中的频率。

### 时序数据可视化



(g) 折线图



(h) 南丁格尔玫瑰图




(i) OHLC 图

- **折线图**常用来显示趋势和关系。
- **南丁格尔玫瑰图**适用于周期性时序数据。
- **OHLC图**与蜡烛图类似用作交易工具，显示和分析证券、货币、股票、债券等商品随时间的价格变动。


### 时序数据可视化



(j) 螺旋图



(k) 堆叠式面积图



(l) 量化波形图

- **螺旋图**沿阿基米德螺旋线绘制基于时间的数据。螺旋图可使用条形、线条或数据点，沿着螺旋路径显示。
- **堆叠式面积图**的原理与简单面积图相同，但它能同时显示多个数据系列。
- **量化波形**可显示不同类别的数据随着时间的变化，其形状类似河流，因此量化波形图看起来相对美观。

### 多维数据可视化

- **多维数据**指的是具有多个维度属性的数据变量。
- 多维数据分析的目标是探索多维数据项的分布规律和模式，并揭示不同维度属性之间的隐含关系。
- **散点图**(Scatterplot)是最为常用的多维可视化方法。






Fig.19 2D and 3D scatterplot<sup>[89,90]</sup>

图 19 二维和三维散点图<sup>[89,90]</sup>




- Excel不需要复杂的学习就可以轻松使用，是普通用户的首选工具。
- 缺点：Excel在颜色、线条和样式上可选择的范围较为有限。




□ ECharts是百度的一个开源的数据可视化框架，一个纯 Javascript 的图表库，能够在 **PC 端和移动设备上**流畅运行。

□ ECharts 提供直观，生动，可交互，可高度个性化定制的数据可视化图表。




□ **Matplotlib**风格类似 MATLAB，是基于 Python 的图表绘图系统。

通过Matplotlib，开发者仅需要几行代码，便可以生成绘图，如直方图，功率谱，条形图，散点图等。



- ❑ **Tableau**是可视化领域标杆性的**商业智能分析软件**，起源于美国斯坦福大学的科研成果。
- ❑ **Tableau**实现了数据运算与美观的图表的完美结合，操作非常简单，用户只要将大量数据拖放到数字“画布”上，就能创建好各种图表，非常适合**企业**进行日常数据报表和数据可视化分析工作。



---

# 本章知识点总结

---

## 第二次课堂作业

假设某区域有 1 台农机，有 12 块地块  $A = \{1, 2, \dots, 12\}$  等待作业，所有地块都需要使用同一台农机。每块地均有一个作业开始时间  $s[i]$  和结束时间  $f[i]$ 。问：如何安排农机，才能让农机完成尽可能多的地块作业。（使用贪心算法求解）。

|        |   |   |   |   |   |   |    |    |   |    |    |    |    |
|--------|---|---|---|---|---|---|----|----|---|----|----|----|----|
|        | 1 | 1 | 2 | 3 | 4 | 5 | 6  | 7  | 8 | 9  | 10 | 11 | 12 |
| $s[i]$ | 2 | 1 | 3 | 0 | 5 | 3 | 6  | 8  | 5 | 9  | 8  | 11 |    |
| $f[i]$ | 4 | 3 | 5 | 6 | 7 | 9 | 10 | 11 | 9 | 12 | 13 | 14 |    |



华中农业大学

HUAZHONG AGRICULTURAL UNIVERSITY

Wuhan 430070, Hubei, P.R. China 中国·武汉 <http://www.hzau.edu> 传真: 027-87384670

1. 将地块按结束时间从小到大排序:

|        |   |   |   |   |   |   |   |    |    |    |    |    |
|--------|---|---|---|---|---|---|---|----|----|----|----|----|
| $i$    | 2 | 1 | 3 | 4 | 5 | 9 | 6 | 7  | 8  | 10 | 11 | 12 |
| $s[i]$ | 1 | 2 | 3 | 0 | 5 | 5 | 3 | 6  | 8  | 9  | 8  | 11 |
| $f[i]$ | 3 | 4 | 5 | 6 | 7 | 9 | 9 | 10 | 11 | 12 | 13 | 14 |

① 选地块 2, 结束时间为 3.

② 选 3, 5 结束

③ 选 5, 7 结束.

④ 选 8, 11 结束.

⑤ 选 12, 14 结束

∴ 最多选 5 块地, 2, 3, 5, 8, 12.

## 第二次课堂作业

1. 按结束时间排序

|     |   |   |   |   |   |   |   |    |    |    |    |    |
|-----|---|---|---|---|---|---|---|----|----|----|----|----|
| i   | 2 | 1 | 3 | 4 | 5 | 6 | 9 | 7  | 8  | 10 | 11 | 12 |
| sci | 1 | 2 | 3 | 0 | 5 | 3 | 5 | 6  | 8  | 9  | 8  | 11 |
| fc  | 3 | 4 | 5 | 6 | 7 | 9 | 9 | 10 | 11 | 12 | 13 | 14 |

则选择作业2, 然后选择开始时间大于等于3的最近序列即作业3, 则  $t_3=5$

然后选择作业5, 此时  $t_5=7$ , 则选择作业8, 则  $t_8=11$

则选择 ~~地块~~ 地块作业12

则安排的地块作业顺序为: 地块2 → 地块3 → 地块5 →

地块8 → 地块12

2.

## 第二次课堂作业


按结束时间排序：

地块  $i$     2   1   3   4   5   6   9   7   8   10   11   12

$s[i]$        1   2   3   0   5   3   5   6   8   9   8   11

$f[i]$        3   4   5   6   7   9   9   10   11   12   13   14

先选地块2、地块1冲突、选地块3、地块4  
冲突、.....



选择地块2、3、5、8、12

## 第二次课堂作业

图画 批注

按开始时间排序:

地块 4 2 1 3 6 5 9 7 8 11 10 12

$s[i]$  0 1 2 3 3 5 5 6 8 8 9 11

$f[i]$  6 3 4 5 9 7 9 10 11 13 12 14




只能完成3个.

# 第二次课堂作业

## 2. 递归算法-动态规划 (50分)

最后修改: 2026-04-15 19:49

老奶奶想买的某农产品售价10元，她身上有一张2元，一张3元，和两张5元的钱。(1) 问老奶奶能否凑出10元钱？若能，分别是哪几种方式？（PS：请用完全二叉树展开方法对所有可能的凑钱方式进行遍历。）(2) 用动态规划算法优化完全二叉树展开（即画出ppt上表格表示）。



能凑出10元钱，有2种方式：  
① 拿2张5元的钱  
② 拿1张2元，1张3元，1张5元。

12)


X表示用这行以上的元素凑出列所在的钱

|   | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|---|----|
| 2 | X |   | X |   |   |   |   |   |   |   |    |
| 3 | X |   | X | X |   | X |   |   |   |   |    |
| 5 | X |   | X | X |   | X | X | X | X |   | X  |
| 5 | X |   | X | X |   | X | X | X | X | X | X  |

# 第二次课堂作业

老奶奶想买的某农产品售价10元，她身上有一张2元，一否凑出10元钱？若能，分别是哪几种方式？（PS：请用：进行遍历。）（2）用动态规划算法优化完全二叉树展开（

2. (1) 树的节点表示已经凑的钱。



老奶奶能凑出10元。共2种有效方式：① {2, 3, 5}  
② {5, 5}

(2). 老奶奶的目标是凑10块钱。

X表示用这行 以上的元素集。凑出所在的钱

|   | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|---|----|
| 2 | X |   | X | X |   | X |   | X | X |   | X  |
| 3 | X |   | X |   |   | X |   | X |   |   | X  |
| 5 | X |   |   |   |   | X |   |   |   |   | X  |
| 5 |   |   |   |   |   | X |   |   |   |   | X  |

# 第二次课堂作业

## 2. 递归算法-动态规划 (50分)

最后修改: 2026-04-15 19:49

老奶奶想买的某农产品售价10元，她身上有一张2元，一张3元，和两张5元的钱。(1) 问老奶奶能否凑出10元钱？若能，分别是哪几种方式？（PS：请用完全二叉树展开方法对所有可能的凑钱方式进行遍历。）(2) 用动态规划算法优化完全二叉树展开（即画出ppt上表格表示）。

(1)

①  $2 + 3 + 5 \times 1 = 10$   
②  $2 \times 0 + 3 \times 0 + 5 \times 2 = 10$   
共 2 种

(2)

|        | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|--------|---|---|---|---|---|---|---|---|---|---|----|
| 2      | ✓ | × | ✓ | × | × | × | × | × | ✓ | × | ×  |
| 3      | ✓ | × | ✓ | ✓ | × | ✓ | × | × | ✓ | ✓ | ×  |
| 5 (2张) | ✓ | × | ✓ | ✓ | × | ✓ | × | ✓ | ✓ | ✓ | ✓  |

# 第二次课堂作业

## 3. 四门问题 (20分)

最后修改: 2026-04-15 19:49

参赛者会看见四扇关闭了的门，其中一扇的后面有一辆汽车，另外三扇门后面则各藏有一只山羊，选中后面有汽车的那扇门可赢得该汽车。当参赛者选定了一扇门，主持人会随机开启剩下的三扇门中有山羊的一扇门；并问：“要不要换一扇门？”。请分别用概率论推导（理论思维），求出换与不换获得汽车的概率。

设 A: 不换 B: 换

~~$P(A) = \frac{1}{4}$~~

第一次就选中汽车:  $P(A) = \frac{1}{4}$

第一次选中山羊的门:  $1 - P(A) = \frac{3}{4}$

$P(B) = \frac{3}{4} \times \frac{1}{2} = \frac{3}{8}$

$P(\text{换门得车}) = P(\text{初选车}) \cdot P(\text{换得车} | \text{初选车})$   
 $+ P(\text{初选羊}) \cdot P(\text{换得车} | \text{初选羊})$   
 $= \frac{1}{4} \times 0 + \frac{3}{4} \times \frac{1}{2}$   
 $= \frac{3}{8}$

~~$P(\text{不换得车}) = \frac{1}{4}$~~

$\frac{3}{8} > \frac{1}{4}$

$\therefore$  换门中奖概率高，换门。

## 第二次课堂作业

3.

① 不换门获得汽车的概率

不换门的中奖概率等于初始选中汽车的概率:

$$P(\text{不换中奖}) = \frac{1}{4}.$$

② 换门获得汽车的概率.

$$P(\text{换门中奖}) = P(\text{初始选车}) \times 0 + P(\text{初选选羊}) \times 1$$

$$= \frac{1}{4} \times 0 + \frac{3}{4} \times 1$$

$$= \frac{3}{4}.$$

## 第二次课堂作业

$$P_1 = P(B_1)P(A|B_1) = \frac{1}{4} \times \frac{1}{3} = \frac{1}{12}$$

$$P_2 = P(B_2)P(A|B_2) = \frac{1}{4} \times 0 = 0$$

$$P_3 = P(B_3)P(A|B_3) = \frac{1}{4} \times 1 = \frac{1}{4}$$

$$P_4 = P(B_4)P(A|B_4) = \frac{1}{4} \times 1 = \frac{1}{4}$$

$$P(A) = \frac{7}{12}$$

$$P(B_1|A) = \frac{\frac{1}{12}}{\frac{7}{12}} = \frac{1}{7}$$

$$P(B_3|A) = \frac{3}{7}$$

$$P(B_4|A) = \frac{3}{7}$$